中心化归一化网络的预测 KL 标度
固定深度标度定理

高斯回归；维度先行极限

2026 年 10 月 24 日

对任意固定深度、各层宽度与输入维数成正比的网络，本文证明平均 Bayes 预测 KL 的首项为 $P_{\text{hidden}}(d)/(2n)$。激活类包含中心化归一化的 tanh、sigmoid 和 ReLU。证明先从函数距离控制参数在排列和符号变换下的距离，再用互信息估计得到 Fisher 信息矩阵所需的谱性质。条件 I–MMSE 与高斯分部积分给出下界，线性高斯参考分布给出相同首项的上界。维数极限先于样本比极限；证明不要求固定样本比下的风险极限存在，也不依赖后验的局部高斯近似。

1 模型、激活类与定理

固定 $L \ge 1$，$k_0 = d$，$k_\ell/d \to \gamma_\ell \in (0,\infty)$，$\gamma_0 = 1$。第 ℓ 层权重为 $W^{(\ell)} \in \mathbb{R}^{k_\ell \times k_{\ell-1}}$，其元素独立标准高斯。输入 $x \sim N(0, I_d)$ 独立于参数。本文每层使用同一固定激活 $\sigma_\ell \equiv \sigma$，且

$$\mathbb{E}\sigma(G) = 0, \qquad \mathbb{E}\sigma(G)^2 = 1, \qquad G \sim N(0,1).$$

记 $W = (W^{(\ell)})_{\ell=1}^{L}$、$\theta = \theta(W) = (v, W)$，固定 $v_i = 1$，网络定义为

$$\begin{aligned} h^{(0)}(x) &= x, \qquad h^{(\ell)}(x) = \sigma_\ell\left(\frac{W^{(\ell)} h^{(\ell-1)}(x)}{\sqrt{k_{\ell-1}}}\right), \\ F_\theta^{(L)}(x) &= \frac{v^{\mathsf{T}} h^{(L)}(x)}{\sqrt{k_L}}. \end{aligned} \tag{1}$$

真实参数 $\theta^0 = (v, W^0)$ 由上述先验 P_0 抽取。训练集 $\mathcal{D}_n = \{(x_\mu, y_\mu)\}_{\mu=1}^n$ 由

$$y_\mu = F_{\theta^0}^{(L)}(x_\mu) + \sqrt{\Delta} z_\mu, \qquad z_\mu \sim N(0,1), \quad \Delta > 0$$

生成。训练和测试输入独立同分布；噪声相互独立，且独立于参数与全部输入。记 $P_{\text{out}}(y \mid \lambda) = N(y; \lambda, \Delta)$，真实先验和通道给出的后验为

$$P(d\theta \mid \mathcal{D}_n) \propto P_0(d\theta) \prod_{\mu=1}^{n} P_{\text{out}}\Big(y_\mu \mid F_\theta^{(L)}(x_\mu)\Big).$$

只有隐藏矩阵被学习，读出 v 固定；隐藏参数数目为

$$P_{\text{hidden}}(d) = \sum_{\ell=1}^{L} k_{\ell-1} k_\ell, \qquad c = \lim_d \frac{P_{\text{hidden}}(d)}{d^2} = \sum_{\ell=1}^{L} \gamma_{\ell-1}\gamma_\ell.$$

后验预测密度及平均预测 KL 定义为

$$\begin{aligned} p_{\mathcal{D}_n}(y \mid x) &= \mathbb{E}_{\theta \mid \mathcal{D}_n} P_{\text{out}}\Big(y \mid F_\theta^{(L)}(x)\Big), \\ \epsilon_{\log,d,n} &= \mathbb{E}_{\theta^0, \mathcal{D}_n, x}\, \mathrm{KL}\Big(P_{\text{out}}\Big(\cdot \mid F_{\theta^0}^{(L)}(x)\Big) \,\Big\|\, p_{\mathcal{D}_n}(\cdot \mid x)\Big). \end{aligned} \tag{2}$$

写 $\epsilon_{\log,d}(\alpha) := \epsilon_{\log,d,\lfloor \alpha d^2 \rfloor}$。下文简记 $p = P_{\text{hidden}}(d)$、$F_W = F = F_{\theta(W)}^{(L)}$、$\theta' = \theta(V)$，先验平均中的 W^0 简记为 W。微分、高斯积分和 OU 耦合仅作用于 $W \in \mathbb{R}^p$；齐次多项式网络另行定义。

所有常数允许依赖固定深度、激活、宽度比例与噪声，不能依赖 d, n。

1.1 激活类

取下列两类的并集 $\mathcal{A}_{\mathrm{bal}}$。两支均满足上述中心化及单位方差条件。光滑奇函数支：σ 有界、奇、属于 C^∞，每个固定阶导数有界。分段线性支：令 $c_0=\sqrt{2/\pi}$，

$$\sigma(z)=az+b(|z|-c_0),\qquad b\neq 0,\qquad a^2+b^2(1-2/\pi)=1. \tag{3}$$

两支均全局 Lipschitz。

记 He_j 为概率论约定的 Hermite 多项式，$\psi_j=\mathrm{He}_j/\sqrt{j!}$、$a_j=\mathbb{E}[\sigma(G)\psi_j(G)]$。与网络符号一致，$\mu_{\ell,j}=\mu_j=\sqrt{j!}a_j$。以下事实使光滑支无需另加高阶系数假设。

引理 1 (高阶奇系数自动存在)**.** *若 σ 为有界连续奇函数且 $\mathbb{E}\sigma(G)^2=1$，则存在奇数 $m\geq 5$ 使 $a_m\neq 0$。*

证明. 若结论不成立，奇性和 Hermite 系的完备性给出 $\sigma=a_1\psi_1+a_3\psi_3$ 高斯几乎处处成立；连续性使等式处处成立。有界奇多项式只能为零，与单位方差矛盾。 □

光滑支固定选择上述一个 m；分段线性支取 $m=6$，其 $a_6\neq 0$ 在下节直接验证。m 可依赖固定激活，但不随维数或样本数变化；后文常数允许依赖此选择。

定理 1. *上述模型中，对任意固定深度 $L\geq 1$，任一固定 $\sigma\in\mathcal{A}_{\mathrm{bal}}$ 满足*

$$\boxed{\lim_{\alpha\to\infty}\limsup_{d\to\infty}\left|\alpha\epsilon_{\log,d}(\alpha)-\frac{c}{2}\right|=0.} \tag{4}$$

该结论包含任意固定正斜率的中心化归一化 tanh、logistic sigmoid，以及中心化归一化 ReLU。

先取 $d\to\infty$，再取 $\alpha\to\infty$；不要求固定 α 的风险极限存在。

1.2 tanh、sigmoid 与 ReLU

对任意固定 $a>0$，令

$$s_a^2=\mathbb{E}\tanh^2(aG)>0,\qquad \sigma_a(z)=\tanh(az)/s_a.$$

它是有界光滑奇函数，且方差为一。由 $\tanh'=1-\tanh^2$ 递推，每阶导数都是 $\tanh(az)$ 的多项式，因而有界，故属于光滑支。对固定 $b>0$，logistic sigmoid $\ell_b(z)=(1+e^{-bz})^{-1}$ 满足 $\ell_b(z)-1/2=\tanh(bz/2)/2$，其均值为 $1/2$、方差为 $s_{b/2}^2/4$，中心化归一化后恰为 $\sigma_{b/2}$。

对 ReLU，直接积分给出

$$\mu_R=\mathbb{E}G_+=\frac{1}{\sqrt{2\pi}},\qquad v_R=\mathrm{Var}(G_+)=\frac{1}{2}-\frac{1}{2\pi},\qquad \sigma_R(z)=\frac{z_+-\mu_R}{\sqrt{v_R}}.$$

由 $z_+=(z+|z|)/2$，它对应式 (3) 的 $a=b=1/(2\sqrt{v_R})$。整个分段线性支都中心化；奇偶正交性给出其方差 $a^2+b^2(1-2/\pi)=1$。由 $\mathrm{He}_6(z)=z^6-15z^4+45z^2-15$ 及 $\mathbb{E}|G|^{2j+1}=2^j j!\sqrt{2/\pi}$，得到

$$\mathbb{E}[|G|\,\mathrm{He}_6(G)]=3\sqrt{2/\pi},\qquad a_6=\frac{3b\sqrt{2/\pi}}{\sqrt{6!}}\neq 0.$$

分段线性支的奇次系数 a_j 在 $j\geq 3$ 时均为零；光滑奇函数支的偶次系数均为零。这正是后文两类展开项所使用的奇偶结构。

2 先验矩与局部估计

令 $q_\ell=\|h^{(\ell)}\|^2/k_\ell$、$a(W,X)=\nabla_W F_{\theta(W)}^{(L)}(X)$。附录引理 3–6 证明：对每个固定 $r>0$，

$$\mathbb{E}|q_\ell-1|^r\leq C_r d^{-r/2},\qquad \mathbb{E}|F_{\theta(W)}^{(L)}(X)|^r+\mathbb{E}\|a(W,X)\|^r\leq C_r. \tag{5}$$

存在只依赖固定模型参数的 $0<\delta\leq 1$，使对与 (W,X) 独立的标准高斯 Z，有

$$W_\tau=e^{-\tau}W+\sqrt{1-e^{-2\tau}}Z,\qquad \mathbb{E}\|a(W_\tau,X)-a(W,X)\|^2\leq C\tau^\delta\quad(0<\tau\leq 1). \tag{6}$$

对 $0 < t \le 1/2$，写 $W(t) = \sqrt{1-t}W + \sqrt{t}Z$，则一阶展开满足

$$\begin{aligned} F^{(L)}_{\theta(W(t))} - F^{(L)}_{\theta(W)} &= \sqrt{t}\, a(W,\cdot)^T Z + E_t, \\ \mathbb{E}\|E_t\|^2_{L^2_X} &\le C t^{1+\delta}. \end{aligned} \tag{7}$$

常数和指数不依赖扰动参数；维数阈值允许依赖该参数，并在其紧离零的区间上一致。以下局部界均在对应阈值以上使用。

3 全局函数比较与参数匹配

本节证明：两个网络的输出接近时，其参数在适当排列和符号变换后也接近。先用一个齐次多项式网络提取实际输出中可比较的分量。沿用 ψ_j, a_j 的定义，置

$$N = m^L, \qquad S = 1 + m + \cdots + m^{L-1}, \qquad B = a_m^S \neq 0.$$

以各层齐次激活 $z^m/\sqrt{m!}$、原权重与原读出构造多项式网络，其最高输入次数系数为 $C_N(W) \in \mathrm{Sym}^N \mathbb{R}^d$。定义

$$H_m(W) = I_N(C_N(W)), \qquad T_W = B H_m(W).$$

记 Π_N 为 $L^2(P_X)$ 到第 N 阶 Hermite 子空间的正交投影。I_N 将对称张量映为该子空间中的多项式：对 $v \neq 0$，$I_N(v^{\otimes N})(X) = \|v\|^N \mathrm{He}_N(\langle v, X\rangle/\|v\|)$，再线性延拓。其归一化满足

$$\langle I_N(C), I_N(D)\rangle_{L^2_X} = N!\langle C, D\rangle. \tag{8}$$

张量均取对称张量空间中继承的 Hilbert 范数。

引理 2 (函数内积的统一估计)**.** *若 Π_d 为原高斯参数先验，记 $\Gamma(\Pi_d, \Pi_d)$ 为两个边缘均为 Π_d 的联合分布集合，则*

$$e_d := \sup_{\pi \in \Gamma(\Pi_d, \Pi_d)} \mathbb{E}_\pi |\langle T_W, F^{(L)}_{\theta'} - T_V\rangle_{L^2_X}| \longrightarrow 0. \tag{9}$$

这里允许任意正确先验边缘的耦合，不要求 W, V 独立。

证明. 附录 D 给出实际输出的多项式近似，附录 E 逐项比较并控制耦合误差，得到式 (56)，即本引理。 □

对内积估计展开平方，得到齐次多项式网络的距离控制。对某个正确边缘耦合令 $D = \mathbb{E}\,\|T_W - T_V\|^2$、$B_F = \mathbb{E}\left\|F^{(L)}_\theta - F^{(L)}_{\theta'}\right\|^2$。在原耦合、转置耦合以及两个对角项中分别使用 (9)，得

$$|\mathbb{E}\langle T_W - T_V, F^{(L)}_\theta - F^{(L)}_{\theta'}\rangle - D| \le 4e_d.$$

所以

$$D \le \sqrt{D B_F} + 4e_d \le (D + B_F)/2 + 4e_d, \quad D \le B_F + 8e_d.$$

齐次全局匹配定理给出有限可测映射族 $\mathcal{G}_d$，

$$\begin{aligned} \log|\mathcal{G}_d| &= O(d\log d) = o(p), \\ \frac{1}{p}\mathbb{E}\min_{g\in\mathcal{G}_d}\|W - gV\|^2 &\le C\mathbb{E}\,\|H_m(W) - H_m(V)\|^2 + o_d(1) \\ &\le C\mathbb{E}\left\|F^{(L)}_\theta - F^{(L)}_{\theta'}\right\|^2 + o_d(1). \end{aligned} \tag{10}$$

误差对耦合一致，逐层匹配的证明见附录 F。映射可包含行符号变换；后文仅用这些有限标签控制条件熵，不要求它们保持实际网络输出。

4 互信息界与后验收缩

记 $I_{d,n}=I(\theta^0;\mathcal{D}_n)=I(W;\mathcal{D}_n)$。Bayes 定义和样本条件独立性给出

$$\epsilon_{\log,d,n}=I_{d,n+1}-I_{d,n},\qquad \epsilon_{\log,d,n+1}\le\epsilon_{\log,d,n}. \tag{11}$$

第二式也可由条件熵递减看出：真实条件噪声熵不随数据量改变，预测熵随观察增加而减小。

4.1 粗风险上界

固定充分大的 u，令 $n=\lfloor ud^2\rfloor$、$t=(1+n/p)^{-1}$。此时 $t\to(1+u/c)^{-1}>0$，故维数充分大时 t 位于紧离零的区间；下一节仅由先验矩与 OU 余项证明的 (21) 因而适用。又

$$\mathbb{E}\log\det(I_p+ntA/\Delta)\le nt\mathbb{E}\,\mathrm{tr}\,A/\Delta\le Cp,\qquad (n/p)t^{1+\delta}\le 1,$$

所以 $I_{d,n}\le\frac{p}{2}\log(1+n/p)+Cp$。由 (11)，$n\epsilon_{\log,d,n}\le I_{d,n}$，因此

$$\limsup_d\epsilon_{\log,d}(u)\le C\frac{\log u}{u}\qquad (u\text{ 充分大}). \tag{12}$$

4.2 后验参数距离与条件熵

给定 $\mathcal{D}_n$ 独立抽取后验样本 W,V；平均数据后两者保持原先验边缘。记 $B_X=F^{(L)}_{\theta(W)}(X)-F^{(L)}_{\theta(V)}(X)$。以后验预测密度为中间点，Hellinger 三角不等式和 $H^2\le\mathrm{KL}$ 给

$$\mathbb{E}[1-e^{-B_X^2/(8\Delta)}]\le 2\epsilon_{\log,d,n}, \tag{13}$$

其中指数项是两个同方差高斯密度的亲和度。对固定 $q>2$，标量不等式

$$z^2\le C_q(1+|z|^q)^{2/q}(1-e^{-z^2/(8\Delta)})^{1-2/q}$$

由分别考察 $|z|\le 1$ 和 $|z|>1$ 得到。Hölder 与 (5) 因而给 $\mathbb{E}B_X^2\le C_q\epsilon_{\log,d,n}^{1-2/q}$。定义

$$r_{d,n}=\frac{1}{p}\mathbb{E}\min_{g\in\mathcal{G}_d}\|W-gV\|^2,\qquad r_*(u)=\limsup_d r_{d,\lfloor ud^2\rfloor}.$$

在 (10) 中取此后验耦合，再取 $q=2/\eta$，由 (12) 得

$$r_*(u)\le C_\eta(\log u/u)^{1-\eta},\qquad 0<\eta<1. \tag{14}$$

在同一耦合中选择可测最优标签 $\widehat{g}$，并令 $V_t=\sqrt{1-t}W+\sqrt{t}U$，其中 U 独立于上述变量且为标准高斯，$0\le t\le 1/2$。给定 $\mathcal{D}_n$，V 与 V_t 独立；且

$$\mathbb{E}\|V_t-\sqrt{1-t}\widehat{g}V\|^2=p[t+(1-t)r_{d,n}].$$

条件于 $(\mathcal{D}_n,V,\widehat{g})$ 后用高斯最大熵，再用 Jensen，得到

$$h(V_t\mid\mathcal{D}_n)\le\log|\mathcal{G}_d|+\frac{p}{2}\log\{2\pi e[t+(1-t)r_{d,n}]\}. \tag{15}$$

这里加入标签的条件熵至多为 $\log|\mathcal{G}_d|$。$t=0$ 时 $V_0=W$；从 $h(W)=\frac{p}{2}\log(2\pi e)$ 减去上述界并用 (14)，得

$$\liminf_d\frac{I_{d,\lfloor\alpha d^2\rfloor}}{p}\ge\frac{1-\eta}{2}\log\alpha-\frac{1-\eta}{2}\log\log\alpha-C_\eta. \tag{16}$$

这里 $\eta\in(0,1)$ 固定，α 充分大。对 $t>0$，记 $J_n(t)=I(W;V_t\mid\mathcal{D}_n)$。从 (15) 减去条件噪声熵，得到

$$J_n(t)\le\log|\mathcal{G}_d|+\frac{p}{2}\log\left(1+\frac{(1-t)r_{d,n}}{t}\right)\le\log|\mathcal{G}_d|+\frac{pr_{d,n}}{2t}. \tag{17}$$

5 线性高斯参考分布与互信息界

对上述 V_t，$0<t\le 1/2$ 时可反向写为 $W=\sqrt{1-t}V_t+\sqrt{t}\xi$，其中 ξ 与 V_t 独立标准高斯。记 $f_W=F^{(L)}_{\theta(W)}$、$a(x)=\nabla f_{V_t}(x)$、$A=\mathbb{E}_X a(X)a(X)^T$。对固定 t 及 $d\ge d_0(t)$，(7)、(5) 给出

$$f_W(x)-f_{V_t}(x)=\sqrt{t}\,a(x)^T\xi+R_t(x),\qquad \mathbb{E}\|R_t\|^2_{L^2_X}\le Ct^{1+\delta},\quad \mathbb{E}\|a(X)\|^4\le C.$$

5.1 相对熵分解与互信息增量

给定 $V_t,X_{1:j}$，令 Φ_j 的第 i 行为 $a(X_i)^T$，定义

$$Q_j=N\big((f_{V_t}(X_i))_{i\le j},S_j\big),\qquad S_j=\Delta I_j+t\Phi_j\Phi_j^T.$$

这些参考分布由同一个虚拟系数 $\zeta\sim N(0,I_p)$ 的线性模型 $f_{V_t}(X_i)+\sqrt{t}\,a(X_i)^T\zeta+\sqrt{\Delta}Z_i$ 产生，因此其样本边缘相容。输入采用真实的独立分布，虚拟系数不作为额外观察。令 P_j 为给定 V_t 的真实数据分布，定义

$$C_j=\mathbb{E}\log\frac{p(Y_{1:j}\mid W,X_{1:j})}{q_j(Y_{1:j}\mid V_t,X_{1:j})},\qquad B_j=\mathbb{E}_{V_t}\mathrm{KL}(P_j\|Q_j).$$

P_j,Q_j 包含相同的输入边缘。由相对熵分解和 Markov 链 $V_t-W-\mathcal{D}_j$，

$$I_{d,j}+J_j(t)=\frac{p}{2}\log(1/t)+C_j-B_j.\tag{18}$$

参考分布的边缘相容性给 $B_n\ge B_j\ge 0$。结合 $J_n(t)\ge 0$，同一恒等式给

$$I_{d,n}\le\frac{p}{2}\log(1/t)+C_n,\qquad I_{d,n}-I_{d,j}\le C_n-C_j+J_j(t).\tag{19}$$

5.2 交叉熵的非线性误差

令 $L_j=\sqrt{t}\Phi_j\xi$、$R_j=(R_t(X_i))_{i\le j}$，并置 $H_j=\mathbb{E}\log\det(I_p+t\Phi_j^T\Phi_j/\Delta)$。高斯密度公式和 Sylvester 恒等式给

$$C_j=H_j/2+\mathbb{E}L_j^TS_j^{-1}R_j+\tfrac12\mathbb{E}R_j^TS_j^{-1}R_j,$$

其中纯线性项与噪声项精确抵消，因为 $\mathbb{E}[L_j^TS_j^{-1}L_j\mid V_t,X_{1:j}]+\Delta\,\mathrm{tr}\,S_j^{-1}=j$。又由 $S_j\succeq\Delta I_j$，

$$\mathbb{E}L_j^TS_j^{-1}L_j=\mathbb{E}\,\mathrm{tr}(t\Phi_j\Phi_j^TS_j^{-1})\le p,\qquad \mathbb{E}R_j^TS_j^{-1}R_j\le Cjt^{1+\delta}.$$

加权 Cauchy–Schwarz 给出

$$|C_j-H_j/2|\le C\sqrt{pjt^{1+\delta}}+Cjt^{1+\delta}.\tag{20}$$

此处不要求 R_j 与 ξ 独立。

5.3 经验与总体行列式的比较

置 $\overline{H}_j=\mathbb{E}\log\det(I_p+jtA/\Delta)$。在 $M\succeq I_p$ 上，$D^2(-\log\det)(M)[H,H]=\mathrm{tr}(M^{-1}HM^{-1}H)\le\|H\|^2_{\mathrm{HS}}$。条件于 V_t，对 $I_p+(t/\Delta)\sum_{i\le j}a(X_i)a(X_i)^T$ 在其均值处作二阶 Taylor 展开，再用条件独立性与梯度四阶矩，得

$$0\le\overline{H}_j-H_j\le\frac{jt^2}{2\Delta^2}\mathbb{E}\|a(X)a(X)^T-A\|^2_{\mathrm{HS}}\le Cjt^2.$$

对 $n>j\ge 1$，逐特征值使用 $(1+nt\lambda/\Delta)/(1+jt\lambda/\Delta)\le n/j$，故

$$H_n-H_j\le\overline{H}_n-\overline{H}_j+Cjt^2\le p\log(n/j)+Cjt^2.$$

由 (19) 的第一式、(20) 及 $H_n\le\overline{H}_n$，累计信息满足

$$\begin{aligned}\frac{I_{d,n}}{p}&\le\frac12\log\frac1t+\frac{1}{2p}\mathbb{E}\log\det(I_p+ntA/\Delta)\\&\quad+C\sqrt{\frac{n}{p}t^{1+\delta}}+C\frac{n}{p}t^{1+\delta}.\end{aligned}\tag{21}$$

6 信息矩阵的谱与预测下界

令 $a_W(x)=\nabla_W F_\theta^{(L)}(x)$、$\mathcal{I}_W=\mathbb{E}_X a_W a_W^{T}/\Delta$，并记

$$D_d(r)=\mathbb{E}\frac{1}{p}\operatorname{tr}\{r(p\mathcal{I}_W+rI)^{-1}\},\qquad \nu_d=\frac{1}{p}\mathbb{E}\sum_{i=1}^{p}\delta_{\lambda_i(p\mathcal{I}_W)}.$$

由梯度二阶矩，$\int\lambda\,d\nu_d=\mathbb{E}\operatorname{tr}\mathcal{I}_W\le C$。

6.1 互信息界排除零附近的正比例谱质量

记 $q_d(s)=\nu_d([0,s])$。反设 $b=\lim_{s\downarrow0}\limsup_d q_d(s)>0$，固定 $0<\beta<b$。固定 $1/(1+\delta)<a<1$，在 (21) 中取 $n=\lfloor\alpha d^2\rfloor$、$t=\alpha^{-a}$。对每个充分大的固定 α，可选维数子序列使 $q=q_d(\alpha^{-1})\ge\beta$。因 $n/p\to\alpha/c$，记 $Q_d=nt/p\le C\alpha^{1-a}$。$A/\Delta$ 与 $\mathcal{I}_W$ 同分布，所以 Jensen 不等式给

$$\begin{aligned}\frac{1}{p}\mathbb{E}\log\det(I_p+ntA/\Delta)&=\int\log(1+Q_d\lambda)\,d\nu_d\\&\le\log(1+Q_d/\alpha)+(1-q)\log\left(1+\frac{CQ_d}{1-q}\right)\\&\le(1-\beta)(1-a)\log\alpha+C.\end{aligned}$$

$q=1$ 时第二项按连续延拓取零；最后一步用 $-(1-q)\log(1-q)\le1/e$。故沿该子序列，信息上界至多

$$\frac{1-\beta(1-a)}{2}\log\alpha+C+o_\alpha(1).$$

在 (16) 中固定 $\eta=\beta(1-a)/2$，其 $\log\alpha$ 系数比上式大 $\beta(1-a)/4$，而其余损失仅为 $O_\eta(\log\log\alpha)$。令 $\alpha\to\infty$ 得矛盾，因此 $b=0$。最后由 $D_d(r)\le q_d(s)+r/s$，依次令 $d\to\infty$、$r\downarrow0$、$s\downarrow0$，得到

$$D_*(r):=\limsup_d D_d(r),\qquad\lim_{r\downarrow0}D_*(r)=0.\tag{22}$$

6.2 预测 KL 下界

附录 G 对正则化测试场作 OU 平滑，证明

$$\epsilon_{\log,d,n}\ge\frac{p[1-D_d(r)-C\sqrt{r}]_+^2}{2\{n(1+C\sqrt{r})^2+Cp/r^{1+2/\delta}\}},\quad 0<r\le1,\ d\ge d_0(r).\tag{23}$$

固定 r，依次令 $d\to\infty$、$\alpha\to\infty$，得到

$$\liminf_{\alpha\to\infty}\alpha\liminf_d\epsilon_{\log,d}(\alpha)\ge\frac{c[1-D_*(r)-C\sqrt{r}]_+^2}{2(1+C\sqrt{r})^2}.$$

最后由 (22) 令 $r\downarrow0$，得到

$$\liminf_{\alpha\to\infty}\alpha\liminf_d\epsilon_{\log,d}(\alpha)\ge c/2.\tag{24}$$

7 预测 KL 上界

固定 $\vartheta\in(0,1)$，取 $n=\lfloor\alpha d^2\rfloor$、$j=\lfloor(1-\vartheta)\alpha d^2\rfloor$。由风险递减及 (19)，有 $(n-j)\epsilon_{\log,d,n}\le C_n-C_j+J_j(t)$。代入 (17)、(20) 和行列式差界，固定 α,t 后令 $d\to\infty$，由 $p/d^2\to c$、$\log|\mathcal{G}_d|=o(d^2)$ 得

$$\begin{aligned}\alpha\limsup_d\epsilon_{\log,d}(\alpha)\le{}&\frac{c}{2\vartheta}\left\{\frac{r_*((1-\vartheta)\alpha)}{t}+\log\frac{1}{1-\vartheta}\right\}\\&+\frac{C}{\vartheta}\left\{\alpha t^2+\sqrt{\alpha t^{1+\delta}}+\alpha t^{1+\delta}\right\}.\end{aligned}\tag{25}$$

固定 $1/(1+\delta) < a < 1$ 和 $0 < \eta < 1-a$，取 $t = \alpha^{-a}$。由 (14)，第一误差为 $O_\vartheta(\alpha^{a-1+\eta}(\log\alpha)^{1-\eta}) = o(1)$；又因 $a > 1/2$、$a(1+\delta) > 1$，其余三项也趋零。先 $\alpha \to \infty$，再 $\vartheta \downarrow 0$，由 $\vartheta^{-1}\log(1/(1-\vartheta)) \to 1$ 得

$$\limsup_{\alpha\to\infty} \alpha \limsup_{d} \epsilon_{\log,d}(\alpha) \le c/2.$$

结合 (24)，并使用

$$\limsup_{d} |\alpha\epsilon_{\log,d}(\alpha) - c/2| = \max\{\alpha \limsup_{d} \epsilon_{\log,d}(\alpha) - c/2,\, c/2 - \alpha \liminf_{d} \epsilon_{\log,d}(\alpha)\},$$

即得定理 1。

A 固定深度网络的解析估计及分部积分的定义域

沿用模型中的 $h^{(\ell)}, F$，记 $u^{(\ell)} = W^{(\ell)}h^{(\ell-1)}/\sqrt{k_{\ell-1}}$。固定深度 L，且 $cd \le k_\ell \le Cd$；期望均对独立高斯权重和输入。本节矩估计也允许各层使用不同的固定、中心化单位方差的 Lipschitz 激活。各矩阶先固定，常数可依赖激活、深度和宽比。OU 估计的常数不依赖扰动参数；维数阈值允许依赖该参数，并在紧离零区间上一致。

A.1 输出和隐藏范数的任意固定阶矩

引理 3. 令 $q_\ell = \|h^{(\ell)}\|^2/k_\ell$。每个固定 $r > 0$ 均有

$$\mathbb{E}q_\ell^r \le C_r, \qquad \mathbb{E}|q_\ell - 1|^r \le C_r d^{-r/2}, \qquad \mathbb{E}|F|^r \le C_r.$$

单个特征及任意固定个特征的乘积也有任意固定阶矩界；特征可来自不同层或具有上述高斯边缘的耦合输入。

证明. 写 $b(q) = \mathbb{E}\sigma(\sqrt{q}G)$、$v(q) = \mathbb{E}\sigma(\sqrt{q}G)^2$。Lipschitz 性、中心化及单位方差给出全局界

$$\mathbb{E}|\sigma(\sqrt{q}G)|^s \le C_s(1+q^{s/2}), \qquad |b(q)| + |v(q)-1| \le C|q-1| \quad (q \ge 0). \tag{26}$$

这里用 $|\sigma(z)| \le C(1+|z|)$ 及 $|\sqrt{q}-1|(\sqrt{q}+1) = |q-1|$。若 Y_i 给定 $\mathcal{F}$ 后独立且中心化，则

$$\mathbb{E}\left[\left|N^{-1}\sum_i Y_i\right|^{2m}\middle|\mathcal{F}\right] \le C_m N^{-m} \max_i \mathbb{E}[|Y_i|^{2m} \mid \mathcal{F}]. \tag{27}$$

证明只需展开 $2m$ 次幂：单次出现的指标使该项为零，其余项至多有 m 个指标，共 $O_m(N^m)$ 项，每项由 Hölder 控制。

给定前层，本层行输出独立同分布为 $\sigma(\sqrt{q_{\ell-1}}G)$。先由 Jensen 与式 (26) 归纳得 $\mathbb{E}q_\ell^{2m} \le C_m$；再对 $Y_i = (h_i^{(\ell)})^2 - v_\ell(q_{\ell-1})$ 用式 (27)，得到

$$\mathbb{E}|q_\ell - 1|^{2m} \le C_m d^{-m} + C_m\mathbb{E}|q_{\ell-1}-1|^{2m} = O(d^{-m}).$$

初值 $q_0 = d^{-1}\sum_i X_i^2$ 由同一展开给出。真实全一读出保留其条件均值：

$$F = \sqrt{k_L}b_L(q_{L-1}) + k_L^{-1/2}\sum_i \{h_i^{(L)} - b_L(q_{L-1})\}.$$

第一项的 $2m$ 阶矩至多 $C_m k_L^m \mathbb{E}|q_{L-1}-1|^{2m} = O(1)$，第二项由式 (27) 及正矩界控制。取 $2m \ge r$ 得全部所需阶数；单个特征矩由条件行估计给出，固定乘积矩由 Hölder 得到。 □

A.2 梯度的任意固定阶矩

令 $A_\ell = W^{(\ell)}/\sqrt{k_{\ell-1}}$，$B_\ell = \|A_\ell\|_{\mathrm{op}}$。以后 P 表示 $1 + \|X\|/\sqrt{d}$ 与有限个 B_ℓ 的非负固定次数多项式；存在第二组独立高斯矩阵时也允许其归一化算子范数。所有这样的 P 都有一致有界的固定阶矩。事实上，两球面的 $1/4$ 网各有至多 $9^m, 9^r$ 个点；网逼近及标量高斯尾界给 $m \times r$ 标准高斯矩阵 G 的尾界

$$\Pr\{\|G\|_{\mathrm{op}} > 2u\} \le 2\,9^{m+r} e^{-u^2/2}.$$

在有界宽比下积分尾界，得到归一化算子范数的全部固定阶矩。

引理 4. *对 Lipschitz 激活，弱梯度满足 $\mathbb{E}\|\nabla_W F\|^r \le C_r$，每个固定 $r > 0$ 均成立。*

证明. 前向递推给出 $\|h^{(\ell)}\|/\sqrt{k_\ell} \le P$。定义

$$\beta_L = k_L^{-1/2}\mathbf{1}, \quad \lambda_\ell = \mathrm{diag}(\sigma'_\ell(u^{(\ell)}))\beta_\ell, \quad \beta_{\ell-1} = A_\ell^T \lambda_\ell.$$

由有界斜率，$\|\beta_\ell\| + \|\lambda_\ell\| \le P$，且

$$\nabla_{W^{(\ell)}} F = \lambda_\ell (h^{(\ell-1)})^T/\sqrt{k_{\ell-1}}, \qquad \|\nabla_W F\|^2 \le P. \tag{A3}$$

网络局部 Lipschitz，上述几乎处处的链式公式代表其弱梯度。

□

A.3 两类激活的梯度变化

引理 5. *令 $W' = \sqrt{1-t}W + \sqrt{t}Z$，$Z$ 独立标准高斯，$0 < t \le 1/2$。对任意范数多项式 P 和固定 $t > 0$，充分大的 d 下两类激活均满足*

$$\mathbb{E}[P\|\nabla F(W', X) - \nabla F(W, X)\|^2] \le C_P t^{1/4}.$$

常数独立于 t，维数阈值在紧离零区间上一致。

证明. 反向坐标首先满足，对每个固定 $s > 0$，

$$\mathbb{E}[P|\beta_{\ell,i}|^{2s}] \le C_{P,s} k_\ell^{-s}. \tag{28}$$

终层直接成立。其余层给定 $h = h^{(\ell)}$，下一层高斯矩阵在右乘任何固定 h 的正交变换时分布不变，β_ℓ 相应旋转；反向范数只由独立于 h 的下游算子范数控制，故 $\mathbb{E}[\|\beta_\ell\|^{2s} \mid h] \le C_s$。沿 h 及垂直于 h 分解，并用后者均匀球面方向的坐标矩，得

$$\mathbb{E}[|\beta_{\ell,i}|^{2s} \mid h] \le C_s \left(k_\ell^{-s} + |h_i|^{2s}/\|h\|^{2s}\right).$$

$h = 0$ 时分布对全部旋转不变，上式的比值取零。在 $q_\ell \ge 1/2$ 上用特征正矩，在补集上用比值不超过一及 $\Pr(q_\ell < 1/2) \le C_m d^{-m}$（引理 3），得到无权坐标矩；再对 P 用 Cauchy–Schwarz 即得 (28)。这里 U 在 S^{n-1} 上均匀时，标准高斯径向分解给 $\mathbb{E}|U_1|^{2s} = \Gamma(s+1/2)\Gamma(n/2)/(\sqrt{\pi}\Gamma(n/2+s)) \le C_s n^{-s}$。

前向递推给 $\|A'_\ell - A_\ell\|_{\mathrm{op}} \le \sqrt{t}P$、$\|h'^{(\ell)} - h^{(\ell)}\|/\sqrt{k_\ell} \le \sqrt{t}P$。记 $D_\ell = \mathrm{diag}(\sigma'(u^{(\ell)}))$。光滑支中，给定前层，$u'_i - u_i$ 是中心高斯，方差不超过 $C(tq_{\ell-1} + \|h' - h\|^2/k_{\ell-1})$，故 $\mathbb{E}|\sigma'(u'_i) - \sigma'(u_i)|^4 \le C\mathbb{E}|u'_i - u_i|^4 \le Ct^2$。分段线性支中，令 $\mathcal{G} = \{q_{\ell-1}, q'_{\ell-1} \ge 1/2\}$。给定前层，在 $\mathcal{G}$ 上两预激活为中心高斯，相关系数为 $\sqrt{1-t}\langle h, h'\rangle/(\|h\|\|h'\|)$，其夹角满足

$$\omega_\ell \le C\left(\sqrt{t} + \frac{\|h - h'\|}{\sqrt{\|h\|\|h'\|}}\right) \le \sqrt{t}P.$$

二维高斯极角均匀性给条件异号概率 ω_ℓ/π，而 $\Pr(\mathcal{G}^c) \le C_m d^{-m}$，因此 $\Pr(u_i u'_i < 0) \le C\sqrt{t} + C_m d^{-m}$。零预激活在 $\mathcal{G}$ 上概率为零；在预激活为零处任选有界斜率代表，其可能贡献由 $\Pr(\mathcal{G}^c)$ 吸收，仍得 $\mathbb{E}|\sigma'(u'_i) - \sigma'(u_i)|^4 \le C\sqrt{t} + C_m d^{-m}$。于是两支均有

$$\mathbb{E}[P\|(D'_\ell - D_\ell)\beta_\ell\|^2] \le \sum_i (\mathbb{E}[P^2\beta_{\ell,i}^4])^{1/2}(\mathbb{E}|\sigma'(u'_i) - \sigma'(u_i)|^4)^{1/2} \le C_P(t^{1/4} + d^{-1}).$$

从相同读出反向使用 $\lambda'_\ell - \lambda_\ell = D'_\ell(\beta'_\ell - \beta_\ell) + (D'_\ell - D_\ell)\beta_\ell$ 及 $\beta'_{\ell-1} - \beta_{\ell-1} = A_\ell^T(\lambda'_\ell - \lambda_\ell) + (A'_\ell - A_\ell)^T\lambda'_\ell$。算子范数仅改变允许的 P，矩阵差项为 $O(t)$，故固定深度归纳保留上述界。最后展开梯度块公式 (A3) 的乘积差，得到同一界。固定 $t > 0$ 后取 $d^{-1} \le t^{1/4}$ 即得结论；光滑支全程为 $O(t)$。 □

A.4 OU 梯度变化与余项

引理 6. 式 (6) 和式 (7) 以统一指数 $\delta = 1/4$ 成立，维数阈值按本节约定。

证明. 记 c_N 为对 X 平均后的第 N 阶参数 Hermite 能量，$a_t = \sqrt{1-t}$，并令 $G(t) = \mathbb{E}\|\nabla F(W(t), X) - \nabla F(W, X)\|^2$。正交性和 $\partial_i H_\nu = \sqrt{\nu_i} H_{\nu - e_i}$ 给

$$G(t) = 2 \sum_{N \geq 1} N(1 - a_t^{N-1}) c_N \leq C t^\delta.$$

末步由引理 5，两支统一取 $\delta = 1/4$。取 $t = 1 - e^{-2\tau}$ 即得第一式；$t > 1/2$ 时由梯度二阶矩增大常数即可。对式 (7) 的余项，同一正交展开及关于 Z 的分部积分给

$$\mathbb{E}\|E_t\|_{L^2_X}^2 = \sum_{N \geq 1} \{2(1 - a_t^N) + tN - 2tN a_t^{N-1}\} c_N.$$

当 $N \geq 2$ 时 $a_t^N \geq 1 - Nt/2$；当 $N = 1$ 时大括号等于 $(1 - a_t)^2 \leq t^2$。因此

$$\mathbb{E}\|E_t\|_{L^2_X}^2 \leq t^2 \mathbb{E}\|\nabla F\|^2 + t G(t) \leq C t^{1+\delta}. \tag{29}$$

计算先对有限 Hermite 和成立，再在高斯 Sobolev 范数下取极限。 □

A.5 高斯分部积分的定义域

引理 7. 设 $g : \mathbb{R}^p \to \mathbb{R}^p$ 属于高斯 $W^{1,2}$，也允许值域带独立的外部 L^2 变量。定义 $\delta g = \operatorname{div} g - W \cdot g$。则其闭扩张满足

$$\mathbb{E}(\delta g)^2 = \mathbb{E}\|g\|^2 + \mathbb{E} \sum_{i,j} (\partial_i g_j)(\partial_j g_i) \leq \mathbb{E}\{\|g\|^2 + \|Dg\|_{\mathrm{HS}}^2\}. \tag{A13}$$

证明. 对紧支撑光滑场，展开 $(\delta g)^2$ 并逐坐标两次分部积分得到等式，再用 $2uv \leq u^2 + v^2$ 得不等式。一般 g 先乘径向截断 χ_R（$\|\nabla \chi_R\|_\infty \leq C/R$），再在紧集卷积。尾部及截断导数由 $g, Dg \in L^2$ 控制；高斯密度在紧集有正上下界，故所得紧支撑光滑场在高斯 $W^{1,2}$ 中收敛于 g。上述不等式使散度在 L^2 中收敛；对测试函数分部积分识别极限为分布散度，并将等式传至极限。外部变量先用简单函数逼近再积分。 □

B 对称张量的 Gram 矩阵界

固定整数 $m \geq 5$、$q \geq 1$。设单位行 $w_1, \ldots, w_k$ 满足 $\max_{i \neq j} |\langle w_i, w_j \rangle| \leq \delta$。对多重指标 $r \in \mathbb{N}^k$、$|r| = q$，定义

$$P_r = \operatorname{Sym} \bigotimes_j w_j^{\otimes m r_j}, \qquad Z_{r,i} = \operatorname{Sym} \bigotimes_j w_j^{\otimes (m r_j - \mathbf{1}_{j=i})}, \quad r_i > 0.$$

Sym 是全部槽位排列的平均，范数取继承的 Hilbert 张量范数。令 $\mathcal{F}$、$\mathcal{F}^-$ 分别以 P_r、$Z_{r,i}$ 为列。则

$$c I \preceq \mathcal{F}^* \mathcal{F} \preceq C I, \qquad c I \preceq (\mathcal{F}^-)^* \mathcal{F}^- \preceq C I, \tag{30}$$

只要 $\delta + \sum_{h=1}^q k^h \delta^{mh-2} = o(1)$；$c, C > 0$ 只依赖 m, q。

证明使用精确配对公式

$$\left\langle \operatorname{Sym} \bigotimes_{a=1}^R u_a, \operatorname{Sym} \bigotimes_{a=1}^R v_a \right\rangle = \frac{1}{R!} \sum_{\pi \in \mathfrak{S}_R} \prod_a \langle u_a, v_{\pi(a)} \rangle.$$

若列的标签重数为 (n_j)，对角中的无错配项为 $\prod_j n_j!/R!$，它有只依赖固定总次数的正下界；其余对角项为 $O(\delta)$。纯列的重数为 mr，删除列的重数为 $mr - e_i$。两族内部不同列具有不同重数，后者因模 m 的余数唯一确定 i。同一有限支撑内的非对角项至少含一个错配，故为 $O(\delta)$，此类列的数量有固定上界。若另一列含 $h \geq 1$ 个新标签，它至少有 $mh - 1$ 个槽必须与不同标签配对，故内积至多 $C\delta^{mh-2}$；这样的列至多 Ck^h 个。因此每个 Gram 矩阵与上述正对角矩阵之差的绝对行和至多 $C(\delta + \sum_h k^h \delta^{mh-2}) = o(1)$。对称矩阵的 Schur 界即得 (30)。

行长在固定正区间时，各列只乘有固定上下界的标量，结论不变。对按输入宽度归一化的高斯行，行长一致趋于一且 $\delta = O(\sqrt{\log d / d})$、$k \asymp d$，故扰动趋零；事件补集概率可取任意固定负幂。

C 计算树展开的张量估计

本节估计计算树展开所产生的系数张量。所有空间取实 Euclidean 空间及其 Hilbert 张量积；$\|\cdot\|_{\mathrm{HS}}$ 表示张量 Hilbert 范数，$\mathrm{Flat}_{S|S^c}$ 表示按索引位置分组的矩阵化。下文的一个模式是系数张量的一个索引位置；不同模式可以取相同数值，也可以由同一个原节点索引复制得到。各层宽度在 $[cd, Cd]$ 内，深度、多项式次数、涉及的层数和操作次数均固定。记 $\delta_d = L_d/\sqrt{d}$、$\rho_d = L_d/d$，其中 L_d 是可随有限次运算增大的固定对数幂。概率估计分别在每个网络的高斯边缘下建立；相应事件成立后，以下估计对两网络间任意耦合均成立。

C.1 系数张量的范数界与线性求和

计算树的系数张量。 从原网络的归一化读出向量开始，按原计算树自上而下展开。每个当前模式代表一个原节点的指标，模式 p 的一次展开为

$$Je_a = \bigotimes_{t=1}^{q} u_a^{(t)}, \qquad q \geq 1, \qquad \|U_t\|_{\mathrm{op}} \leq C, \quad U_t = (u_a^{(t)})_a. \tag{31}$$

因子 e_a 表示保留父索引。也可在某节点停止展开，保留该节点以下的整个张量映射。同一父索引产生的多个因子仍共享该索引。依赖两网络的映射只能作用在停止展开的叶节点上，每个映射输出一个张量因子；输出多个因子的非线性映射须先按原计算树展开并纳入系数张量。

引理 8（展开算子的范数）。 把上述展开作用于全部保留因子的复合映射称为展开算子。任意固定次数的此类复合均有界。具体地，令 $\Delta_q e_a = e_a^{\otimes q}$，则 $J = (\bigotimes_t U_t^*)\Delta_q$，而 Δ_q 为等距嵌入，故 $\|J\| \leq \prod_t \|U_t\|$。同样，若 $F_j : e_a \mapsto f_a^{(j)}$ 有界，则共享指标的乘积特征 $e_a \mapsto \bigotimes_j f_a^{(j)}$ 有界。也可从 Gram 矩阵看出：其 Gram 为 $\circ_j F_j^* F_j$，且对半正定矩阵 $X \preceq bI, Y \succeq 0$，$X \circ Y \preceq b\,\mathrm{diag}(Y)$。

引理 9（展开保持范数和切片界）。 设 E 有 r 个模式，满足

$$\|E\|_{\mathrm{HS}} \leq C, \qquad \max_{p,a} \|E(e_a \text{ 于模式} p, \cdot)\|_{\mathrm{HS}} \leq \delta_d, \qquad \|\,\mathrm{Flat}_{S|S^c} E\|_{\mathrm{op}} \leq \delta_d \quad (\varnothing \neq S \neq [r]). \tag{32}$$

除 $r = q = 1$ 外，一次展开保持这些结论，常数可增大固定倍数。

证明。 Hilbert 范数由展开算子有界立即得到。考虑新核的一个非平凡分割。若新产生的整个块在同一侧，该分割就是旧核的非平凡分割两侧复合有界算子。若新块跨越两侧，在两侧暂时保留正交父指标 a。中央算子按 a 分块对角，每块为旧切片 $E(e_a, \cdot)$ 的某个矩阵化，算子范数至多其 Hilbert 范数 δ_d。再施加两侧的行映射即得结论，包含旧核只有一个模式的情形。

除 $r = q = 1$ 外，新张量至少有两个索引；其坐标切片满足 $\|E_{\mathrm{new}}(e_a \text{ 于} p, \cdot)\|_{\mathrm{HS}} \leq \|\,\mathrm{Flat}_{\{p\}|\{p\}^c} E_{\mathrm{new}}\|_{\mathrm{op}} \leq C\delta_d$，故已由刚证明的矩阵化界控制。$r = q = 1$ 时没有非平凡矩阵化，仍须另用高斯连续乘积的坐标估计。□

线性路径上的高斯矩阵乘积。 令 A_ℓ 为独立、按输入宽度平方根归一化的高斯矩阵。任意固定连续积 $P = A_b \cdots A_a$ 满足

$$\|P\|_{\mathrm{op}} \leq C, \qquad \max_{ij} |P_{ij}| \leq C_M \sqrt{\log d / d} \tag{33}$$

且可使失败概率为 $O(d^{-M})$。算子范数由各层相乘得到；条件于 $Q = A_{b-1} \cdots A_a$ 后，$(A_b Q)_{ij}$ 是方差 $\|Qe_j\|^2/n_{b-1} \leq C/d$ 的高斯变量，尾界与有限并合即得第二式。读出向量乘连续高斯积的坐标最大值也由条件于最后尚未暴露的高斯因子得到相同估计。于是首次分叉以前的 $r = q = 1$ 链可单独处理；首次分叉以后模式数不减，前一引理处理所有后续步骤。停止展开或施加恒等映射无须概率估计。有限原树核全部满足 (32)。这里的一元链仅由原网络矩阵组成。

外部映射及重建。 对系数张量的每个索引施加有界、输出一个因子的映射，保持所有非平凡矩阵化界，但不必保持坐标切片界。完成一次收缩后，应从原计算树重新构造系数张量：在对应父节点处停止展开，将已算出的跨网络收缩矩阵作为该叶节点的外部映射。不同深度均可停止展开，但根到叶的内部路径仍只含原网络矩阵。以下坐标切片估计始终用于这样重建的原系数张量。

引理 10（线性路径的精确求和）。 令底层行向量为 b_j，父层矩阵为 $U=(u_{aj})$，并设 $z_a=\sum_j u_{aj}b_j$。一个父节点有 t 个线性子槽以及次数 $q_1,\dots,q_h\ge 2$ 的非线性子槽，则其未对称化张量严格等于

$$z_a^{\otimes t}\otimes\bigotimes_{\ell=1}^{h}\left(\sum_j u_{aj}b_j^{\otimes q_\ell}\right). \tag{34}$$

*证明。*给每个有序子槽分配独立求和指标，再逐个使用多线性性；线性槽的求和正好是 z_a，非线性槽保留原式。固定次数的对称化为槽排列的平均，可在求和后施加。纯一元链因此是归一化矩阵的普通乘法，无额外 $\sqrt{\text{宽度}}$ 因子。式中的所有非线性因子仍共享 a，不得替换为独立阵列。坐标掩码一般不与此求和交换；必须先在全部张量因子的展开算子中证明掩码删除的误差为 $o(1)$，再恢复原张量并用本等式。 □

C.2 同层索引的旋转与双索引收缩

概率工具。 若确定性矩阵 $A_j:\mathbb{R}^u\to\mathbb{R}^v$ 满足 $\max\{\|\sum_j A_jA_j^*\|,\|\sum_j A_j^*A_j\|\}\le s^2$，则独立标准高斯系数满足

$$\mathbb{P}\left(\left\|\sum_j g_jA_j\right\|>t\right)\le 2(u+v)\exp[-t^2/(2s^2)].$$

这是有限维矩阵高斯级数界。其自伴膨胀为 $H_j=\left(\begin{smallmatrix}0 & A_j^*\\ A_j & 0\end{smallmatrix}\right)$，$\|\sum_j H_j^2\|\le s^2$；矩阵高斯 Laplace 界 $\mathbb{E}\,\mathrm{tr}\exp(\lambda_{\mathrm{c}}\sum_j g_jH_j)\le \mathrm{tr}\exp(\lambda_{\mathrm{c}}^2\sum_j H_j^2/2)$ 配合 $\lambda_{\mathrm{c}}=t/s^2$ 得到上尾，对负号重复即得双侧界。以下只用其维数为固定 d 次幂时的 $O(s\sqrt{\log d})$ 结论。

引理 11（同层旋转下的坐标切片）。 在同一原网络层，同时展开所有尚未停止的模式。选择当前高斯层矩阵的列索引所对应的模式 p：它随该层矩阵右乘正交矩阵而旋转，不包括保留的父索引 e_a 或其确定性复制。再选不同模式 q；总模式数为 $N\ge 3$。令 E 为尚未施加外部映射的系数张量。以任意高多项式概率有

$$\max_j\ \sup_{\|v\|\le 1}\|E(e_j\ \text{于}p,v\ \text{于}q,\cdot)\|_{\mathrm{HS}}\le\rho_d. \tag{35}$$

此时尚未展开更低层；在较高层停止展开的索引保持不动。

*证明。*条件于一个满足 (32) 的核，置 $A_jv=E(e_j,v,\cdot)$。直接按矩阵元素求和可知

$$\left\|\sum_j A_j^*A_j\right\|=\|\,\mathrm{Flat}_{\{q\}|\{q\}^c}E\|^2\le\delta_d^2,\qquad \left\|\sum_j A_jA_j^*\right\|=\|\,\mathrm{Flat}_{\{p,q\}|\{p,q\}^c}E\|^2\le\delta_d^2.$$

第二分割非平凡恰好使用 $N\ge 3$。前述级数界、$\|g\|\ge c\sqrt{d}$ 的高斯尾界，给均匀球面向量 $u=g/\|g\|$ 的收缩范数至多 $C_M\delta_d\sqrt{\log d/d}$。对独立 Haar 矩阵的各列作并合，不要求列独立。将当前高斯层矩阵右乘该正交矩阵不改变分布，并同时旋转对应其列索引的全部模式。未固定模式上的旋转是等距算子；若 q 也对应该层的列索引，对 v 的上确界仍不变。故 Haar 后的估计转回原坐标即为所需式。所有核和模式只有固定有限种。□

推论 12（重复坐标项的范数）。 若至少两个模式对应同一高斯层矩阵的列索引，且总模式数至少三，则其中至少两个索引取相同值的部分满足

$$\|E_{\mathrm{coll}}\|_{\mathrm{HS}}^2\le\sum_{p<q}\sum_j\|E(e_j\ \text{于}p,e_j\ \text{于}q,\cdot)\|^2\le Cd\rho_d^2=o(1). \tag{36}$$

在该层引入这些模式时先估计这一部分，再将误差通过有界的展开算子传递，最终误差仍为 $o(1)$。这里只删除不同原节点的索引恰取相同值的项；同一父索引的确定性复制仍须保留。

推论 13（原始系数的矩与坐标界）。 设 C_R 为固定深度、固定次数、零常数高斯多项式网络的原始 R 阶系数，允许保留有序因子、对称化及固定有限个展开项的和。对每个固定 $0 < p < \infty$，$\sup_d \mathbb{E}\|C_R\|_{\mathrm{HS}}^p < \infty$。若全部索引由同一原高斯层的列索引产生（不含父索引的确定性复制），宽度为 $k \asymp d$，则对任意固定 M，以失败概率 $O(d^{-M})$ 同时有

$$\max_{i_1,\dots,i_R \text{ 互异}} |(C_R)_{i_1\cdots i_R}| \le L_d k^{-R/2}, \qquad \|\operatorname{Coll}_R C_R\|_{\mathrm{HS}}^2 \le L_d/d \quad (R \ge 3), \tag{37}$$

其中 L_d 为固定对数幂；$R \ge 3$ 时还有 $\mathbb{E}\|\operatorname{Coll}_R C_R\|_{\mathrm{HS}}^2 = o(1)$。为证矩界，将原展开算子的范数相乘，再用归一化高斯矩阵算子范数的固定阶矩和 Hölder 不等式，不需乘积中各因子独立。列置换不变性使互异坐标的二阶矩相同，故每个至多 $C/(k)_R = O(k^{-R})$。每个坐标是固定次数 D_0 的高斯多项式，$\|Z\|_u \le (u-1)^{D_0/2}\|Z\|_2$；取 $u = C_M \log d$，在 $e\|Z\|_u$ 处用 Markov 并对至多 k^R 个坐标作并集界，即得第一界。第二界由同层旋转引理 11及式 (36)应用于每个有序展开项得到；固定有限个排列与展开项的和不改变阶数。矩界及 Cauchy–Schwarz 给 $\mathbb{E}\|\operatorname{Coll}_R C_R\|^2 \le L_d/d + (\mathbb{E}\|C_R\|^4)^{1/2} O(d^{-M/2}) = o(1)$。这里只控制原始系数，尚未施加依赖两个网络的外部映射。

引理 14（两个父索引的收缩与二阶非对角项）。 在一个未加掩码的原始切口中，设不同父模式 p, q 的所选线性槽与教师行收缩后给出 η_i, ζ_i，其 ℓ^2 范数有界。模式 p 是本层引入的模式，且删去所选槽后仍有非空残余；所有完整残余家族均为有界算子。若总模式数 $R \ge 3$，完整剩余源张量 S_i 满足 $\|S_i\|_{\mathrm{HS}} \le C\rho_d$。事实上，令 $B_i e_b = \zeta_{ib} f_b$，其中 f_b 是第二个源索引删除所选槽后的完整剩余特征；无剩余槽时取 $f_b = 1$。逐点有 $\|B_i\|_{\mathrm{HS}}^2 = \sum_b |\zeta_{ib}|^2 \|f_b\|^2 \le C$。将原始切片 $E(e_a, \cdot)$ 看作从 q 索引到其余索引的算子 T_a。式 (35)给 $\|T_a\|_{\mathrm{op}} \le \rho_d$，故 $\|T_a B_i^*\|_{\mathrm{HS}} \le C\rho_d$。保留第一个索引 a，乘 η_{ia} 后平方求和，再施加完整剩余特征，即得所需界。这些估计逐点成立，不要求 B_i 与网络独立。

若 $R = 2$、两个索引属于同一原网络层，且删除所选槽后两个模式均有非空残余，式 (37)给 $\max_{a \ne b} |D_{ab}| \le L_d/d$；保留两标签后施加完整特征映射，非对角部分满足

$$\|S_i^{\mathrm{off}}\| \le C\Big(\sum_{a \ne b} |D_{ab}\eta_{ia}\zeta_{ib}|^2\Big)^{1/2} \le C L_d/d.$$

两种界与教师切片和 $C\sqrt{d}\|C\|$ 配对均为 $o(1)\|C\|$。该二阶结论不控制对角或坐标–向量切片；不同层的两个索引亦不适用，须保留根索引另行处理。同一父索引的确定性复制不是两个不同父节点，不能使用本估计。

C.3 保留剩余因子的局部收缩估计

引理 15 (残余家族与局部收缩)**.** *设 $F_a = \sum_b U_{ab} Q_b$，U 为原高斯层或连续积，Q_b 为正次数原计算树；停止叶允许有界自适应单槽映射。完整家族 $e_a \mapsto F_a$ 有界，且当 F_a 至少有两个输出因子时，每个非平凡输出矩阵化均至多 $C\delta_d$。同指标乘积家族也有界。*

固定一个有 $m \ge 2$ 个因子的教师节点。设它接触源父索引 a 的一个旧收缩因子 ℓ_a，该源列除 ℓ_a 外至少还有一个完整因子，且 $G_{ia} = \langle a_i, \ell_a \rangle$ 满足 $\|G\|_{\max} \le \kappa_d$、$\sup_i \|G_{i,:}\|_2 \le C$。所有其他完整残余均保留，其他源父标签的映射不依赖 a。教师、源原系数分别为 C, D。则完整配对满足：

$$|\text{pairing}| \le \begin{cases} C\kappa_d \|C\|\|D\|, & \text{本叶还接触另一源父节点,} \\ C\sqrt{d}\,\alpha(D)(\delta_d + \kappa_d)\|C\|, & \text{本叶全在父节点 } a, \end{cases} \tag{38}$$

第二行中，多模核取 $\alpha(D) = \|\operatorname{Flat}_{a|\mathrm{rest}} D\|$；一模核 $D = d$ 取 $\alpha(D) = \|d\|_\infty$，但要求除 ℓ_a 外至少有两个完整因子。因此 $\alpha(D), \delta_d, \kappa_d \le L_d/\sqrt{d}$ 时两类配对均为 $o(1)$。

证明. 残余家族是原展开算子与 U^* 的复合。对固定 a，以 $U_{a,:}$ 为读出重建核；式 (33) 和引理 9 给各非平凡矩阵化界，外部单槽映射保持它们。乘积家族由对角等距嵌入保持有界。

若还接触另一父节点，先将来自其他父节点的全部 $t \ge 1$ 个槽映到正交教师标签 i。该映射的伴随为 $(A^*)^{\otimes t}\Delta_t$，故有界。保留 a, i 后乘 G_{ia} 的算子范数为 $\|G\|_{\max}$；再在每个 i 块内提升本列的剩余家族并完成其余配对。至少一个其他完整因子保证该家族有界；即使它被本叶完全收缩，也留下 ℓ^2 有界的标量家族，而非无权删除标签。全部为完整张量上的有界算子，无部分迹或逐 i 求和损失。

以下本叶全在 a。固定 i，其余因子收缩后形成家族 H_j：完全收缩者是 ℓ^2 有界向量；部分收缩者的列范数至多 $C\delta_d$；完全保留者仍为有界家族。因为本叶还有 $m-1\ge 1$ 个槽，或者存在部分收缩者，或者至少一个因子完全收缩。令 $B_i e_a = G_{ia}\bigotimes_j H_j e_a$。前一情形用 $\|G_{i,:}\|_2$，后一情形用 $\|G\|_{\max}$ 及完全收缩向量的 ℓ^2 范数，均得 $\|B_i\|_{\mathrm{HS}}\le C(\delta_d+\kappa_d)$。多模情形把其余模式展开记为 T，于是 $\|(B_i\otimes T)D\|_{\mathrm{HS}}\le C\alpha(D)(\delta_d+\kappa_d)$。

一模情形至少有两个 H_j。若有部分收缩者 H_u，取 $j\neq u$，利用 $H_j^*H_j\preceq CI$ 和 $\mathrm{diag}(H_u^*H_u)\preceq C\delta_d^2 I$，Schur 乘积序给乘积家族算子范数至多 $C\delta_d$；作用于 $(d_aG_{ia})_a$ 即得 $C\|d\|_\infty\delta_d$。否则移入一个完全收缩向量 η，$\|(d_aG_{ia}\eta_a)_a\|_2\le C\|d\|_\infty\kappa_d$，其余至少一个家族仍有界。最后仅用一次 $\sum_i\|C(e_i,\cdot)\|\le C\sqrt{d}\|C\|$，即得第二行。 □

二阶非对角核可写成 $D-\mathrm{diag}\,D$ 分别应用此界；对角核的算子范数和 Hilbert 范数均不增。此论证不适用于其他掩码，也未声称二阶对角为小量。一模且仅有一个其他因子的边界使用引理 17 中的保留索引子程序。

D 实际激活的输入混沌投影与多项式近似

固定 $N>2$，记 $A_\ell=W^{(\ell)}/\sqrt{k_{\ell-1}}$、$u=c_0=\sqrt{2/\pi}$，并置

$$P_N(z)=\sum_{j=1}^{N}\frac{a_j z^j}{\sqrt{j!}},\qquad Q_N(z)=\sum_{j=1}^{N}\frac{b_j z^j}{\sqrt{j!}},\qquad b_j=\mathbb{E}[(\sigma(G)^2-1)\psi_j(G)]. \tag{39}$$

Q_N 只用于分段线性分支。对使用原矩阵 $A_1,\dots,A_t$、读出 $k_t^{-1/2}\mathbf{1}$、输出激活 A 及下层激活 $p_1,\dots,p_{t-1}$ 的多项式网络，先取形式 N 次对称系数、再施加 I_N，记为 $R_{t,N}[A;p]$；只保留每个隐藏层全部索引互异的展开项所得函数记为 $J_{t,N}[A;p]$。输入坐标不受限制，故 $J_{1,N}=R_{1,N}$；$;P_N$ 表示所有下层均用 P_N。这些定义允许固定辅助变量取系数。形式取系数在 I_N 之前，不包括更高形式次数经高斯收缩得到的第 N 阶项。

D.1 条件展开及其误差

本节所有 L^p 均对原高斯先验及输入。引理 3 和第 A 节的矩阵尾界给出

$$\|q_\ell-1\|_p=O(d^{-1/2}),\qquad \sup_d\mathbb{E}\left[\|A_\ell\|_{\mathrm{op}}^p+|h_i^{(\ell)}|^p\right]<\infty. \tag{40}$$

固定乘积也有全部固定阶矩，允许重复索引；$q_\ell\notin[1/2,2]$ 的概率因此可取任意多项式衰减。首层行写为 $A_{1,i:}=s_iv_i$，$\|v_i\|=1$。高斯长度和内积尾界及矩阵尾界给出概率至少 $1-d^{-M}$ 的事件

$$\max_i|s_i-1|+\max_{i\neq j}|\langle v_i,v_j\rangle|\le C_M\sqrt{\log d/d},\qquad \|A_1\|_{\mathrm{op}}\le C_M. \tag{41}$$

首层有限乘积。 若固定 t 个单位向量的 Gram 矩阵 G 满足 $\|G-I\|\le\eta$，且 $\max_i|s_i-1|\le\delta$，则

$$\left\|\Pi_N\prod_{i=1}^{t}\sigma(s_iv_i\cdot X)-\sum_{\substack{n_i\ge1\\ \sum_i n_i=N}}\frac{\prod_i a_{n_i}}{\sqrt{\prod_i n_i!}}I_N\left(\mathrm{Sym}\bigotimes_i(s_iv_i)^{\otimes n_i}\right)\right\|_2\le C_{t,N}(\eta+\delta). \tag{42}$$

为证明它，在 $\mathrm{Sym}^N\,\mathrm{span}\{v_i\}$ 中取 $B_n=I_N(\mathrm{Sym}\bigotimes_i v_i^{\otimes n_i})$，$n_i\ge0$、$\sum n_i=N$。其 Gram 矩阵是 G 的多项式，在 $G=I$ 附近一致可逆；投影坐标等于该矩阵的逆乘 $\mathbb{E}[\prod_i\sigma(s_iZ_i)B_n(Z;G)]$，$Z\sim N(0,G)$。对高斯密度按协方差求导，导数由可积的多项式乘高斯密度控制；B_n 的系数多项式依赖于 G，激活至多线性增长且 Lipschitz，故上述有限个积分关于 (G,s) 局部 Lipschitz。在 $(I,\mathbf{1})$ 处，独立性给系数 $\prod_i a_{n_i}/\sqrt{\prod_i n_i!}$，$a_0=0$ 删除零次数。再把 v_i 改为 s_iv_i 即得上式，包含完整非多项式乘积的一切收缩项。特别地 $t>N$ 时近似和为空。

逐层条件展开。令 $\chi=\sigma^2-1$，$f=\sigma$，或在分段线性支取 $f=\chi$。给定前层特征 $h\in\mathbb{R}^k$，置 $q=\|h\|^2/k$、$c_r^f(q)=\mathbb{E}f(\sqrt{q}G)\psi_r(G)$。条件 Hermite 展开使用

$$f(W_i\cdot h/\sqrt{k})=\sum_{r\ge0}c_r^f(q)\sum_{|\alpha|=r}\sqrt{\frac{r!}{\alpha!}}(h/\|h\|)^\alpha\prod_j\psi_{\alpha_j}(W_{ij}). \tag{43}$$

$q=0$ 按实际随机变量的连续值解释。由于 $|f(x)|\le C(1+x^2)$，$q\mapsto f(\sqrt{q}\,\cdot)$ 为 $[1/2,2]$ 到 $L^2(\gamma)$ 的连续映射，其 Hermite 尾一致趋零。区间外用完整条件二阶矩 $C(1+q^2)$、式 (40) 及任意高阶小概率控制。对固定多个不同行输出，条件独立性使逐因子差的条件平方期望等于一个尾的平方期望乘其余因子的二阶矩；故乘积也可截断，无须单行尾的高阶收敛。

固定 r 后，换元 $y=\sqrt{q}G$ 并对密度及 $\psi_r(y/\sqrt{q})$ 求导，可知 $c_r^f(q)q^{-r/2}$ 在 $[1/2,2]$ 上 Lipschitz，故可替换为 $c_r^f(1)$，误差趋零。区间外，精确有限分量的固定阶条件矩由 $c_r^f(q)$ 的增长及高斯 Hermite 矩界控制，替换后的多项式由特征矩控制；Hölder 与小概率界再次给 $o(1)$。这里不使用负阶 q 矩，也不对 f 求导。

若固定展开含 T 个前层输出因子，重复索引赋值至多 C_Tk^{T-1} 个，而平方归一化因子为 k^{-T}。先合并给出相同权重 Hermite 单项式的排序（重数只依赖 T），由正交性及固定乘积矩，删去这些赋值的平方误差为 $O_T(k^{-1})$。剩余权重变量均只出现一次，Hermite 单项式成为普通权重乘积。隐藏层零阶系数为零（奇支）或 $bu(\sqrt{q}-1)=O_{L^p}(d^{-1/2})$（分段线性支），也可在固定乘积中删去；输出层零阶项稍后单独保留。

这些局部误差经整个读出求和仍趋零。事实上，在任一阶段先合并相同的上方权重单项式，写

$$\Delta=\sum_g\beta_g\Psi_g(W_{>\ell})E_g(W_{\le\ell},X),\quad \sum_g\beta_g^2\le C_{\text{fixed}},\quad \mathbb{E}\|\Delta\|_{L^2_X}^2\le C_{\text{fixed}}\sup_g\mathbb{E}\|E_g\|_{L^2_X}^2. \tag{44}$$

这里不同 Ψ_g 正交、每个变量次数为一，且独立于下层；其系数平方和有界，是因为读出 $k_t^{-1/2}$ 与每条边的输入宽度 $-1/2$ 次幂，平方后恰好抵消输出及各自由索引的数目，合并重数只依赖固定展开结构。从输出层向下依次取有限截断，使总 L^2 尾任意小，再用 (42) 处理互异的首层激活因子。式 (41) 与上述平方和界使首层误差趋零；坏事件上固定乘积和固定次数多项式矩至多有固定多项式维数增长，可由任意高阶失败概率吸收。若某节点次数超过 N，其不同子树至少给出超过 N 个互异首层因子，投影近似为空。故各层截断达到 N 后所得表达式稳定；先令 $d\to\infty$、再令截断误差趋零，得到

$$\Pi_NF_{t,+}^f=J_{t,N}[H_f;P_N]+o_{L^2}(1),\qquad H_\sigma=P_N,\quad H_\chi=Q_N. \tag{45}$$

其中 $F_t^f=k_t^{-1/2}\sum_i f((A_th^{(t-1)})_i)$，$F_{t,+}^f$ 是减去给定前层的条件均值后所得函数。$t=1$ 时直接展开每行：$\mathbb{E}f(sG)\psi_N(G)$ 关于 $s\in[1/2,2]$ Lipschitz，故可换成 $s^N\mathbb{E}f(G)\psi_N(G)$。首层向量映射 $e_i\mapsto v_i^{\otimes N}$ 有界，因为其 Gram 绝对行和至多 $\sum_j|\langle v_i,v_j\rangle|^2\le\|V\|_{\text{op}}^2$。读出范数为一，逐行 $O(\max_i|s_i-1|)$ 的系数误差因此给总 $o(1)$，坏事件同上。

D.2 二次对角与索引恢复

对完整上部多项式，$r\ge3$ 的重复坐标由推论 13 控制；该结论不能直接用于受索引限制的 J。二次项满足如下补充公式：输入宽度为 k、深度为 t、各层激活 $p_j(z)=\sum_{r\ge1}g_{j,r}z^r$ 时，

$$\mathbb{E}\|\operatorname{Diag}D_2-\lambda I_k/\sqrt{k}\|_{\text{HS}}^2=O(k^{-1}),\qquad \lambda=g_{t,2}\prod_{j<t}g_{j,1}^2\sqrt{k_t/k}. \tag{46}$$

正次网络二次项恰有一个二次节点；节点位于第 j 层时，去掉固定标量后为 $D_2^{(j)}=B_j^T\operatorname{diag}(v_j)B_j$，其中 $B_j=A_j\cdots A_1=C_jA_1$，$v_j=A_{j+1}^T\cdots A_t^T\mathbf{1}/\sqrt{k_t}$。令 $H_j=C_j^T\operatorname{diag}(v_j)C_j$。条件于 H_j，A_1 各列独立，故

$$\mathbb{E}((D_2^{(j)})_{ii}\mid H_j)=\operatorname{tr}H_j/k,\qquad \mathbb{E}\sum_i|(D_2^{(j)})_{ii}-\operatorname{tr}H_j/k|^2=2\mathbb{E}\|H_j\|_{\text{HS}}^2/k=O(k^{-1}).$$

末步用 $\|H_j\|_{\text{HS}}\le\|C_j\|_{\text{op}}^2\|v_j\|$。$j<t$ 时 v_j 独立于 C_j，均值零、协方差 I/k_j，所以 $\mathbb{E}|\operatorname{tr}H_j|^2=k_j^{-1}\mathbb{E}\sum_a\|C_{j,a:}\|^4=O(1)$。$j=t$ 时 $\operatorname{tr}H_t=\|C_t\|_F^2/\sqrt{k_t}$，均值为 $\sqrt{k_t}$，且方差为 $O(k_t^{-1})$：对独立下一层 A，

$$\mathbb{E}(\|AC\|_F^2\mid C)=\frac{k_{\text{new}}}{k_{\text{old}}}\|C\|_F^2,\qquad \operatorname{Var}(\|AC\|_F^2\mid C)=\frac{2k_{\text{new}}}{k_{\text{old}}^2}\|CC^T\|_{\text{HS}}^2=O_{L^1}(1),$$

由全方差公式沿固定长度乘积归纳即得 $\operatorname{Var}\|C_t\|_F^2=O(1)$。乘回标量证明(46)，亦适用于辅助变量取系数。

引理 16 (去掉索引互异限制)**.** 对固定零常数多项式 $A, p_1, \dots, p_{t-1}$，$t \ge 2$，以 $[p]_r$ 表示 z^r 系数，有

$$J_{t,N}[A; p] = R_{t,N}[A; p] - [A]_2 \sqrt{k_t/k_{t-1}}\, R_{t-1,N}[p_{t-1}^2; p_{<t-1}] + o_{L^2}(1). \tag{47}$$

证明. 令 $\gamma = [A]_2\sqrt{k_t/k_{t-1}}$。在取形式系数前，从完整网络减去 $\gamma k_{t-1}^{-1/2}\sum_i y_i y_i$，其中 y 为第 $t-1$ 层输出；两个因子保留各自的父索引，虽数值相等仍视为两个槽。由下向上依次施加第 $s = 1, \dots, t-1$ 层的互异限制。此时上方仍是完整多项式。$s < t-1$ 时可将减项的上部识别为根激活 p_{t-1}^2 的浅网络；两项的确定二次对角标量分别为

$$[A]_2 \prod_{j=s+1}^{t-1} [p_j]_1^2 \sqrt{k_t/k_s} = \gamma [p_{t-1}^2]_2 \prod_{j=s+1}^{t-2} [p_j]_1^2 \sqrt{k_{t-1}/k_s},$$

其中用了 $[p^2]_2 = [p]_1^2$。$s = t-1$ 时减项就是原上部系数的确定二次对角。两项在代入共同下层之前相消；二次余项由(46)、更高次重复坐标由原始碰撞估计给 $o_{L^2}(1)$，一次没有重复坐标。共同下层映射由固定多个原展开映射、坐标投影和对称化组成，其范数由有限个 $\|A_j\|_{\mathrm{op}}$ 的固定次幂控制；已施加的全局坐标限制是收缩，无须分解为逐槽映射。固定次数高斯多项式的矩等价将系数误差提升为 L^4 小量，再用 Hölder 与(8) 得到每步函数误差 $o_{L^2}(1)$，不需独立性。最后的第 $t-1$ 层限制删掉减项的两个相等父标签，原项成为 J，即得结论。 □

D.3 条件均值递推与全部浅层修正

分段线性支对 $f = \sigma, \chi$ 有精确公式

$$\mathbb{E} f(\sqrt{q}G) = \lambda_f (q-1) + c_f(\sqrt{q}-1)^2, \quad (\lambda_\sigma, c_\sigma) = (bu/2, -bu/2), \quad (\lambda_\chi, c_\chi) = (1, b^2u^2). \tag{48}$$

由 $|\sqrt{q}-1| \le |q-1|$ 和引理 3，乘读出因子 $\sqrt{k_t}$ 后的二次余项仍为 $O_{L^2}(d^{-1/2})$。$t \ge 2$ 时线性项等于 $\lambda_f\sqrt{k_t/k_{t-1}}F_{t-1}^{\chi}$；$t = 1$ 时为 $\lambda_f\sqrt{k_1}(q_0 - 1)$，被 $N > 2$ 投影精确消去。高斯密度按方差求导还给 $[H_f]_2 = \frac{1}{2}\mathbb{E}[f(G)(G^2-1)] = \lambda_f$。结合(45) 与引理 16，直接得到

$$\Pi_N F_t^f = R_{t,N}[H_f; P_N] + \lambda_f\sqrt{k_t/k_{t-1}}\big(\Pi_N F_{t-1}^{\chi} - R_{t-1,N}[P_N^2; P_N]\big) + o_{L^2}(1), \quad t \ge 2, \tag{49}$$

初值为 $\Pi_N F_1^f = R_{1,N}[H_f] + o_{L^2}(1)$。置 $U_N = [Q_N - P_N^2]_{\deg \le N}$、$E_t = \Pi_N F_t^{\chi} - R_{t,N}[P_N^2; P_N]$，则 $E_1 = R_{1,N}[U_N] + o_{L^2}(1)$ 且 $E_t = R_{t,N}[U_N; P_N] + \sqrt{k_t/k_{t-1}}E_{t-1} + o_{L^2}(1)$。固定深度归纳及 $f = \sigma$ 的递推遂给

$$\mathcal{Q}_N = R_{L,N}[P_N; P_N] + \mu' \sum_{t=1}^{L-1} \sqrt{k_L/k_t}\, R_{t,N}[U_N; P_N], \qquad \mu' = bu/2, \tag{50}$$

$$\boxed{\mathbb{E}_W \|\Pi_N F_L - \mathcal{Q}_N\|_{L^2_X}^2 \longrightarrow 0, \qquad N > 2.} \tag{51}$$

奇支各条件均值及二次系数均为零，同样证明给出 $\mu' = 0$，无需 χ。所有多项式零常数，逐层代入不降低形式次数，故超过 N 次的项均可删去。以下比较深层项和式 (50) 中全部浅层修正；单网络 L^2 误差将用 Cauchy–Schwarz 转移到任意先验边缘耦合。

E 计算树展开项的逐层比较

固定 L、$N = m^L$；奇激活取奇数 $m \ge 5$，分段线性激活取偶数 $m \ge 6$。令 $\delta_d, \kappa_d \le K_d/\sqrt{d}$，$K_d$ 是可随有限次运算增大的固定对数幂。每个节点选一个正次单项式并将孩子排序，得到有序展开项；先固定其 N 个输入因子与齐次教师项的槽配对，最后对有限种选择和至多 $N!$ 个排列求和。教师、源各自的原高斯事件先固定，跨网络映射随后可任意依赖两网络。

引理 17 (有序树消元)**.** 高度 $t < L$、根为任意零常数多项式 A、下层为 P 的每个有序 N 次展开项，与高度 L 的齐次教师项的每种固定槽配对均为 $o(1)$。高度 L 的普通 P 展开项中，除每个节点次数均为 m 的项外，结论相同。

证明. 对源高度 t 作强归纳；固定 t 时按教师高度处理尚未完成的节点。已完成高度 $h-1$ 的收缩作为第 h 步的一个因子，刚完成的输出留到下一步才使用。所有这些跨网络收缩放在源侧；教师始终保留原始齐次系数 C。固定当前教师行 i 后，其余完整教师因子的范数至多 $K_d\|C(e_i,\cdot)\|$，故

$$\sum_i \|C(e_i,\cdot)\| \le \sqrt{k}\|C\| \le K_d\sqrt{d}. \tag{52}$$

每次在源原树的停止节点重建系数核，再施加有界完整特征映射；不同高度的输出分别保留标签。同一父索引的复制也保留，绝不当作独立高斯列索引或可删除的碰撞。纯一元链先用引理 10 精确求和，所有收缩均作用于恢复后的无掩码项。

完整收缩与保留索引子程序。 一次合法完整收缩使用同一源节点的 m 个完整线性孩子，其矩阵 $M_{ia}=\prod_{j=1}^{m}\rho_{ia}^{(j)}$ 满足

$$\sup_i \sum_a |M_{ia}| + \sup_a \sum_i |M_{ia}| \le K_d, \qquad \|AM\|_{\max} \le K_d\kappa_d, \tag{53}$$

其中各 $\rho^{(j)}$ 的行列 ℓ^2 范数有界，A 为下一教师原高斯矩阵。前式由 Hölder 得到，后式只用 $\|A\|_{\max}\le\kappa_d$，不要求 M 独立于 A。完整孩子条件本身尚不保证高度增长：同一原节点可先产生多个旧输出。以下每次复用旧输出前，先排除其来源节点仍有其他因子的项；通过此过滤后，父收缩才严格位于已完成孩子之上。因此高度 h 的教师子树在每条源路径上至少占用 h 个原节点。

二模式的特殊状态写成

$$\sum_{a,b} E_{ab}\ell_a \otimes Q_b, \qquad \|E\|_{\mathrm{HS}} \le K_d, \quad \|E\|_{\mathrm{op}} \le \delta_d. \tag{54}$$

ℓ 是一个完整当前因子，Q 为原始高度至多 $L-1$ 的完整子树；E 是原二阶停止核或沿原一元链传播的核，故满足引理 9。所有尚未收缩因子和下一步输出都包含在此式中。保留 a，暂缓从 ℓ 到教师根的整条路径，按高度处理路径之外的教师子树。每次先检查旧输出复用，再推进选中路径；旧 G 只来自已认证完整的较低教师高度步骤。此时选一个 Q 后代就有至少两个模式，选两个不同后代就有至少三个模式。因此旧收缩因子仍带残余时，式 (38) 的混合父界或多模界适用；两个不同源父节点相遇时，引理 14 的 $R\ge 3$ 界适用。混合父旧输出的完整配对直接为 $O(K_d\kappa_d)=o(1)$；同父旧输出与双父切片情形，固定教师行后的完整余张量分别至多 $K_d\delta_d(\delta_d+\kappa_d)$ 和 K_d/d，由(52) 均为 $o(1)$。在余下项中，将选中路径推进到最低的非单因子节点；若它们来自同一非线性孩子，就应更早停止，故每步只能完整使用该节点的 m 个线性孩子。每完成一次收缩，已完成教师节点数增加；其间线性路径游标只沿有限原树向上移动。旧输出的上述过滤保证每次父收缩严格高于孩子，故高度计数适用于 Q。此子程序既不调用本引理的结论，也不再次调用二模式子程序。

根部其余 $m-1$ 个教师孩子高度均为 $L-1$。若 Q 更浅，消元不能完成；若其高度恰为 $L-1$，这 $m-1$ 次收缩只能在 Q 原根 b 处完成。记矩阵为 $M^{(j)}$，$G^{(j)}=AM^{(j)}$；每个 $G^{(j)}$ 的列 ℓ^2 范数有界，最大条目至多 $K_d\kappa_d$。保留整条暂缓路径及所有残余，去掉这 $m-1$ 个已知因子后有

$$R_b=\sum_a E_{ab}\ell_a\otimes Q_b^{\mathrm{res}}, \qquad \sum_b \|R_b\| \le K_d\sqrt{d}\|E\|_{\mathrm{HS}}.$$

固定最终教师行时其完整路径范数有界。结合归一化读出的 $O(d^{-1/2})$ 最大值，对两个 G 用列 ℓ^2 界、其余 $m-3$ 个用条目界，整个配对至多

$$K_d\|E\|_{\mathrm{HS}}\kappa_d^{m-3}=o(1). \tag{55}$$

这里同时使用全部 $m-1$ 个因子，未将一个小标量核单独乘任意余张量。

消元顺序与全部边界。 首先排除旧收缩因子再次使用时仍带其他因子的项。当前教师节点若还接触另一源父节点，使用(38) 第一行；否则原核为多模，或一模但另有至少两个因子时，使用第二行。一模且没有其他因子时允许继续。仅有一个其他因子时，若它也是旧收缩因子，本列只有两个当前位置，不能容纳 $m\ge 5$ 个槽，已属第一种情况。若它是原始完整孩子，正次数及其他输出标签的保留迫使上方只有原一元链；故

系数 d 满足 $\|d\|_2 \le K_d$、$\|d\|_\infty \le \kappa_d$。展开该孩子第一条边，得到(54)，其中 $E_{ab} = d_a U_{ab}$、Q 高度至多 $t-1 \le L-1$，由保留索引子程序排除。因此以后复用的收缩因子均已包含其来源节点的全部因子。

然后沿当前教师节点所选的 m 条源路径向上推进；一元节点精确求和，在最低的非单因子节点停止，较高路径暂缓，较低路径推进至同高或其更低分支。选中最低父节点的当前层列索引随该层右旋转，且删除选中槽后仍有残余。若选中因子涉及不同父节点，原核有至少三个模式时用双父引理的 $R \ge 3$ 情形。二模式中若一父为单因子、另一父有残余，使用保留索引子程序。若两父都有残余，则两者同属当前原高斯层：较高层的旧收缩因子已不带其他因子，而暂不处理的较高输出另保留标签，会使模式数至少三。因此二阶非对角项适用双父引理，其两边非空残余条件同时满足。

二阶对角由式 (46) 化为 $\lambda_s I/\sqrt{k_s}$ 加 $o_{L^2}(1)$ 的 Hilbert–Schmidt 误差；误差通过完整有界特征映射传递。主项将两个原父标签识别，将根单项式相乘，保持全部有序孩子与原教师槽分配，成为高度 $s < t$、读出 $1/\sqrt{k_s}$ 的前缀项。根次数可有任意奇偶性，故由加强的源高度归纳控制；已有收缩展开回原始等式后也无残缺子树。$s = 0$ 时只有输入次数二，不贡献 $N > 2$。不同层的二模式不使用此对角公式：较高的旧因子若参与，就用保留索引子程序；若不参与，本次仅涉及一个父节点。两个模式若都为较高旧输出，每个至多含 m^{L-1} 个原输入因子，合计小于 N；一个若已达到高度 L，它已独自耗尽 N 个因子。确定性复制只按原输入因子数计数，不增加原父节点数。

所有坏情形已被排除，余下 m 条路径必在同一最低源父节点相遇，且来自 m 个不同的完整线性孩子，否则应在更低非线性孩子处停止。因此每步都是前述合法完整收缩；有限原树的边只被推进有限次，过程终止。高度计数排除 $t < L$。$t = L$ 时每条路径必须取等号，故无额外一元节点且每节点次数恰为 m；除预先分出的全 m 项外均矛盾。二阶融合已严格降低源高度，归纳从 $t = 1$ 起闭合。全 m 项的系数、权重与归一化保持原值，两类激活的结论同时成立。 □

E.1 从确定性事件到任意先验耦合

先控制各自先验下的误差，再对耦合取上确界。固定次数和深度时，有序展开项、因子配对、停止展开的位置选择、合并高度及收缩步骤的种类数均与 d 无关。分别在两个边缘上同时施加所有前述原始高斯事件，然后才允许跨网络收缩矩阵依赖两个网络。在共同好事件上，各项估计均为确定性 $o(1)$。在坏事件上，用固定次数系数的有界边缘高阶矩和 Hölder 不等式；坏事件概率可取任意所需多项式阶。该控制不依赖耦合，因此对所有先验边缘耦合一致。

设 T_W 为与激活对应、带完整标量系数的全 m 平衡齐次输入混沌项，$\mathcal{Q}_N(V)$ 为式 (50) 的多项式近似。上述逐展开项估计给出 $\mathbb{E}_\pi|\langle T_W, \mathcal{Q}_N(V) - T_V\rangle| = o(1)$，对耦合一致。又 T_W 位于第 N 输入混沌，故 $\langle T_W, F_V\rangle = \langle T_W, \Pi_N F_V\rangle$。剩余配对期望由 Cauchy–Schwarz 不等式控制为 $\|T_W\|_{L^2(W,X)}\|\Pi_N F_V - \mathcal{Q}_N(V)\|_{L^2(V,X)} = o(1)$；这里使用有界边缘二阶矩与式 (51)，同样对耦合一致。因此

$$\boxed{\sup_{\pi\in\Gamma(\mathsf{P}_W,\mathsf{P}_V)} \mathbb{E}_\pi|\langle T_W, F_V - T_V\rangle| \longrightarrow 0.} \tag{56}$$

F 齐次比较网络的全局匹配

固定 L、整数 $m \ge 5$、$k_0 = d$ 及 $k_s \asymp d$。本节的齐次网络为 $h^{(s)} = c_m(W^{(s)}h^{(s-1)}/\sqrt{k_{s-1}})^{\odot m}$，$c_m = (m!)^{-1/2}$，$h^{(0)} = x$，输出为 $\mathcal{H}_W = k_L^{-1/2}\sum_i h_i^{(L)}$，参数数目为 $p = \sum_s k_{s-1}k_s$。将 $h^{(s)}$ 换成形式变量 Y 后的输出记为 $P_s(Y)$，其次数为 $q_s = m^{L-s}$。写 $P_s(Y) = \langle C_s, Y^{\otimes q_s}\rangle$，使用继承的 Hilbert 范数，即

$$\|C_r(P)\|^2 = \sum_{|\nu|=r} \frac{\nu!}{r!}|p_\nu|^2 \quad 若 P(Y) = \sum_\nu p_\nu Y^\nu; \qquad C_L = k_L^{-1/2}\mathbf{1}. \tag{57}$$

定理 2 (齐次网络的有限标签全局匹配)**.** *存在确定性的参数对齐映射族 $\mathcal{G}_d$，使任意两个具有原独立标准高斯先验边缘的网络满足*

$$\log|\mathcal{G}_d| = O(d\log d) = o(p), \qquad p^{-1}\mathbb{E}\min_{g\in\mathcal{G}_d}\|W - gV\|_F^2 \le K\mathbb{E}\|C_0(W) - C_0(V)\|^2 + o_d(1). \tag{58}$$

K 只依赖固定深度、次数和宽度比例，余项对耦合一致。右侧亦可换为 $K\mathbb{E}\|\mathcal{H}_W - \mathcal{H}_V\|^2_{L^2(N(0,I_d))} + o_d(1)$。

共同典型事件。 归一化权重行的长度一致趋于一，单位行自身相干度 $\eta_d = O(\sqrt{\log d/d})$，行阵列算子范数有界，列平方和有正的常数上下界。在此高斯集中事件上，第 B 节的两个 Gram 界适用。令 $B_{s,i} = \partial_i P_s$、$w_j = W_{j:}^{(s+1)}/\sqrt{k_s}$；链式法则给出

$$B_{s,i}(Y) = m c_m \sum_j w_{ji} (w_j \cdot Y)^{m-1} B_{s+1,j}\big(c_m (w \cdot Y)^{\odot m}\big).$$

展开后的项正是 (30) 中带标签 (ν, j) 的删除因子张量。固定次数下单项式系数范数与 (57) 等价，故从 $B_{L,i} = k_L^{-1/2}$ 反向归纳，得到 $\|C(B_{s,i})\|^2 \asymp \sum_j w_{ji}^2 \|C(B_{s+1,j})\|^2 \asymp k_s^{-1}$。因此完整切片满足

$$a/k_s \le \|C_s(e_i, \cdot)\|^2 = q_s^{-2} \|C(\partial_i P_s)\|^2 \le b/k_s. \tag{59}$$

特别地 $\|C_s\| \le C$。令 SF 投影到平方自由坐标，其正交基中的系数为 $c_I = p_I/\sqrt{q_s!}$（$|I| = q_s$）。式 (37) 及原始系数界 13 给出同一边缘高概率事件上的

$$\max_I |c_I|^2 \le C (\log d)^{D_s} k_s^{-q_s}, \qquad D_s = m + \cdots + m^{L-s}, \tag{60}$$

$$\|(I - \mathrm{SF}) C_s\|^2 \le L_d/d = o(1). \tag{61}$$

终层取 $D_L = 0$，第二项为零。这里 L_d 可取适当的对数幂。这些事件在后文内部层的协调行列变换下保持：权重的集中量不变，系数仅重排、变号。故后面的数据依赖对齐仍可逐点使用全部估计。

全局对称与分组提升。 在一层写归一化行 $w_i = r_i a_i$、$\|a_i\| = 1$，置 $U_A e_i = a_i^{\otimes m}$、$\overline{C}_s = \mathrm{diag}(r_i^m)^{\otimes q_s} C_s$。有 $\|U_A\| \le \|A\|^m \le C$ 及精确代入式

$$C_{s-1} = c_m^{q_s} \, \mathrm{Sym}_{m q_s} U_A^{\otimes q_s} \overline{C}_s. \tag{62}$$

半径一致趋于一，故 $\overline{C}_s - C_s = o(1)$，且逐坐标的半径乘子一致为 $1 + o(1)$，故 (59)–(61) 仍成立。下证对任意两个典型网络、$q = q_s$，一致有

$$\|C_{s-1}^A - C_{s-1}^B\|^2 = \lambda_{m,q} \|G_A - G_B\|^2 + o(1), \qquad \lambda_{m,q} = \frac{q!}{(mq)!}. \tag{63}$$

这里 $G_A = U_A^{\otimes q} \overline{C}_s^A$、$G_B = U_B^{\otimes q} \overline{C}_s^B$。定义平方自由基的分组与全对称提升 $Q_I = \sqrt{q!}\,\mathrm{Sym}_q \bigotimes_{i \in I} a_i^{\otimes m}$、$E_I = \sqrt{(mq)!/(m!)^q}\,\mathrm{Sym}_{mq} \bigotimes_{i \in I} a_i^{\otimes m}$。式 (62) 将该基送到 $\sqrt{\lambda_{m,q}} E_I$。置 $\rho_{ij} = \langle a_i, b_j \rangle$、$\tau = d^{-1/8}$。二部图 $|\rho_{ij}| > \tau$ 的度数至多 $D = \lceil C/\tau^2 \rceil$；在各侧连接共享邻居的顶点，度数至多 D^2。不含这种边的 q 元集称为好集。对好 $I = \{i_1, \dots, i_q\}$ 和 $\sum_a v_a = m$，

$$\sum_j \prod_a |\rho_{i_a j}|^{v_a} \le \begin{cases} C, & |\operatorname{supp} v| = 1, \\ C\tau, & |\operatorname{supp} v| \ge 2. \end{cases} \tag{64}$$

确实，每列至多一个因子超过 τ；按最大因子的位置分区，从乘积保留该因子的平方，或保留它与另一因子各一幂。余下至少一幂不超过 τ，所留两幂的和由平方和界或 Cauchy–Schwarz 控制。配对计数给出

$$\langle E_I^A, E_J^B \rangle = \sum_{\substack{e_{ab} \ge 0 \\ \sum_b e_{ab} = \sum_a e_{ab} = m}} \frac{(m!)^q}{\prod_{a,b} e_{ab}!} \prod_{a,b} \rho_{i_a j_b}^{e_{ab}}.$$

$e = mP$（P 为排列矩阵）的项之和正是 $\langle Q_I^A, Q_J^B \rangle$。其余项至少一列混合两个标签；把对 J 的求和扩大到所有有序指标并分离各列，式 (64) 给出绝对行和 $O(\tau)$。交换两侧给出列和。令 $K_{\mathrm{act}} = (\langle E_I^A, E_J^B \rangle)_{I,J}$、$K_{\mathrm{grp}} = (\langle Q_I^A, Q_J^B \rangle)_{I,J}$ 为好集上的交叉 Gram，则

$$\|K_{\mathrm{act}} - K_{\mathrm{grp}}\|_{\mathrm{op}} \le C\tau. \tag{65}$$

自身 Gram 是同一论证的特例，因 $\eta_d < \tau$ 而所有集合均好。坏集至多 $C_q D^2 k^{q-1}$ 个，其总系数能量由 (60) 至多为 $C d^{-1/2} (\log d)^{D_s} = o(1)$，这一计数对依赖两个网络和系数的图也成立。两个提升有界，故删除坏集及重复指标的误差均为 $o(1)$；对三个 Gram 块应用 (65) 并恢复完整系数，即得 (63)。$q = 1$ 时无拆槽，等式精确成立。

单层匹配与系数恢复。 令 $M = U_A^* U_B = (\rho_{ij}^m)$、$\rho_i = \max_j |\rho_{ij}|$。一行中超过 τ 的至多 D 个学生行，其自身 Gram 范数至多 $1 + D\eta_d$；其余项保留平方并提出 τ^{m-2}，得到

$$\sum_j |M_{ij}| \le \rho_i^{m-2} + e_d, \qquad \sum_i |M_{ij}| \le 1 + e_d, \qquad e_d = C(D\eta_d + \tau^{m-2}) = o(1). \tag{66}$$

写完整有序系数数组 $C = \overline{C}_s^A = (c_I)$、$D' = \overline{C}_s^B = (d_J)$，并令 $\mathsf{K} = (M/(1+e_d))^{\otimes q}$。其绝对行列和 $r_I, s_J \le 1$，且

$$\begin{aligned} \mathcal{E} &:= \|C\|^2 + \|D'\|^2 - 2\langle C, \mathsf{K} D' \rangle \\ &= \sum_I (1 - r_I) c_I^2 + \sum_J (1 - s_J) d_J^2 + \sum_{I,J} |\mathsf{K}_{IJ}| (c_I - \operatorname{sgn}(\mathsf{K}_{IJ}) d_J)^2. \end{aligned} \tag{67}$$

因 $U_A^* U_A, U_B^* U_B = I + o_{\mathrm{op}}(1)$（非对角绝对行和至多 $k\eta_d^m = o(1)$），有 $\mathcal{E} = \|G_A - G_B\|^2 + o(1)$。$r_I$ 为各槽行和的乘积，故用第一槽的缺额及完整切片下界 (59) 得 $k_s^{-1} \sum_i (1 - \rho_i^{m-2}) \le C\mathcal{E} + o(1)$。固定 $\rho_0 \in (1/\sqrt{2}, 1)$。因 $2\rho_0^2 > 1 + \eta_d$，绝对相关超过 ρ_0 的边构成部分双射。补为排列并逐行定向后，对角相关非负；未匹配比例由上述缺额控制，已匹配行用 $1 - x^m \le m(1 - x^{m-2})/(m-2)$，便得

$$k_s^{-1} \sum_i \big(\ell_i + \|a_i - b_i\|^2 \big) \le C\mathcal{E} + o(1), \qquad \ell_i = 1 - \langle a_i, b_i \rangle^m. \tag{68}$$

同步重排系数并乘相应 m 次符号以保持 G_B 不变。此时 $\mathsf{K}_{II} \ge 0$，$1 - \mathsf{K}_{II} \le \sum_{a=1}^q (\ell_{i_a} + e_d)$。保留 (67) 的对角平方项，并用完整切片上界，得到

$$\|C - D'\|^2 \le \mathcal{E} + \sum_I (1 - \mathsf{K}_{II})(c_I - d_I)^2 \le \mathcal{E} + \frac{Cq}{k_s} \sum_i (\ell_i + e_d) \le C\mathcal{E} + o(1).$$

去掉半径因子，并结合 (63)，得到

$$\|C_s^A - C_s^B\|^2 + k_s^{-1} \sum_i \|w_i - v_i\|^2 \le C \|C_{s-1}^A - C_{s-1}^B\|^2 + o(1). \tag{69}$$

此处行已对齐；半径误差由 $\|r_i a_i - t_i b_i\|^2 \le C\|a_i - b_i\|^2 + C \max_j (|r_j - 1| + |t_j - 1|)^2$ 吸收。

深度归纳及任意耦合。 内部层的有符号行排列写作 $S_s = D_s P_s$，令 $R_s = D_s^{m \bmod 2} P_s$。将下一层的列同时变为 $V^{(s+1)} R_s^{-1}$，保持整个齐次函数及当前 C_{s-1} 不变。故自下而上在各内部层应用 (69)，以后对齐不影响已完成的层，固定深度下每层平均归一化行距离均至多 $C\|C_0(W) - C_0(V)\|^2 + o(1)$。终层 $q_L = 1$ 只需 (68)：若定向符号为 ς_i，在分析表示中把学生系数改为 $\varsigma_i^m t_i^m / \sqrt{k_L}$，原张量仍不变，切片界仍成立。无需恢复终层系数；终层符号只是参数标签，不要求保持函数。取所有映射 $(gV)^{(1)} = S_1 V^{(1)}$、$(gV)^{(s)} = S_s V^{(s)} R_{s-1}^{-1}$，则 $\log |\mathcal{G}_d| \le \sum_s (\log(k_s!) + k_s \log 2) = O(d \log d)$。按固定标签次序打破平局可使选择可测。将各层界以 $k_{s-1} k_s / p$ 加权相加，即得典型事件上的 (58)。任意先验耦合的联合失败概率由两个边缘失败概率之和控制；坏事件上用恒等对齐及 $p^{-1}\|W - V\|^2 \le 2p^{-1}(\|W\|^2 + \|V\|^2)$，再用归一化高斯平方范数的一致二阶矩和 Cauchy–Schwarz，期望贡献为一致的 $o(1)$。最后 $N = m^L$ 阶高斯混沌的等距性给出 $N! \|C_0(W) - C_0(V)\|^2 = \|\Pi_N(\mathcal{H}_W - \mathcal{H}_V)\|_{L^2}^2 \le \|\mathcal{H}_W - \mathcal{H}_V\|_{L^2}^2$，证明函数距离版本。 □

实际函数的参数比较。 式 (56) 和正文极化恒等式将实际函数距离控制转为齐次系数距离控制，再应用定理 2。行符号仅用于有限标签对齐，不要求保持实际激活的函数值。

G 条件 I–MMSE 与统一平滑测试场

记 $f = F_{\theta(W)}^{(L)}(X)$、$a = \nabla_W f$、$\mathcal{I}_W = \mathbb{E}_X a a^T / \Delta$、$Z = (\mathcal{D}_n, X)$。另取独立标准高斯 N，令 $U_s = \sqrt{s} f + N$、$m(s) = \mathbb{E}[(f - \mathbb{E}[f \mid Z, U_s])^2]$。真实高斯输出通道及条件 I–MMSE 给

$$\epsilon_{\log,d,n} = I(f; U_{1/\Delta} \mid Z) = \frac{1}{2} \int_0^{1/\Delta} m(s)\, ds. \tag{70}$$

为验证第二等号，条件于 $Z=z$，令 q_v 为 $f+\sqrt{v}N$ 的密度。高斯热方程、分部积分及条件期望公式给

$$\frac{d}{dv}h(q_v)=\frac{1}{2}\mathcal{J}(q_v),\qquad \partial_y \log q_v(y)=\frac{\mathbb{E}[f\mid z, f+\sqrt{v}N=y]-y}{v}.$$

正交分解得到 $\mathrm{mmse}(f\mid z,f+\sqrt{v}N)=v-v^2\mathcal{J}(q_v)$。从 $h(q_v)$ 减去噪声熵后微分，再令 $v=1/s$，互信息导数即为 MMSE 的一半。上述计算先对截断信号及有界空间成立；由 $\mathcal{J}(q_v)\le 1/v$ 和信号二阶矩的一致可积性，可在任意 $0<s_0\le s\le s_1$ 上去掉截断。最后用 $I(f;U_s\mid Z)\le s\mathbb{E}f^2/2$、$m(s)\le \mathbb{E}f^2$，平均 z 并令 $s_0\downarrow 0$，即得 (70)。

G.1　真实通道的分部积分界

对只依赖 (W,X) 的向量场 b，令

$$G_s=\delta b+b^{T}S_D+\sqrt{s}Nb^{T}a,\qquad \delta b=\mathrm{div}_W\, b-W\cdot b,\quad S_D=\nabla_W \log p(\mathcal{D}_n\mid W).$$

固定观察并对参数分部积分得 $\mathbb{E}[(\mathbb{E}[f\mid Z,U_s]-f)G_s]=\mathbb{E}b^{T}a$。给定 (W,X)，训练得分与辅助噪声独立且中心化，训练得分协方差为 $n\mathcal{I}_W$。因此 Cauchy–Schwarz 给

$$m(s)\ge \frac{(\mathbb{E}b^{T}a)^2}{n\mathbb{E}b^{T}\mathcal{I}_W b+\mathbb{E}(\delta b)^2+s\mathbb{E}(b^{T}a)^2}. \tag{71}$$

先对紧支撑光滑场及截断的后验均值证明，再用引理 7 的 Sobolev 逼近和 L^2 收敛取极限；以下估计保证所需可积性。

G.2　正则化测试场的 *OU* 平滑

固定 $0<\tau\le r\le 1$，令 $\lambda=r/p$、$M_W=(\mathcal{I}_W+\lambda I_p)^{-1}$、$b_0(W,X)=M_W a(W,X)$。取 (6) 中的 W_τ，仅对参数作条件平均：

$$b_\tau(W,X)=\mathbb{E}[b_0(W_\tau,X)\mid W,X].$$

真实网络、训练似然及辅助观测 U_s 均不变。首先

$$\mathbb{E}\|b_0\|^2=\Delta\mathbb{E}\,\mathrm{tr}(M_W^2\mathcal{I}_W)\le\frac{\Delta p}{4\lambda},\qquad \mathbb{E}\|b_\tau\|^4\le\mathbb{E}\|b_0\|^4\le C\lambda^{-4}.$$

将 b_0 视为 $L^2(P_X;\mathbb{R}^p)$ 值函数，记第 k 阶参数 Hermite 能量为 c_k。OU 半群逐阶乘 $e^{-\tau k}$，所以

$$\mathbb{E}\|Db_\tau\|_{\mathrm{HS}}^2=\sum_{k\ge1}ke^{-2\tau k}c_k\le C\tau^{-1}\mathbb{E}\|b_0\|^2\le Cp^2/(r\tau).$$

这直接使 b_τ 属于高斯 $W^{1,2}$，不需要对 M_W 求导。由引理 7、梯度四阶矩及 $\tau\le r$，

$$\mathbb{E}(\delta b_\tau)^2\le Cp^2/(r\tau),\qquad \mathbb{E}(b_\tau^{T}a)^2\le(\mathbb{E}\|b_\tau\|^4\mathbb{E}\|a\|^4)^{1/2}\le Cp^2/r^2\le Cp^2/(r\tau). \tag{72}$$

写 $b'(x)=b_0(W_\tau,x)$、$a'(x)=a(W_\tau,x)$、$e(x)=a(W,x)-a'(x)$，并另取独立输入 $\overline{X}$。条件于 $(W,W_\tau,\overline{X})$，X 仍独立，因此

$$\mathbb{E}_X b'(X)b'(X)^{T}=\Delta M_{W_\tau}\mathcal{I}_{W_\tau}M_{W_\tau}\preceq\frac{\Delta}{4\lambda}I_p.$$

由 (6)，$\mathbb{E}\|e(X)\|^2\le C\tau^{\delta}$。分别用 Cauchy–Schwarz 和上式条件协方差，得到

$$|\mathbb{E}b'(X)^{T}e(X)|\le Cp\tau^{\delta/2}/\sqrt{r},\qquad \Delta^{-1}\mathbb{E}[(b'(X)^{T}e(\overline{X}))^2]\le\frac{\mathbb{E}\|e(\overline{X})\|^2}{4\lambda}\le Cp\tau^{\delta}/r.$$

高斯先验不变性给 $\mathbb{E}b'(X)^{T}a'(X)=\Delta p[1-D_d(r)]$；独立输入给 $\Delta^{-1}\mathbb{E}[(b'(X)^{T}a'(\overline{X}))^2]=\Delta\mathbb{E}\,\mathrm{tr}[(M_W\mathcal{I}_W)^2]\le\Delta p$。故条件 Jensen 与 L^2 三角不等式给

$$\begin{aligned}\mathbb{E}b_\tau^{T}a&=\mathbb{E}b'(X)^{T}(a'(X)+e(X))\ge\Delta p[1-D_d(r)-C\tau^{\delta/2}/\sqrt{r}],\\ \mathbb{E}b_\tau^{T}\mathcal{I}_W b_\tau&\le\Delta^{-1}\mathbb{E}[(b'(X)^{T}(a'(\overline{X})+e(\overline{X})))^2]\le\Delta p[1+C\tau^{\delta/2}/\sqrt{r}]^2.\end{aligned} \tag{73}$$

将目标量下界取正部，与 (72) 一同代入 (71) 并对 (70) 积分。最后取 $\tau=r^{2/\delta}\le r$，使 $\tau^{\delta/2}/\sqrt{r}=\sqrt{r}$，即得 (23)。