# 中心化归一化网络的预测 KL 标度
# 固定深度标度定理

高斯回归；维度先行极限

*2026 年 10 月 24 日*

对任意固定深度、各层宽度与输入维数成正比的网络，本文证明平均 Bayes 预测 KL 的首项为 $P_{\text{hidden}}(d)/(2n)$。激活类包含中心化归一化的 tanh、sigmoid 和 ReLU。证明先从函数距离控制参数在排列和符号变换下的距离，再用互信息估计得到 Fisher 信息矩阵所需的谱性质。条件 I–MMSE 与高斯分部积分给出下界，线性高斯参考分布给出相同首项的上界。维数极限先于样本比极限；证明不要求固定样本比下的风险极限存在，也不依赖后验的局部高斯近似。

## 1 模型、激活类与定理

**中心化和归一化是模型的明确假设**。固定 $L \geq 1$，$k_0 = d$，$k_\ell/d \to \gamma_\ell \in (0,\infty)$，$\gamma_0 = 1$。第 $\ell$ 层权重为 $W^{(\ell)} \in \mathbb{R}^{k_\ell \times k_{\ell-1}}$，其元素独立标准高斯。输入 $x \sim N(0, I_d)$ 独立于参数。本文每层使用同一固定激活 $\sigma_\ell \equiv \sigma$，且

$$\mathbb{E}\sigma(G) = 0, \qquad \mathbb{E}\sigma(G)^2 = 1, \qquad G \sim N(0,1).$$

记 $W = (W^{(\ell)})_{\ell=1}^L$、$\theta = \theta(W) = (v, W)$，固定 $v_i = 1$，网络定义为

$$\begin{aligned} h^{(0)}(x) &= x, \qquad h^{(\ell)}(x) = \sigma_\ell\left(\frac{W^{(\ell)} h^{(\ell-1)}(x)}{\sqrt{k_{\ell-1}}}\right), \\ F_\theta^{(L)}(x) &= \frac{v^\mathsf{T} h^{(L)}(x)}{\sqrt{k_L}}. \end{aligned} \tag{1}$$

真实参数 $\theta^0 = (v, W^0)$ 由上述先验 $P_0$ 抽取。训练集 $\mathcal{D}_n = \{(x_\mu, y_\mu)\}_{\mu=1}^n$ 由

$$y_\mu = F_{\theta^0}^{(L)}(x_\mu) + \sqrt{\Delta} z_\mu, \qquad z_\mu \sim N(0,1), \quad \Delta > 0$$

生成。训练和测试输入独立同分布；噪声相互独立，且独立于参数与全部输入。记高斯通道为

$$P_{\text{out}}(y \mid \lambda) = N(y; \lambda, \Delta).$$

学习者使用真实先验和通道，其后验为

$$P(d\theta \mid \mathcal{D}_n) \propto P_0(d\theta) \prod_{\mu=1}^n P_{\text{out}}\left(y_\mu \mid F_\theta^{(L)}(x_\mu)\right).$$

只有隐藏矩阵被学习，读出 $v$ 固定；隐藏参数数目为

$$P_{\text{hidden}}(d) = \sum_{\ell=1}^L k_{\ell-1} k_\ell, \qquad c = \lim_d \frac{P_{\text{hidden}}(d)}{d^2} = \sum_{\ell=1}^L \gamma_{\ell-1}\gamma_\ell.$$

后验预测密度及平均预测 KL 定义为

$$\begin{aligned} p_{\mathcal{D}_n}(y \mid x) &= \mathbb{E}_{\theta \mid \mathcal{D}_n} P_{\text{out}}\left(y \mid F_\theta^{(L)}(x)\right), \\ \epsilon_{\log,d,n} &= \mathbb{E}_{\theta^0, \mathcal{D}_n, x} \, \mathrm{KL}\left(P_{\text{out}}\left(\cdot \mid F_{\theta^0}^{(L)}(x)\right) \,\middle\|\, p_{\mathcal{D}_n}(\cdot \mid x)\right). \end{aligned} \tag{2}$$

写 $\epsilon_{\log,d}(\alpha) := \epsilon_{\log,d,\lfloor \alpha d^2 \rfloor}$。技术证明中简记 $p = P_{\text{hidden}}(d)$，并把 $W$ 视为 $p$ 维隐藏权重坐标；梯度、Hessian、高斯积分和 OU 耦合均只作用于这些坐标。写 $\theta' = \theta(V)$ 表示第二组权重对应的参数。先验平均中可将真实隐藏权重 $W^0$ 简记为 $W$；技术附录中的 $F_W = F_{\theta(W)}^{(L)}$ 与 $F = F_W$ 均指同一个实际输出，除非明确使用下文定义的齐次多项式网络。

所有常数允许依赖固定深度、激活、宽度比例与噪声，不能依赖 $d, n$。

### 1.1 激活类

**取下列两类的并集 $\mathcal{A}_{\text{bal}}$**。两支均满足上述中心化及单位方差条件。光滑奇函数支：$\sigma$ 有界、奇、属于 $C^\infty$，每个固定阶导数有界。分段线性支：令 $c_0 = \sqrt{2/\pi}$，

$$\sigma(z) = az + b(|z| - c_0), \qquad b \neq 0, \qquad a^2 + b^2(1 - 2/\pi) = 1. \tag{3}$$

两支均全局 Lipschitz。条件只涉及一个实函数，不包含 Fisher、后验或信息极限前提。

记 $\mathrm{He}_j$ 为概率论约定的 Hermite 多项式，$\psi_j = \mathrm{He}_j/\sqrt{j!}$、$a_j = \mathbb{E}[\sigma(G)\psi_j(G)]$。与网络符号一致，$\mu_{\ell,j} = \mu_j = \sqrt{j!}a_j$。以下事实使光滑支无需另加高阶系数假设。

**引理 1** (高阶奇系数自动存在)**.** *若 $\sigma$ 为有界连续奇函数且 $\mathbb{E}\sigma(G)^2 = 1$，则存在奇数 $m \geq 5$ 使 $a_m \neq 0$。*

*证明.* 奇性使所有偶次系数为零。若所有奇数 $m \geq 5$ 的系数也为零，Hermite 系的 $L^2(\gamma)$ 完备性给出 $\sigma = a_1\psi_1 + a_3\psi_3$，高斯几乎处处成立。两边连续且高斯密度处处为正，故处处相等。有界多项式只能为常数，奇性又使该常数为零，与单位方差矛盾。 □

光滑支固定选择上述一个 $m$；分段线性支取 $m = 6$，其 $a_6 \neq 0$ 在下节直接验证。$m$ 可依赖固定激活，但不随维数或样本数变化；后文常数允许依赖此选择。

**定理 1.** *上述模型中，对任意固定深度 $L \geq 1$，任一固定 $\sigma \in \mathcal{A}_{\text{bal}}$ 满足*

$$\boxed{\lim_{\alpha\to\infty} \limsup_{d\to\infty} \left|\alpha\epsilon_{\log,d}(\alpha) - \frac{c}{2}\right| = 0.} \tag{4}$$

*该结论包含任意固定正斜率的中心化归一化 tanh、logistic sigmoid，以及中心化归一化 ReLU。*

先取 $d \to \infty$，再取 $\alpha \to \infty$。不要求固定 $\alpha$ 的风险极限存在；不据此扩展到未中心化模型、层间任意混用两支、增长深度或非高斯输出下同一精确常数的上界。

## 2 三个激活为何属于此类

**只需验证上述标量函数性质**。对任意固定 $a > 0$，令

$$s_a^2 = \mathbb{E}\tanh^2(aG) > 0, \qquad \sigma_a(z) = \tanh(az)/s_a.$$

它有界、光滑且为奇函数，因而中心化，定义给出单位方差。由 $\tanh' = 1 - \tanh^2$ 递推，每个固定阶导数都是 $\tanh(az)$ 的多项式乘固定常数，故有界。因此 $\sigma_a$ 属于光滑奇函数支，高阶非零系数由引理 1 自动保证。

对任意固定 $b > 0$，logistic sigmoid $\ell_b(z) = (1 + e^{-bz})^{-1}$ 满足

$$\ell_b(z) - \tfrac{1}{2} = \tfrac{1}{2}\tanh(bz/2).$$

其均值为 $1/2$，方差为 $s_{b/2}^2/4$，故中心化归一化后恰为 $\sigma_{b/2}$。

对 ReLU，直接积分给出

$$\mu_R = \mathbb{E}G_+ = \frac{1}{\sqrt{2\pi}}, \qquad v_R = \mathrm{Var}(G_+) = \frac{1}{2} - \frac{1}{2\pi}, \qquad \sigma_R(z) = \frac{z_+ - \mu_R}{\sqrt{v_R}}.$$

由 $z_+ = (z + |z|)/2$，它对应式 (3) 的 $a = b = 1/(2\sqrt{v_R})$。整个分段线性支都中心化；奇偶正交性给出其方差 $a^2 + b^2(1 - 2/\pi) = 1$。又由

$$\mathrm{He}_6(z) = z^6 - 15z^4 + 45z^2 - 15, \qquad \mathbb{E}|G|^{2j+1} = 2^j j!\sqrt{2/\pi},$$

得到 $\mathbb{E}[|G|\,\mathrm{He}_6(G)] = 3\sqrt{2/\pi}$，所以

$$a_6 = \frac{3b\sqrt{2/\pi}}{\sqrt{6!}} \neq 0.$$

分段线性支的奇次系数 $a_j$ 在 $j \geq 3$ 时均为零；光滑奇函数支的偶次系数均为零。这正是后文两类展开项所使用的奇偶结构。

## 3 先验矩与局部估计

以下先验矩估计用于控制线性近似误差和后验抽样误差。令 $q_\ell = \left\|h^{(\ell)}\right\|^2/k_\ell$，$q_0 = \|X\|^2/d$。对固定 $r>0$，所需结论为

$$\begin{aligned} &\mathbb{E}|q_\ell - 1|^r \le C_r d^{-r/2}, \qquad \sup_d \mathbb{E}|F_\theta^{(L)}(X)|^r < \infty, \\ &\sup_d \mathbb{E}\left\|\nabla_W F_\theta^{(L)}(X)\right\|^r < \infty. \end{aligned} \tag{5}$$

输出与范数矩由附录引理 3 证明；其中保留了全一读出的条件均值 $\sqrt{k_L}\,\mathbb{E}[\sigma(\sqrt{q_{L-1}}G)]$。梯度矩及光滑支的 $\mathbb{E}\|\nabla_W^2 F\|_{\mathrm{HS}}^2 \le C$ 由引理 4 的前向、反向递推与 Hessian 分解给出。

令 $a(W,X) = \nabla_W F_{\theta(W)}^{(L)}(X)$。引理 8 给出两支共用的梯度变化估计：对独立标准高斯 $Z$ 和 $0<\tau\le 1$，

$$W_\tau = e^{-\tau}W + \sqrt{1-e^{-2\tau}}Z, \qquad \mathbb{E}\|a(W_\tau,X) - a(W,X)\|^2 \le C\sqrt{\tau}. \tag{6}$$

记 $\theta(t) = \theta(W(t))$。令 $W(t) = \sqrt{1-t}W + \sqrt{t}Z$ 为保持先验的 OU 耦合。高斯 Hermite 展开给出

$$\begin{aligned} &F_{\theta(t)}^{(L)} - F_\theta^{(L)} = \sqrt{t}\,(\nabla_W F_\theta^{(L)})^T Z + E_t, \\ &\mathbb{E}\,\|E_t\|_{L_X^2}^2 \le Ct^{1+\delta}, \qquad \delta = \begin{cases} 1, & \text{光滑支}, \\ 1/2, & \text{分段线性支}. \end{cases} \end{aligned} \tag{7}$$

该余项估计针对上述保持高斯先验的扰动，常数与维数无关。

## 4 全局函数比较与参数匹配

本节证明：两个网络的输出接近时，其参数在适当排列和符号变换后也接近。先用一个齐次多项式网络提取实际输出中可比较的分量。写 $\psi_j = \mathrm{He}_j/\sqrt{j!}$、$a_j = \mathbb{E}\sigma(G)\psi_j(G)$，并置

$$N = m^L, \qquad S = 1 + m + \cdots + m^{L-1}, \qquad B = a_m^S \ne 0.$$

以各层齐次激活 $z^m/\sqrt{m!}$、原权重与原读出构造多项式网络，其最高输入次数系数为 $C_N(W) \in \mathrm{Sym}^N \mathbb{R}^d$。定义

$$H_m(W) = I_N(C_N(W)), \qquad T_W = BH_m(W).$$

这里 $I_N$ 将对称张量映为第 $N$ 阶 Hermite 多项式：对 $v\ne 0$，$I_N(v^{\otimes N})(X) = \|v\|^N \mathrm{He}_N(\langle v,X\rangle/\|v\|)$，再线性延拓。它满足 $\langle I_N(C), I_N(D)\rangle_{L_X^2} = N!\langle C,D\rangle$。张量均取对称张量空间中继承的 Hilbert 范数。

**引理 2** (函数内积的统一估计)**.** *若 $\Pi_d$ 为原高斯参数先验，记 $\Gamma(\Pi_d,\Pi_d)$ 为两个边缘均为 $\Pi_d$ 的联合分布集合，则*

$$e_d := \sup_{\pi\in\Gamma(\Pi_d,\Pi_d)} \mathbb{E}_\pi|\langle T_W, F_{\theta'}^{(L)} - T_V\rangle_{L_X^2}| \longrightarrow 0. \tag{8}$$

*这里允许任意正确先验边缘的耦合，不要求 $W,V$ 独立。*

*证明.* 记 $\Pi_N$ 为 $L^2(P_X)$ 到第 $N$ 阶 Hermite 子空间的正交投影。先在各自先验下逼近 $\Pi_N F_\theta^{(L)}$。令

$$P_N(z) = \sum_{j=1}^N \frac{a_j z^j}{\sqrt{j!}}, \quad Q_N(z) = \sum_{j=1}^N \frac{\beta_j z^j}{\sqrt{j!}}, \quad \beta_j = \mathbb{E}[(\sigma(G)^2-1)\psi_j(G)].$$

取原网络的前 $t$ 层，末层激活改为多项式 $A$，其余层改为 $P_N$。展开这个多项式网络，取次数恰为 $N$ 的系数张量，再应用 $I_N$，所得函数记为 $R_{t,N}[A;P_N]$。光滑奇支有

$$\Pi_N F_\theta^{(L)} = R_{L,N}[P_N;P_N] + o_{L^2(W,X)}(1).$$

分段线性支令 $\mu = bc_0/2$、$U_N = [Q_N - P_N^2]_{\le N}$，则实际公式为

$$\begin{aligned}\Pi_N F_\theta^{(L)} &= R_{L,N}[P_N; P_N] \\ &\quad + \mu \sum_{t=1}^{L-1} \sqrt{k_L/k_t}\, R_{t,N}[U_N; P_N] + o_{L^2(W,X)}(1).\end{aligned} \tag{9}$$

$U_N$ 可同时含奇次项和偶次项。式 (9) 中较浅网络的修正项来自条件均值与重复索引的二次项，推导见附录 D。

逐层展开多项式后，每一项可由有序树记录：节点标明所选幂次，叶对应张量因子。次数和深度固定，所以只有有限种展开项。附录 E 按层证明：与 $T_W$ 取内积时，深度 $L$ 中只有每个节点均取 $m$ 次项的贡献保留，其余项以及所有较浅网络的贡献均为 $o(1)$。保留项的 $S$ 个节点各贡献 $a_m$，因此恰为 $T_V$。

这些估计在分别由各网络参数确定的高概率事件上成立；事件补集由固定高阶矩控制，因此估计对两个网络的任意先验边缘耦合一致。若实际逼近误差为 $E_d(V)$，则

$$\mathbb{E}_\pi |\langle T_W, E_d(V)\rangle| \le (\mathbb{E}\,\|T_W\|^2)^{1/2} (\mathbb{E}\,\|E_d(V)\|^2)^{1/2} = o(1).$$

这只用边缘，不用两网络独立性。因 $T_W$ 位于第 $N$ 阶 Hermite 子空间，与其他 Hermite 阶数的分量正交，得到 (8)。 □

### 4.1 从函数比较到参数匹配

对内积估计展开平方，得到齐次多项式网络的距离控制。对某个正确边缘耦合令 $D = \mathbb{E}\,\|T_W - T_V\|^2$、$B_F = \mathbb{E}\left\|F_\theta^{(L)} - F_{\theta'}^{(L)}\right\|^2$。在原耦合、转置耦合以及两个对角项中分别使用 (8)，得

$$|\mathbb{E}\langle T_W - T_V, F_\theta^{(L)} - F_{\theta'}^{(L)}\rangle - D| \le 4e_d.$$

所以

$$D \le \sqrt{DB_F} + 4e_d \le (D + B_F)/2 + 4e_d, \quad D \le B_F + 8e_d.$$

齐次全局匹配定理给出有限可测映射族 $\mathcal{G}_d$，

$$\begin{aligned}\log|\mathcal{G}_d| &= O(d\log d) = o(p), \\ \frac{1}{p}\mathbb{E}\min_{g\in\mathcal{G}_d}\|W - gV\|^2 &\le C\mathbb{E}\,\|H_m(W) - H_m(V)\|^2 + o_d(1) \\ &\le C\mathbb{E}\left\|F_\theta^{(L)} - F_{\theta'}^{(L)}\right\|^2 + o_d(1).\end{aligned} \tag{10}$$

误差对耦合一致。附录 F 通过逐层匹配证明式 (10)，右侧仍为函数距离的平方。映射可包含行符号变换；后文只将 $gV$ 用作高斯混合分布的中心，因此不要求这些变换保持实际网络输出。

## 5 互信息界与后验收缩

**先由先验矩控制后验参数距离**。记 $I_{d,n} = I(\theta^0; \mathcal{D}_n) = I(W; \mathcal{D}_n)$。Bayes 定义和样本条件独立性给出

$$\epsilon_{\log,d,n} = I_{d,n+1} - I_{d,n}, \qquad \epsilon_{\log,d,n+1} \le \epsilon_{\log,d,n}. \tag{11}$$

第二式也可由条件熵递减看出：真实条件噪声熵不随数据量改变，预测熵随观察增加而减小。

### 5.1 粗风险上界

由下一节仅依赖先验矩与 OU 余项证明的 (19)，取 $n/p \ge 1$、$t = (1 + n/p)^{-1}$。此时

$$\mathbb{E}\log\det(I_p + ntA/\Delta) \le nt\mathbb{E}\,\mathrm{tr}\,A/\Delta \le Cp, \qquad (n/p)t^{1+\delta} \le 1,$$

所以 $I_{d,n} \le \frac{p}{2}\log(1 + n/p) + Cp$。由 (11)，$n\epsilon_{\log,d,n} \le I_{d,n}$，因此

$$\limsup_d \epsilon_{\log,d}(u) \le C\frac{\log u}{u} \qquad (u \text{ 充分大}). \tag{12}$$

### 5.2 从 KL 到函数距离，再到匹配距离

**平均后验样本仍有精确的先验边缘**。给定 $\mathcal{D}_n$ 独立抽取 $W, V$；平均数据后各自服从 $\Pi_d$。若 $B_X = F_\theta^{(L)}(X) - F_{\theta'}^{(L)}(X)$，高斯 Hellinger 比较给出

$$\mathbb{E}[1 - e^{-B_X^2/(8\Delta)}] \le 2\epsilon_{\log,d,n}. \tag{13}$$

理由是 Hellinger 距离在 $L^2$ 平方根密度空间满足三角不等式；以后验预测密度为中间点，再用 $(x+y)^2 \le 2x^2 + 2y^2$，两个后验样本的平均平方距离至多四倍单样本平方距离，而后者由 KL 控制。高斯两均值的亲和度恰为 $e^{-B_X^2/(8\Delta)}$。

对固定 $q > 2$，先在 $B_X^2 \le 8\Delta$ 上使用 $1 - e^{-x} \ge (1 - e^{-1})x$，得到截断二阶矩 $\le C\epsilon_{\log,d,n}$。在补集上，(13) 控制概率，(5) 控制 $q$ 阶矩，Hölder 给出

$$\mathbb{E}[B_X^2 \mathbf{1}_{B_X^2 > 8\Delta}] \le (\mathbb{E}|B_X|^q)^{2/q} \Pr(B_X^2 > 8\Delta)^{1-2/q} \le C_q \epsilon_{\log,d,n}^{1-2/q}.$$

因此

$$\mathbb{E} \left\| F_\theta^{(L)} - F_{\theta'}^{(L)} \right\|_{L_X^2}^2 \le C_q(\epsilon_{\log,d,n} + \epsilon_{\log,d,n}^{1-2/q}).$$

将 (10) 应用于这一后验耦合，定义

$$r_{d,n} = \frac{1}{p}\mathbb{E} \min_{g \in \mathcal{G}_d} \|W - gV\|^2, \qquad r_*(u) = \limsup_d r_{d,\lfloor ud^2 \rfloor}.$$

取 $q = 2/\eta$，$0 < \eta < 1$，由 (12) 得

$$r_*(u) \le C_\eta \left( \frac{\log u}{u} \right)^{1-\eta}. \tag{14}$$

这里只固定一次矩阶数，不令其随维度增长。

### 5.3 由后验参数距离得到互信息下界

给定 $\mathcal{D}_n$ 独立抽取后验样本 $W, V$，选使 $\|W - gV\|$ 最小的可测标签。条件独立性、有限标签熵及高斯最大熵给

$$h(W \mid \mathcal{D}_n) = h(W \mid \mathcal{D}_n, V) \le \log |\mathcal{G}_d| + \frac{p}{2} \log(2\pi e r_{d,n}).$$

因 $W \sim N(0, I_p)$，有 $I_{d,n}/p \ge \frac{1}{2}\log(1/r_{d,n}) - p^{-1}\log|\mathcal{G}_d|$。结合 (14)，对每个固定 $0 < \eta < 1$ 及充分大的固定 $\alpha$，

$$\liminf_d \frac{I_{d,\lfloor \alpha d^2 \rfloor}}{p} \ge \frac{1-\eta}{2}\log\alpha - \frac{1-\eta}{2}\log\log\alpha - C_\eta. \tag{15}$$

## 6 线性高斯参考分布与互信息增量

令 $V_t = \sqrt{1-t}W + \sqrt{t}U$，其中 $U$ 为独立标准高斯，$0 < t \le 1/2$。反向写为 $W = \sqrt{1-t}V_t + \sqrt{t}\xi$，其中 $\xi$ 与 $V_t$ 独立标准高斯。记 $f_W = F_{\theta(W)}^{(L)}$、$a(x) = \nabla f_{V_t}(x)$、$A = \mathbb{E}_X a(X)a(X)^T$。已有 (7)、(5) 给出

$$f_W(x) - f_{V_t}(x) = \sqrt{t}\, a(x)^T\xi + R_t(x), \qquad \mathbb{E}\|R_t\|_{L_X^2}^2 \le Ct^{1+\delta}, \quad \mathbb{E}\|a(X)\|^4 \le C.$$

两支统一可取 $\delta = 1/2$。

### 6.1 相对熵分解与互信息增量

给定 $V_t, X_{1:j}$，令 $\Phi_j$ 的第 $i$ 行为 $a(X_i)^T$，定义

$$Q_j = N((f_{V_t}(X_i))_{i \le j}, S_j), \qquad S_j = \Delta I_j + t\Phi_j\Phi_j^T.$$

这些参考分布由同一个虚拟系数 $\zeta \sim N(0, I_p)$ 的线性模型 $f_{V_t}(X_i) + \sqrt{t}\, a(X_i)^T\zeta + \sqrt{\Delta}Z_i$ 产生，因此其样本边缘相容。输入采用真实的独立分布，虚拟系数不作为额外观察。令 $P_j$ 为给定 $V_t$ 的真实数据分布，定义

$$C_j = \mathbb{E}\log\frac{p(Y_{1:j} \mid W, X_{1:j})}{q_j(Y_{1:j} \mid V_t, X_{1:j})}, \qquad B_j = \mathbb{E}_{V_t}\,\mathrm{KL}(P_j \| Q_j).$$

这里 $P_j, Q_j$ 均包含输入的相同边缘。相对熵分解和边缘相容性分别给

$$I(W; \mathcal{D}_j \mid V_t) = C_j - B_j, \qquad B_n - B_j \geq 0 \quad (n \geq j).$$

第二式由相对熵链式法则得到。记知道 $V_t$ 的真实 Bayes 预测 KL 为 $\epsilon^V_{\log,d,k}$，因此

$$\sum_{k=j}^{n-1} \epsilon^V_{\log,d,k} \leq C_n - C_j. \tag{16}$$

### 6.2 交叉熵的非线性误差

令 $L_j = \sqrt{t}\Phi_j\xi$、$R_j = (R_t(X_i))_{i\leq j}$。高斯密度公式给出

$$C_j = \frac{1}{2}\mathbb{E}\log\det(I_j + t\Phi_j\Phi_j^T/\Delta) + \mathbb{E}L_j^T S_j^{-1} R_j + \frac{1}{2}\mathbb{E}R_j^T S_j^{-1} R_j.$$

这里用到了精确抵消

$$\mathbb{E}[L_j^T S_j^{-1} L_j \mid V_t, X_{1:j}] + \Delta\,\mathrm{tr}\, S_j^{-1} = j.$$

由于 $S_j \succeq \Delta I_j$，且线性模型的有效维数至多 $p$，

$$\mathbb{E}R_j^T S_j^{-1} R_j \leq Cjt^{1+\delta}, \qquad \mathbb{E}L_j^T S_j^{-1} L_j = \mathbb{E}\,\mathrm{tr}(t\Phi_j\Phi_j^T S_j^{-1}) \leq p.$$

加权 Cauchy–Schwarz 与 Sylvester 恒等式遂给

$$\left| C_j - \frac{1}{2}H_j \right| \leq C\sqrt{pjt^{1+\delta}} + Cjt^{1+\delta}, \qquad H_j = \mathbb{E}\log\det(I_p + t\Phi_j^T\Phi_j/\Delta). \tag{17}$$

不要求 $R_j$ 与 $\xi$ 独立。

### 6.3 经验与总体行列式的比较

置 $\overline{H}_j = \mathbb{E}\log\det(I_p + jtA/\Delta)$。矩阵 $M \succeq I_p$ 上，$-\log\det M$ 的 Hessian 满足

$$D^2(-\log\det)(M)[H,H] = \mathrm{tr}(M^{-1}HM^{-1}H) \leq \|H\|^2_{\mathrm{HS}}.$$

条件于 $V_t$，在矩阵 $I_p + (t/\Delta)\sum_{i\leq j} a(X_i)a(X_i)^T$ 与其均值间作二阶 Taylor 展开，再用条件独立性，得到

$$0 \leq \overline{H}_j - H_j \leq \frac{jt^2}{2\Delta^2}\mathbb{E}\|a(X)a(X)^T - A\|^2_{\mathrm{HS}} \leq Cjt^2.$$

对 $n > j \geq 1$，逐特征值使用 $(1 + nt\lambda/\Delta)/(1 + jt\lambda/\Delta) \leq n/j$，即有

$$H_n - H_j \leq \overline{H}_n - \overline{H}_j + Cjt^2 \leq p\log(n/j) + Cjt^2.$$

结合 (16)–(17)，得到有限维样本块界

$$\sum_{k=j}^{n-1} \epsilon^V_{\log,d,k} \leq \frac{p}{2}\log\frac{n}{j} + Cjt^2 + C\sqrt{pnt^{1+\delta}} + Cnt^{1+\delta}. \tag{18}$$

同一参考分布也控制累计互信息。由链式法则及 $B_n \geq 0$，$I_{d,n} \leq I(W; V_t) + C_n$。再用 (17) 和 $H_n \leq \overline{H}_n$，得到

$$\begin{aligned} \frac{I_{d,n}}{p} \leq{}& \frac{1}{2}\log\frac{1}{t} + \frac{1}{2p}\mathbb{E}\log\det(I_p + ntA/\Delta) \\ &+ C\sqrt{\frac{n}{p}t^{1+\delta}} + C\frac{n}{p}t^{1+\delta}. \end{aligned} \tag{19}$$

## 7 信息矩阵的谱与预测下界

令 $a_W(x)=\nabla_W F_\theta^{(L)}(x)$、$\mathcal{I}_W=\mathbb{E}_X a_W a_W^T/\Delta$，并记

$$D_d(r)=\mathbb{E}\frac{1}{p}\operatorname{tr}\{r(p\mathcal{I}_W+rI)^{-1}\},\qquad \nu_d=\frac{1}{p}\mathbb{E}\sum_{i=1}^{p}\delta_{\lambda_i(p\mathcal{I}_W)}.$$

由梯度二阶矩，$\int\lambda\,d\nu_d=\mathbb{E}\operatorname{tr}\mathcal{I}_W\le C$。

### 7.1 互信息界排除零附近的正比例谱质量

记 $q_d(s)=\nu_d([0,s])$。反设 $b=\lim_{s\downarrow0}\limsup_d q_d(s)>0$，固定 $0<\beta<b$。在 (19) 中取 $n=\lfloor\alpha d^2\rfloor$、$t=\alpha^{-3/4}$、$\delta=1/2$。对每个充分大的固定 $\alpha$，可选维数子序列使 $q=q_d(\alpha^{-1})\ge\beta$。因 $n/p\to\alpha/c$，记 $Q_d=nt/p\le C\alpha^{1/4}$。$A/\Delta$ 与 $\mathcal{I}_W$ 同分布，所以 Jensen 不等式给

$$\begin{aligned}\frac{1}{p}\mathbb{E}\log\det(I_p+ntA/\Delta)&=\int\log(1+Q_d\lambda)\,d\nu_d\\&\le\log(1+Q_d/\alpha)+(1-q)\log\left(1+\frac{CQ_d}{1-q}\right)\\&\le\frac{1-\beta}{4}\log\alpha+C.\end{aligned}$$

$q=1$ 时第二项按连续延拓取零；最后一步用 $-(1-q)\log(1-q)\le1/e$。故沿该子序列，信息上界至多

$$\frac{1-\beta/4}{2}\log\alpha+C+O(\alpha^{-1/16}).$$

在 (15) 中固定 $\eta=\beta/8$，其 $\log\alpha$ 系数比上式大 $\beta/16$，而其余损失仅为 $O_\eta(\log\log\alpha)$。令 $\alpha\to\infty$ 得矛盾，因此 $b=0$。最后由 $D_d(r)\le q_d(s)+r/s$，依次令 $d\to\infty$、$r\downarrow0$、$s\downarrow0$，得到

$$D_*(r):=\limsup_d D_d(r),\qquad\lim_{r\downarrow0}D_*(r)=0.\tag{20}$$

### 7.2 预测 KL 下界

附录 G 对正则化测试场作 OU 平滑，证明

$$\epsilon_{\log,d,n}\ge\frac{p[1-D_d(r)-C\sqrt{r}]_+^2}{2\{n(1+C\sqrt{r})^2+Cp/r^5\}},\qquad0<r\le1.\tag{21}$$

固定 $r$，依次令 $d\to\infty$、$\alpha\to\infty$，得到

$$\liminf_{\alpha\to\infty}\alpha\liminf_d\epsilon_{\log,d}(\alpha)\ge\frac{c[1-D_*(r)-C\sqrt{r}]_+^2}{2(1+C\sqrt{r})^2}.$$

最后由 (20) 令 $r\downarrow0$，得到

$$\liminf_{\alpha\to\infty}\alpha\liminf_d\epsilon_{\log,d}(\alpha)\ge c/2.\tag{22}$$

## 8 消去辅助观测并完成上界

定义 $J_j(t)=I(W;V_t\mid\mathcal{D}_j)$。给定数据独立抽后验样本 $W'$，用有限匹配族构造参考密度

$$Q_{W'}^{\mathrm{par}}=\frac{1}{|\mathcal{G}_d|}\sum_{g\in\mathcal{G}_d}N(\sqrt{1-t}\,gW',tI_p).$$

任一混合分量都被 $|\mathcal{G}_d|Q_{W'}^{\mathrm{par}}$ 支配，高斯 KL 公式给

$$\mathrm{KL}\big(N(\sqrt{1-t}W,tI_p)\big\|Q_{W'}^{\mathrm{par}}\big)\le\log|\mathcal{G}_d|+\frac{1-t}{2t}\min_g\|W-gW'\|^2.$$

相对熵分解及 $W'$ 的后验条件独立性因此给

$$J_j(t) \le \log|\mathcal{G}_d| + \frac{pr_{d,j}}{2t}. \tag{23}$$

这里最优标签只用于上界，未提供给学习者。

由 Markov 链 $V_t - W - \mathcal{D}_n$ 和互信息链式法则，

$$\sum_{k=j}^{n-1} \epsilon_{\log,d,k} = \sum_{k=j}^{n-1} \epsilon^{V}_{\log,d,k} + J_j(t) - J_n(t).$$

风险递减、$J_n(t) \ge 0$ 及 (18)–(23) 给

$$\begin{aligned}(n-j)\epsilon_{\log,d,n} \le\ & \log|\mathcal{G}_d| + \frac{pr_{d,j}}{2t} + \frac{p}{2}\log\frac{n}{j} \\ & + Cjt^2 + C\sqrt{pnt^{1+\delta}} + Cnt^{1+\delta}.\end{aligned} \tag{24}$$

固定 $\vartheta \in (0,1)$，取 $n = \lfloor \alpha d^2 \rfloor$、$j = \lfloor (1-\vartheta)\alpha d^2 \rfloor$。所有小参数在维度极限中固定。因为 $p/d^2 \to c$、$\log|\mathcal{G}_d| = o(d^2)$，先令 $d \to \infty$ 得

$$\begin{aligned}\alpha \limsup_d \epsilon_{\log,d}(\alpha) \le\ & \frac{c}{2\vartheta}\left\{\frac{r_*((1-\vartheta)\alpha)}{t} + \log\frac{1}{1-\vartheta}\right\} \\ & + \frac{C}{\vartheta}\left\{\alpha t^2 + \sqrt{\alpha t^{1+\delta}} + \alpha t^{1+\delta}\right\}.\end{aligned} \tag{25}$$

在 (14) 中取 $\eta = 1/8$，并取 $t = \alpha^{-3/4}$。两支统一使用 $\delta = 1/2$，则四个误差分别为

$$O_\vartheta(\alpha^{-1/8}(\log\alpha)^{7/8}), \qquad \alpha^{-1/2}, \qquad \alpha^{-1/16}, \qquad \alpha^{-1/8},$$

全部趋零。先 $\alpha \to \infty$，再 $\vartheta \downarrow 0$，由 $\vartheta^{-1}\log(1/(1-\vartheta)) \to 1$ 得

$$\limsup_{\alpha\to\infty} \alpha \limsup_d \epsilon_{\log,d}(\alpha) \le c/2.$$

结合 (22)，并使用

$$\limsup_d |\alpha\epsilon_{\log,d}(\alpha) - c/2| = \max\{\alpha\limsup_d \epsilon_{\log,d}(\alpha) - c/2,\, c/2 - \alpha\liminf_d \epsilon_{\log,d}(\alpha)\},$$

即证明原定理。没有交换维度与样本比极限，也没有对累计信息渐近式求导。

## A　固定深度网络的解析估计及分部积分的定义域

**固定深度与比例宽度下，各阶矩和局部导数具有维数一致的控制**。所有期望均针对独立标准高斯输入和权重；本节不把后验双副本当成高斯耦合。固定深度 $L$，令 $k_0 = d$，且 $cd \le k_\ell \le Cd$，其中 $0 < c < C < \infty$ 固定。采用

$$u^{(\ell)} = W^{(\ell)}h^{(\ell-1)}/\sqrt{k_{\ell-1}}, \quad h^{(\ell)} = \sigma_\ell(u^{(\ell)}), \quad h^{(0)} = X, \qquad F = k_L^{-1/2}\mathbf{1}^T h^{(L)}.$$

每层激活固定、全局 Lipschitz，且 $\mathbb{E}\sigma_\ell(G) = 0$、$\mathbb{E}\sigma_\ell(G)^2 = 1$。常数可以依赖 $L, c, C$、激活以及指定的有限阶矩，不能依赖 $d$。后文 OU 梯度变化与余项估计的常数和维数阈值均独立于其扰动参数。任何矩阶均先固定，再选择维数阈值。

### A.1　输出和隐藏范数的任意固定阶矩

**引理 3.** 令 $q_\ell = \|h^{(\ell)}\|^2/k_\ell$。每个固定 $r > 0$ 均有

$$\mathbb{E}q_\ell^r \le C_r, \qquad \mathbb{E}|q_\ell - 1|^r \le C_r d^{-r/2}, \qquad \mathbb{E}|F|^r \le C_r.$$

这些结论适用于混合使用上述激活的固定层数网络。此外，每个固定 $r > 0$ 有 $\sup_{\ell,i,d}\mathbb{E}|h_i^{(\ell)}|^r < \infty$；任意固定个特征的固定次幂乘积具有一致有界的绝对期望，允许这些特征来自不同层或不同输入副本，只须各副本具有规定的高斯边缘分布。

证明. 写 $b(q)=\mathbb{E}\sigma(\sqrt{q}G)$ 和 $v(q)=\mathbb{E}\sigma(\sqrt{q}G)^2$。由 $|\sigma(z)|\le M|z|+M_0$，对全部 $q\ge 0$ 有

$$\mathbb{E}|\sigma(\sqrt{q}G)|^s\le C_s(1+q^{s/2}),\quad |b(q)|\le C|q-1|,\quad |v(q)-1|\le C|q-1|. \tag{A1}$$

最后一式来自差平方公式及 $|\sqrt{q}-1|(\sqrt{q}+1)=|q-1|$；前一式用 $b(1)=0$。这些是全局估计，不剔除坏方差事件。

先记录样本均值的直接矩展开。条件独立、条件中心化的 $Y_i$ 若满足 $\mathbb{E}[|Y_i|^s\mid\mathcal{F}]\le C_s(1+q^{as})$，$2\le s\le 2m$，则

$$\mathbb{E}\left[\left|N^{-1}\sum_i Y_i\right|^{2m}\middle|\mathcal{F}\right]\le C_mN^{-m}(1+q^{2ma}). \tag{A2}$$

事实上，展开 $2m$ 次幂；含只出现一次的指标的项为零。余项至多有 $m$ 个不同指标，有 $j$ 个不同指标的项数至多 $C_mN^j$；其条件矩绝对值至多 $C_m(1+q^{2ma})$。除以 $N^{2m}$ 即得所述界。

给定前层，当前层的各预激活恰为独立 $N(0,q_{\ell-1})$。Jensen 不等式先给出 $\mathbb{E}[q_\ell^{2m}\mid\mathcal{F}_{\ell-1}]\le C_m(1+q_{\ell-1}^{2m})$，故固定深度归纳得到正矩界。对 $Y_i=(h_i^{(\ell)})^2-v_\ell(q_{\ell-1})$ 使用 (A2)，再使用 (A1)，得到

$$\mathbb{E}|q_\ell-1|^{2m}\le C_md^{-m}+C_m\mathbb{E}|q_{\ell-1}-1|^{2m}.$$

初值由 $q_0=d^{-1}\sum_i X_i^2$ 和同一矩展开给出 $O(d^{-m})$，故所有隐藏层均成立。最后，条件于前 $L-1$ 层，精确分解为

$$F=\sqrt{k_L}\,b_L(q_{L-1})+k_L^{-1/2}\sum_i\{h_i^{(L)}-b_L(q_{L-1})\}.$$

第二项的 $2m$ 阶条件矩由 (A2) 控制为 $C_m(1+q_{L-1}^m)$；第一项的 $2m$ 阶矩不超过 $C_mk_L^m\mathbb{E}|q_{L-1}-1|^{2m}=O(1)$。取 $2m\ge r$ 并用矩的单调性完成输出矩证明。单个特征的矩由 (A1) 对前层条件化得到；固定乘积的矩由 Hölder 不等式得到，不需各因子独立。特别地，全一读出的条件均值没有被丢弃。 □

### *A.2 梯度与 Hessian 的矩界*

令 $A_\ell=W^{(\ell)}/\sqrt{k_{\ell-1}}$，$B_\ell=\|A_\ell\|_{\mathrm{op}}$。以后 $P$ 表示 $1+\|X\|/\sqrt{d}$ 与有限个 $B_\ell$ 的非负固定次数多项式；存在第二组独立高斯矩阵时也允许其归一化算子范数。所有这样的 $P$ 的每个固定阶矩均一致有界。为核实这一点，在 $\mathbb{R}^m,\mathbb{R}^r$ 单位球面各取至多 $9^m,9^r$ 个点的 $1/4$ 网。对高斯 $m\times r$ 矩阵 $G$，双线性形式的网逼近给出

$$\|G\|_{\mathrm{op}}\le 2\max_{u,v\ \text{属于网}}|u^TGv|,\quad \mathbb{P}\{\|G\|_{\mathrm{op}}^2\ge 8[\log 2+(m+r)\log 9+s]\}\le e^{-s}.$$

积分此尾界并使用有界宽度比，即得所需的全部矩。

**引理 4.** *对 Lipschitz 激活，弱梯度满足 $\mathbb{E}\|\nabla_WF\|^r\le C_r$，每个固定 $r>0$ 均成立。若各激活还属于 $C^2$ 且二阶导数有界，则*

$$\mathbb{E}\|\nabla_W^2F\|_{\mathrm{HS}}^2\le C.$$

*特别地，归一化 tanh 和中心化归一化 sigmoid 满足这些结论。*

证明. 前向递推给出 $\|h^{(\ell)}\|/\sqrt{k_\ell}\le P$。定义

$$\beta_L=k_L^{-1/2}\mathbf{1},\quad \lambda_\ell=\mathrm{diag}(\sigma_\ell'(u^{(\ell)}))\beta_\ell,\quad \beta_{\ell-1}=A_\ell^T\lambda_\ell.$$

由有界斜率，$\|\beta_\ell\|+\|\lambda_\ell\|\le P$，且

$$\nabla_{W^{(\ell)}}F=\lambda_\ell(h^{(\ell-1)})^T/\sqrt{k_{\ell-1}},\qquad \|\nabla_WF\|^2\le P. \tag{A3}$$

网络在每个有限维空间局部 Lipschitz；链式公式在可微点成立，并代表弱导数。亦可逐层平滑激活，用上述界和弱紧致性识别同一弱梯度。

写 $J_{u,\ell},J_{h,\ell}$ 为对全部权重的 Jacobian。由

$$\|J_{u,\ell}\|_{\mathrm{op}}\le B_\ell\|J_{h,\ell-1}\|_{\mathrm{op}}+\|h^{(\ell-1)}\|/\sqrt{k_{\ell-1}},\qquad \|J_{h,\ell}\|_{\mathrm{op}}\le M\|J_{u,\ell}\|_{\mathrm{op}},$$

二者算子范数均不超过 $P$。计算图的二阶链式法则把输出 Hessian 精确写为各层的两类项之和。激活项为

$$J_{u,\ell}^T \operatorname{diag}(\beta_\ell \odot \sigma_\ell''(u^{(\ell)}))J_{u,\ell};$$

它的 Hilbert–Schmidt 范数不超过 $\|J_{u,\ell}\|_{\mathrm{op}}^2\|\sigma_\ell''\|_\infty\|\beta_\ell\|$。混合项的双线性形式为

$$k_{\ell-1}^{-1/2}\lambda_\ell^T\{U^{(\ell)}Dh^{(\ell-1)}[V]+V^{(\ell)}Dh^{(\ell-1)}[U]\}.$$

其中一个方向的 Hilbert–Schmidt 范数平方恰为 $\|\lambda_\ell\|^2\|J_{h,\ell-1}\|_{\mathrm{HS}}^2/k_{\ell-1}$，不超过 $\|\lambda_\ell\|^2\|J_{h,\ell-1}\|_{\mathrm{op}}^2$，因为该 Jacobian 的秩不超过 $k_{\ell-1}$。转置方向同理。对固定层数求和，再用 $P$ 的矩界即可。 □

### *A.3 分段线性激活的负阶矩与符号变化*

考虑固定实数 $a,b$ 的激活

$$\sigma(z)=az+b(|z|-c_0),\qquad c_0=\sqrt{2/\pi},\qquad a^2+b^2(1-2/\pi)=1. \tag{A5}$$

当 $b=0$，这是已被激活类排除的线性函数 $\sigma(z)=\pm z$。以下取 $b\neq 0$，但不要求 $a\neq 0$，也不要求 $a+b$ 和 $a-b$ 均非零。因此偶函数支和一侧斜率为零的 ReLU 支均被包含。常数可以依赖固定的 $(a,b)$；不声称当 $b\to 0$ 时一致。

**引理 5.** *存在 $\eta_0,C_0>0$，使得对全部 $r\geq 0$、$0<\eta\leq\eta_0$，*

$$\mathbb{P}\{\sigma(rG)^2\leq\eta\}\leq C_0\sqrt{\eta}.$$

*若 $Q=N^{-1}\sum_{i=1}^N\sigma(rG_i)^2$，则每个固定 $p>0$ 都存在 $N_0(p)$ 使 $\sup_{r\geq 0,N\geq N_0(p)}\mathbb{E}Q^{-p}<\infty$。*

*证明.* 记 $c=bc_0\neq 0$。在两条半轴上，激活分别为 $s_\pm z-c$，其中 $s_\pm=a\pm b$。若斜率为零，该半轴取恒值 $-c$，当 $\sqrt{\eta}<|c|/2$ 时不会贡献小球事件。非零斜率的半轴上，小球事件属于以非零根 $c/s_\pm$ 为中心、长度 $2\sqrt{\eta}/|s_\pm|$ 的区间；无合法半轴根时直接舍去。缩小 $\eta_0$ 后，每个区间与零有固定正距离。对 $|z|\geq\delta>0$，密度 $r^{-1}\phi(z/r)$ 在全部 $r>0$ 上一致有界，因为令 $v=|z|/r$ 后它等于 $v\phi(v)/|z|$。$r=0$ 时事件为空。因此得小球界。

事件 $Q\leq\eta$ 要求至少 $N/2$ 项不超过 $2\eta$；条件独立和子集计数给出 $\mathbb{P}(Q\leq\eta)\leq(C_1\eta^{1/4})^N$。选更小的 $\eta_0$ 使 $C_1\eta_0^{1/4}<1/2$，则

$$\mathbb{E}Q^{-p}\leq\eta_0^{-p}+pC_1^N\int_0^{\eta_0}s^{N/4-p-1}\,ds\leq\eta_0^{-p}+\frac{p\eta_0^{-p}2^{-N}}{N/4-p}$$

对 $N>4p$ 一致有界。逐层条件化立即证明全部隐藏范数及删去一个坐标后的平均平方范数具有固定阶负矩。输入范数的负矩则由

$$\mathbb{E}q_0^{-p}=\prod_{j=1}^p\frac{d}{d-2j}\leq 2^p\quad(d\geq 4p)$$

给出，此处先取整数 $p$，其余阶用矩单调性。 □

**引理 6** (带权符号变化估计)**.** *令 $W'=\sqrt{1-t}W+\sqrt{t}Z$，其中 $Z$ 为与 $(W,X)$ 独立的标准高斯矩阵族，$0<t\leq 1/2$，撇号表示第二个网络。固定一层 $\ell$，记 $D_\ell=\operatorname{diag}(\sigma'(u^{(\ell)}))$。给定两网络的前层变量，令本层对应预激活的夹角为 $\omega_\ell$，$q=q_{\ell-1}$。对前述任意范数多项式 $P$，存在只依赖前层的范数多项式 $P_<$，使*

$$\mathbb{E}[P\|(D_\ell'-D_\ell)\beta_\ell\|^2\mid\text{前层}]\leq C_PP_<(1+q)\omega_\ell.$$

*证明.* 逐单项把 $P$ 分为前层、本层和下游因子。给定本层输出 $h$，下游加权二阶矩 $M(h)=\mathbb{E}[P_>\beta_\ell\beta_\ell^T\mid h]$ 满足

$$M(h)_{ii}\leq C\left(k_\ell^{-1}+h_i^2/\|h\|^2\right). \tag{26}$$

事实上，同时右旋转下一层的 $W,Z$ 保持联合分布及范数，故 $M$ 正交等变。固定 $h$ 的正交变换使 $M=c_\perp(I-hh^T/\|h\|^2)+c_\parallel hh^T/\|h\|^2$；反向范数界给 $\operatorname{tr}M\leq C$，即得上式。终层直接用 $\beta_{L,i}^2=1/k_L$。

本层同时删去 $W, Z$ 的第 $i$ 行。算子范数不超过删行范数与该行归一化长度之和，所以本层因子至多为 $P_{\mathrm{del}}Q_i$，其中 $Q_i \le C(1+\|(W_i,Z_i)\|/\sqrt{k_{\ell-1}})^D$，$D$ 固定。又 $\|h\|^{-2} \le (\sum_{j\neq i} h_j^2)^{-1}$。给定前层，删行变量独立于第 $i$ 行；引理 5 及矩界给

$$\mathbb{E}[P_{\mathrm{del}} \mid \text{前层}] \le C, \qquad \mathbb{E}\left[\frac{P_{\mathrm{del}}}{\sum_{j\neq i} h_j^2}\middle| \text{前层}\right] \le C/k_\ell. \tag{27}$$

第二式由 Cauchy–Schwarz 和删行平均平方范数的二阶负矩得到。

第 $i$ 行两个预激活可写为 $u=\sqrt{q}G$、$u'=\sqrt{q'}(\cos\omega_\ell G+\sin\omega_\ell H)$。在联合行空间中先取这两个方向张成的平面；符号不同对应总角度 $2\omega_\ell$ 的扇区。上面的 $Q_i$ 上界为径向函数。极坐标积分及正交补上的高斯矩遂给

$$\mathbb{E}[Q_i \mathbf{1}_{uu'<0} \mid \text{前层}] \le C\omega_\ell, \qquad \mathbb{E}[Q_i h_i^2 \mathbf{1}_{uu'<0} \mid \text{前层}] \le C(1+q)\omega_\ell. \tag{28}$$

后一式使用 $h_i^2 \le C(1+qG^2)$，再用 $G^2 \le G^2+H^2$ 保持径向上界。由于 $|\sigma'(u')-\sigma'(u)|^2 = 4b^2\mathbf{1}_{uu'<0}$，合并上述三式并对 $i$ 求和即得结论。这里保留了反向导数与本层符号的依赖。 □

### *A.4* 分段线性网络的梯度变化

**引理 7.** 对同一 *OU* 耦合及任意范数多项式 $P$，分段线性支满足

$$\mathbb{E}[P\|\nabla F(W',X)-\nabla F(W,X)\|^2] \le C_P\sqrt{t}.$$

常数和维数阈值不依赖 $0<t\le 1/2$。

证明. 归一化矩阵差及 Lipschitz 前向递推给出逐点界

$$\|A'_\ell - A_\ell\|_{\mathrm{op}} \le \sqrt{t}P, \qquad \|h'^{(\ell)}-h^{(\ell)}\|/\sqrt{k_\ell} \le \sqrt{t}P.$$

给定前层 $h, h'$，本层预激活的相关系数为 $\sqrt{1-t}\langle h,h'\rangle/(\|h\|\|h'\|)$，故

$$\omega_\ell \le C\left(\sqrt{t}+\frac{\|h-h'\|}{\sqrt{\|h\|\|h'\|}}\right), \qquad \mathbb{E}[P_<\omega_\ell] \le C_{P_<}\sqrt{t}.$$

末式由前向差界、两边缘的负阶矩和 Hölder 得到；第一层 $h=h'=X$ 直接成立。引理 6 因而给出

$$\mathbb{E}[P\|(D'_\ell - D_\ell)\beta_\ell\|^2] \le C_P\sqrt{t}. \tag{29}$$

从相同读出开始，使用精确递推

$$\lambda'_\ell-\lambda_\ell = D'_\ell(\beta'_\ell-\beta_\ell)+(D'_\ell-D_\ell)\beta_\ell, \qquad \beta'_{\ell-1}-\beta_{\ell-1} = A_\ell^T(\lambda'_\ell-\lambda_\ell)+(A'_\ell-A_\ell)^T\lambda'_\ell.$$

固定深度反向归纳给 $\mathbb{E}[P(\|\beta'_\ell-\beta_\ell\|^2+\|\lambda'_\ell-\lambda_\ell\|^2)] \le C_P\sqrt{t}$：乘上算子范数只改变允许的 $P$，矩阵差项的平方为 $O(t)$。最后用梯度块公式 (A3) 作乘积差展开，结合前向差界即可。 □

### *A.5* *OU* 梯度变化与余项

**引理 8.** 令 $\delta=1$（光滑支）或 $\delta=1/2$（分段线性支）。对 $W(t)=\sqrt{1-t}W+\sqrt{t}Z$、$0<t\le 1/2$，有

$$G(t) := \mathbb{E}\|\nabla F(W(t),X)-\nabla F(W,X)\|^2 \le Ct^\delta,$$

$$R_t = F(W(t),X)-F(W,X)-\sqrt{t}\,DF(W,X)[Z], \qquad \mathbb{E}|R_t|^2 \le Ct^{1+\delta}.$$

常数和维数阈值不依赖 $t$。

证明. 记 $c_N$ 为对 $X$ 平均后的第 $N$ 阶参数 Hermite 能量，$a_t=\sqrt{1-t}$。正交性和 $\partial_i H_\nu=\sqrt{\nu_i}H_{\nu-e_i}$ 给

$$G(t)=2\sum_{N\ge 1}N(1-a_t^{N-1})c_N\le Ct^{\delta}.$$

光滑支用 $1-a_t^{N-1}\le Ct(N-1)$ 及 $\sum_N N(N-1)c_N=\mathbb{E}\|\nabla^2F\|_{\mathrm{HS}}^2\le C$；分段线性支用引理 7。取 $t=1-e^{-2\tau}$ 即得 (6)；$t>1/2$ 时由梯度二阶矩增大常数即可。同一正交展开（交叉项对 $Z$ 分部积分）给

$$\mathbb{E}|R_t|^2=\sum_{N\ge 1}\{2(1-a_t^N)+tN-2tNa_t^{N-1}\}c_N.$$

当 $N\ge 2$ 时 $a_t^N\ge 1-Nt/2$；当 $N=1$ 时大括号等于 $(1-a_t)^2\le t^2$。因此

$$\mathbb{E}|R_t|^2\le t^2\mathbb{E}\|\nabla F\|^2+tG(t)\le Ct^{1+\delta}. \tag{30}$$

计算先对有限 Hermite 和成立，再在高斯 Sobolev 范数下取极限。 □

### A.6 高斯分部积分的定义域

**引理 9.** 设 $g:\mathbb{R}^p\to\mathbb{R}^p$ 属于高斯 $W^{1,2}$，也允许值域带独立的外部 $L^2$ 变量。定义 $\delta g=\operatorname{div} g-W\cdot g$。则其闭扩张满足

$$\mathbb{E}(\delta g)^2=\mathbb{E}\|g\|^2+\mathbb{E}\sum_{i,j}(\partial_i g_j)(\partial_j g_i)\le\mathbb{E}\{\|g\|^2+\|Dg\|_{\mathrm{HS}}^2\}. \tag{A13}$$

证明. 先取紧支撑光滑场。对高斯密度逐坐标分部积分两次，利用 $\partial_i(W_jg_j)=\mathbf{1}_{i=j}g_j+W_j\partial_i g_j$，交叉项合并后正好得到等式；导数和中每项用 $2uv\le u^2+v^2$ 给出不等式。一般情形先用径向截断 $\chi_R$，其中 $0\le\chi_R\le 1$、球内等于一、$\|\nabla\chi_R\|_\infty\le C/R$，再在紧集上卷积。高斯密度在紧集上光滑且有正上下界，因此普通卷积逼近同时给出高斯 $W^{1,2}$ 逼近。尾部由 $g,Dg$ 的平方可积性控制，截断导数项由 $C\|g\|/R$ 控制。故有紧支撑光滑场序列在该 Sobolev 范数收敛；不等式保证其散度在 $L^2$ 中 Cauchy，并识别为分布散度。等式也由该收敛保留。对外部变量先用简单函数逼近并积分，证明不变。 □

上述散度不等式用于附录 G 的正则化测试场。该场只依赖参数和独立测试输入；训练及辅助高斯观测的得分项另行处理。

## B 对称张量的 *Gram* 矩阵界

固定整数 $m\ge 5$、$q\ge 1$。设单位行 $w_1,\dots,w_k$ 满足 $\max_{i\ne j}|\langle w_i,w_j\rangle|\le\delta$。对多重指标 $r\in\mathbb{N}^k$、$|r|=q$，定义

$$P_r=\operatorname{Sym}\bigotimes_j w_j^{\otimes mr_j},\qquad Z_{r,i}=\operatorname{Sym}\bigotimes_j w_j^{\otimes(mr_j-\mathbf{1}_{j=i})},\quad r_i>0.$$

Sym 是全部槽位排列的平均，范数取继承的 Hilbert 张量范数。令 $\mathcal{F}$、$\mathcal{F}^-$ 分别以 $P_r$、$Z_{r,i}$ 为列。则

$$cI\preceq\mathcal{F}^*\mathcal{F}\preceq CI,\qquad cI\preceq(\mathcal{F}^-)^*\mathcal{F}^-\preceq CI, \tag{31}$$

只要 $\delta+\sum_{h=1}^{q}k^h\delta^{mh-2}=o(1)$；$c,C>0$ 只依赖 $m,q$。

证明使用精确配对公式

$$\left\langle\operatorname{Sym}\bigotimes_{a=1}^{R}u_a,\operatorname{Sym}\bigotimes_{a=1}^{R}v_a\right\rangle=\frac{1}{R!}\sum_{\pi\in\mathfrak{S}_R}\prod_a\langle u_a,v_{\pi(a)}\rangle.$$

若列的标签重数为 $(n_j)$，对角中的无错配项为 $\prod_j n_j!/R!$，它有只依赖固定总次数的正下界；其余对角项为 $O(\delta)$。纯列的重数为 $mr$，删除列的重数为 $mr-e_i$。两族内部不同列具有不同重数，后者因模 $m$ 的余数唯一确定 $i$。同一有限支撑内的非对角项至少含一个错配，故为 $O(\delta)$，此类列的数量有固定上界。若另一列含 $h\ge 1$ 个新标签，它至少有 $mh-1$ 个槽必须与不同标签配对，故内积至多 $C\delta^{mh-2}$；这样的列至多 $Ck^h$ 个。因此每个 Gram 矩阵与上述正对角矩阵之差的绝对行和至多 $C(\delta+\sum_h k^h\delta^{mh-2})=o(1)$。对称矩阵的 Schur 界即得 (31)。

行长在固定正区间时，各列只乘有固定上下界的标量，结论不变。对按输入宽度归一化的高斯行，行长一致趋于一且 $\delta=O(\sqrt{\log d/d})$、$k\asymp d$，故扰动趋零；事件补集概率可取任意固定负幂。

## C 计算树展开的张量估计

本节估计计算树展开所产生的系数张量。所有空间取实 Euclidean 空间及其 Hilbert 张量积；$\|\cdot\|_{\mathrm{HS}}$ 表示张量 Hilbert 范数，$\mathrm{Flat}_{S|S^c}$ 表示按索引位置分组的矩阵化。下文的一个模式是系数张量的一个索引位置；不同模式可以取相同数值，也可以由同一个原节点索引复制得到。各层宽度在 $[cd, Cd]$ 内，深度、多项式次数、涉及的层数和操作次数均固定。记 $\delta_d = L_d/\sqrt{d}$、$\rho_d = L_d/d$，其中 $L_d$ 是可随有限次运算增大的固定对数幂。概率估计分别在每个网络的高斯边缘下建立；相应事件成立后，以下估计对两网络间任意耦合均成立。

### C.1 系数张量的范数界与线性求和

计算树的系数张量。 从原网络的归一化读出向量开始，按原计算树自上而下展开。每个当前模式代表一个原节点的指标，模式 $p$ 的一次展开为

$$Je_a = \bigotimes_{t=1}^{q} u_a^{(t)}, \qquad q \ge 1, \qquad \|U_t\|_{\mathrm{op}} \le C, \quad U_t = (u_a^{(t)})_a. \tag{32}$$

因子 $e_a$ 表示保留父索引。也可在某节点停止展开，保留该节点以下的整个张量映射。同一父索引产生的多个因子仍共享该索引。依赖两网络的映射只能作用在停止展开的叶节点上，每个映射输出一个张量因子；输出多个因子的非线性映射须先按原计算树展开并纳入系数张量。

引理（展开算子的范数）。 把上述展开作用于全部保留因子的复合映射称为展开算子。任意固定次数的此类复合均有界。具体地，令 $\Delta_q e_a = e_a^{\otimes q}$，则 $J = (\bigotimes_t U_t^*)\Delta_q$，而 $\Delta_q$ 为等距嵌入，故 $\|J\| \le \prod_t \|U_t\|$。同样，若 $F_j : e_a \mapsto f_a^{(j)}$ 有界，则共享指标的乘积特征 $e_a \mapsto \bigotimes_j f_a^{(j)}$ 有界。也可从 Gram 矩阵看出：其 Gram 为 $\circ_j F_j^* F_j$，且对半正定矩阵 $X \preceq bI, Y \succeq 0$，$X \circ Y \preceq b\,\mathrm{diag}(Y)$。

引理（展开保持范数和切片界）。 设 $E$ 有 $r$ 个模式，满足

$$\|E\|_{\mathrm{HS}} \le C, \qquad \max_{p,a} \|E(e_a \text{ 于模式} p, \cdot)\|_{\mathrm{HS}} \le \delta_d, \qquad \|\,\mathrm{Flat}_{S|S^c} E\|_{\mathrm{op}} \le \delta_d \quad (\varnothing \ne S \ne [r]). \tag{33}$$

除 $r = q = 1$ 外，一次展开保持这些结论，常数可增大固定倍数。

证明。 Hilbert 范数由展开算子有界立即得到。考虑新核的一个非平凡分割。若新产生的整个块在同一侧，该分割就是旧核的非平凡分割两侧复合有界算子。若新块跨越两侧，在两侧暂时保留正交父指标 $a$。中央算子按 $a$ 分块对角，每块为旧切片 $E(e_a, \cdot)$ 的某个矩阵化，算子范数至多其 Hilbert 范数 $\delta_d$。再施加两侧的行映射即得结论，包含旧核只有一个模式的情形。

除 $r = q = 1$ 外，新张量至少有两个索引；其坐标切片满足 $\|E_{\mathrm{new}}(e_a \text{ 于} p, \cdot)\|_{\mathrm{HS}} \le \|\,\mathrm{Flat}_{\{p\}|\{p\}^c} E_{\mathrm{new}}\|_{\mathrm{op}} \le C\delta_d$，故已由刚证明的矩阵化界控制。$r = q = 1$ 时没有非平凡矩阵化，仍须另用高斯连续乘积的坐标估计。□

高斯一元例外与原树实例。 令 $A_\ell$ 为独立、按输入宽度平方根归一化的高斯矩阵。任意固定连续积 $P = A_b \cdots A_a$ 满足

$$\|P\|_{\mathrm{op}} \le C, \qquad \max_{ij} |P_{ij}| \le C_M \sqrt{\log d / d} \tag{34}$$

且可使失败概率为 $O(d^{-M})$。算子范数由各层相乘得到；条件于 $Q = A_{b-1} \cdots A_a$ 后，$(A_b Q)_{ij}$ 是方差 $\|Qe_j\|^2/n_{b-1} \le C/d$ 的高斯变量，尾界与有限并合即得第二式。读出向量乘连续高斯积的坐标最大值也由条件于最后尚未暴露的高斯因子得到相同估计。于是首次分叉以前的 $r = q = 1$ 链可单独处理；首次分叉以后模式数不减，前一引理处理所有后续步骤。停止展开或施加恒等映射无须概率估计。有限原树核全部满足 (33)。这里的一元链仅由原网络矩阵组成。

外部映射及重建。 对系数张量的每个索引施加有界、输出一个因子的映射，保持所有非平凡矩阵化界，但不必保持坐标切片界。完成一次收缩后，应从原计算树重新构造系数张量：在对应父节点处停止展开，将已算出的跨网络收缩矩阵作为该叶节点的外部映射。不同深度均可停止展开，但根到叶的内部路径仍只含原网络矩阵。以下坐标切片估计始终用于这样重建的原系数张量。

引理（线性槽的精确压缩）。 令底层行向量为 $b_j$，父层矩阵为 $U=(u_{aj})$，并设 $z_a=\sum_j u_{aj}b_j$。一个父节点有 $t$ 个线性子槽以及次数 $q_1,\dots,q_h\ge 2$ 的非线性子槽，则其未对称化张量严格等于

$$z_a^{\otimes t}\otimes\bigotimes_{\ell=1}^{h}\left(\sum_j u_{aj}b_j^{\otimes q_\ell}\right). \tag{35}$$

证明。给每个有序子槽分配独立求和指标，再逐个使用多线性性；线性槽的求和正好是 $z_a$，非线性槽保留原式。固定次数的对称化为槽排列的平均，可在求和后施加。纯一元链因此是归一化矩阵的普通乘法，无额外 $\sqrt{\text{宽度}}$ 因子。式中的所有非线性因子仍共享 $a$，不得替换为独立阵列。坐标掩码一般不与此求和交换；必须先在全部张量因子的展开算子中证明掩码删除的误差为 $o(1)$，再恢复原张量并用本等式。 □

### C.2　同层索引的旋转与双索引收缩

概率工具。 若确定性矩阵 $A_j:\mathbb{R}^u\to\mathbb{R}^v$ 满足 $\max\{\|\sum_j A_jA_j^*\|,\|\sum_j A_j^*A_j\|\}\le s^2$，则独立标准高斯系数满足

$$\mathbb{P}\left(\left\|\sum_j g_jA_j\right\|>t\right)\le 2(u+v)\exp[-t^2/(2s^2)].$$

这是有限维矩阵高斯级数界。其自伴膨胀为 $H_j=\left(\begin{smallmatrix}0 & A_j^*\\ A_j & 0\end{smallmatrix}\right)$，$\|\sum_j H_j^2\|\le s^2$；矩阵高斯 Laplace 界 $\mathbb{E}\,\mathrm{tr}\exp(\lambda_{\mathrm{c}}\sum_j g_jH_j)\le \mathrm{tr}\exp(\lambda_{\mathrm{c}}^2\sum_j H_j^2/2)$ 配合 $\lambda_{\mathrm{c}}=t/s^2$ 得到上尾，对负号重复即得双侧界。以下只用其维数为固定 $d$ 次幂时的 $O(s\sqrt{\log d})$ 结论。

引理（同层旋转下的坐标切片）。 在同一原网络层，同时展开所有尚未停止的模式。选择当前高斯层矩阵的列索引所对应的模式 $p$：它随该层矩阵右乘正交矩阵而旋转，不包括保留的父索引 $e_a$ 或其确定性复制。再选不同模式 $q$；总模式数为 $N\ge 3$。令 $E$ 为尚未施加外部映射的系数张量。以任意高多项式概率有

$$\max_j\ \sup_{\|v\|\le 1}\|E(e_j\ \text{于}p,v\ \text{于}q,\cdot)\|_{\mathrm{HS}}\le\rho_d. \tag{36}$$

此时尚未展开更低层；在较高层停止展开的索引保持不动。

证明。条件于一个满足 (33) 的核，置 $A_jv=E(e_j,v,\cdot)$。直接按矩阵元素求和可知

$$\left\|\sum_j A_j^*A_j\right\|=\|\,\mathrm{Flat}_{\{q\}|\{q\}^c}E\|^2\le\delta_d^2,\qquad \left\|\sum_j A_jA_j^*\right\|=\|\,\mathrm{Flat}_{\{p,q\}|\{p,q\}^c}E\|^2\le\delta_d^2.$$

第二分割非平凡恰好使用 $N\ge 3$。前述级数界、$\|g\|\ge c\sqrt{d}$ 的高斯尾界，给均匀球面向量 $u=g/\|g\|$ 的收缩范数至多 $C_M\delta_d\sqrt{\log d/d}$。对独立 Haar 矩阵的各列作并合，不要求列独立。将当前高斯层矩阵右乘该正交矩阵不改变分布，并同时旋转对应其列索引的全部模式。未固定模式上的旋转是等距算子；若 $q$ 也对应该层的列索引，对 $v$ 的上确界仍不变。故 Haar 后的估计转回原坐标即为所需式。所有核和模式只有固定有限种。□

推论（重复坐标项的范数）。 若至少两个模式对应同一高斯层矩阵的列索引，且总模式数至少三，则其中至少两个索引取相同值的部分满足

$$\|E_{\mathrm{coll}}\|_{\mathrm{HS}}^2\le\sum_{p<q}\sum_j\|E(e_j\ \text{于}p,e_j\ \text{于}q,\cdot)\|^2\le Cd\rho_d^2=o(1). \tag{37}$$

在该层引入这些模式时先估计这一部分，再将误差通过有界的展开算子传递，最终误差仍为 $o(1)$。这里只删除不同原节点的索引恰取相同值的项；同一父索引的确定性复制仍须保留。

双父收缩与二阶非对角纤维。 在一个未加掩码的原始切口中，设不同父模式 $p,q$ 的所选线性槽与教师行收缩后给出 $\eta_i,\zeta_i$，其 $\ell^2$ 范数有界。模式 $p$ 是本层引入的模式，且删去所选槽后仍有非空残余；所有完整残余家族均为有界算子。若切口总模式数 $R\ge 3$，则完整剩余源张量 $S_i$ 满足

$$\|S_i\|_{\mathrm{HS}}\le C\rho_d.$$

令 $B_i e_b=\zeta_{ib}f_b$，其中 $f_b$ 是第二个源索引删除所选槽后的完整剩余特征；无剩余槽时取 $f_b=1$。逐点有 $\|B_i\|_{\mathrm{HS}}^2=\sum_b|\zeta_{ib}|^2\|f_b\|^2\le C$。将原始切片 $E(e_a,\cdot)$ 看作从 $q$ 索引到其余索引的算子 $T_a$。因 $R\ge 3$，式 (36)给 $\|T_a\|_{\mathrm{op}}\le\rho_d$，所以 $\|T_aB_i^*\|_{\mathrm{HS}}\le\|T_a\|_{\mathrm{op}}\|B_i\|_{\mathrm{HS}}\le C\rho_d$。保留第一个索引 $a$，乘 $\eta_{ia}$ 后平方求和，再施加完整剩余特征，得到 $\|S_i\|_{\mathrm{HS}}\le C\rho_d$。最终教师切片和至多 $C\sqrt{d}\|C\|$，故配对为 $O(\sqrt{d}\rho_d)\|C\|=o(1)$。这些界不要求 $B_i$ 与网络独立；两个所选索引须对应不同原始父节点。二阶切口只需另用非对角元估计。两个索引属于同一原网络层的二阶系数张量 $D$ 是固定次数高斯多项式，且 $\mathbb{E}\|D\|_{\mathrm{HS}}^2\le C$；置换不变性给 $\mathbb{E}|D_{ab}|^2\le C/d^2$ $(a\ne b)$。固定次数高斯超可积性给 $\|D_{ab}\|_{L^p}\le(p-1)^{D_0/2}\|D_{ab}\|_{L^2}$。取 $p=C_M\log d$ 并对 $O(d^2)$ 个元并合，得到 $\max_{a\ne b}|D_{ab}|\le L_d/d$，失败概率 $O(d^{-M})$。所需二阶矩由展开算子界及原高斯矩阵算子范数的固定阶矩得到。该结论不控制二阶对角，也不控制二阶坐标–向量切片。

双索引收缩要求两个不同原节点的索引；同一父节点产生的两个后代因子不满足该条件。总模式数为二时，式 (36) 中的第二个非平凡矩阵化不存在。若两个索引属于同一原网络层，仅其非对角部分使用上面的非对角元估计，对角部分另行处理。若两个索引来自不同层，则不能使用这一非对角元估计；后文通过保留根索引处理所需的这类二模式项。

推论（原始高阶碰撞的期望控制）。 设 $C_R$ 是固定深度、固定次数、零常数项高斯多项式网络的原始齐次系数，$R\ge 3$，允许固定有限个展开项的和。则每个固定 $p<\infty$ 均有 $\sup_d\mathbb{E}\|C_R\|_{\mathrm{HS}}^p<\infty$，并且 $\mathbb{E}\|\operatorname{Coll}_R C_R\|_{\mathrm{HS}}^2=o(1)$。为证矩界，把每个展开项写成有限个计算树展开算子及槽排列的和。其范数至多固定常数乘有限个原高斯矩阵算子范数的固定幂；归一化高斯矩阵在固定宽比下有维数一致的任意固定阶矩。因此 Hölder 不等式给所述界，不需层间乘积各因子独立。对索引属于同一原网络层的系数张量，首个输入高斯层赋予正交不变性，同层旋转引理 C.2及碰撞推论给任意 $M$ 的事件 $\Omega_M$，其补集概率 $O(d^{-M})$，而事件内碰撞平方范数至多 $L_d/d$。故

$$\mathbb{E}\|\operatorname{Coll}_R C_R\|^2\le L_d/d+(\mathbb{E}\|C_R\|^4)^{1/2}\mathbb{P}(\Omega_M^{\mathrm{c}})^{1/2}=o(1).$$

对称化只含固定有限个排列，有限个展开项的和由三角不等式处理。

### C.3　完整余张量的统一局部收缩

未收缩因子的矩阵化界。 设 $F_a=\sum_b U_{ab}Q_b$，其中 $U$ 是原高斯层或固定连续积，$Q_b$ 为正次数计算树展开项；不同高度的停止展开的叶节点允许任意有界自适应单槽映射。完整家族 $e_a\mapsto F_a$ 有界。若 $F_a$ 至少有两个张量因子位置，则其每个非平凡对输出因子的矩阵化至多 $C\delta_d$，同时对所有 $a$ 成立：以 $U_{a,:}$ 为读出重建裸核，式 (34) 给读出的范数与最大坐标，展开保持范数和切片界的引理给矩阵化界，最后的单槽映射保持这些界。家族有界性来自展开算子与 $U^*$ 的复合。单槽收缩因子同样是有界家族，不需要非平凡矩阵化估计。同指标乘积家族由对角嵌入保持有界。以上不对自适应叶映射作独立性或坐标切片保持性假设。

**引理 10** (完整余张量的局部收缩)**.** 固定一个教师叶及其所命中的源列，所有未消费张量因子位置始终保留。教师叶含 $m\ge 2$ 个张量因子位置。教师行矩阵和源完整家族有界；其他源列按各自标签分别施加展开算子，且不额外依赖所选列标签。教师系数为 $C$，源系数为 $D$（一模时记为 $d$）。设该叶接触源列中的一个收缩因子 $\ell_a$，其交叉矩阵 $G_{ia}=\langle a_i,\ell_a\rangle$ 满足 $\max|G|\le\kappa_d$ 及 $\sup_i\|G_{i,:}\|_2\le C$。该列的其他因子为上段的原始残余或单槽收缩因子。则有下列三个完整配对界：

1. 若本教师叶还命中另一源列，则界为 $C\kappa_d\|C\|\|D\|$。
2. 若本叶全部位于该列，重建源核心有 $R\ge 2$ 个模式，且 $\|\operatorname{Flat}_{1|\mathrm{rest}}D\|\le\delta_d$，则界为 $C\sqrt{d}\,\delta_d(\delta_d+\kappa_d)\|C\|$。
3. 若本叶全部位于该列，核心只有一个模式 $d_a$，$\|d\|_\infty\le\kappa_d$，且除指定收缩因子外至少有两个完整因子，则界为 $C\sqrt{d}\,\kappa_d(\delta_d+\kappa_d)\|C\|$。

各界在 $\delta_d,\kappa_d\le L_d/\sqrt{d}$ 时均为 $o(1)$。一模仅一个残余因子不在本引理第三项内。

证明. 第一项先保留源标签 $a$，从其他列取本教师叶命中的全部 $t \geq 1$ 个槽。映射 $x \mapsto (\langle a_i^{\otimes t}, x\rangle)_i$ 有界，因为其伴随为 $(A^*)^{\otimes t}\Delta_t$。保留所得正交标签 $i$ 后，乘以 $G_{ia}$ 的范数至多 $\kappa_d$。随后在每个 $i$ 块内提升本列剩余家族，收缩本叶余槽，并分析其余教师叶。这是从完整源系数到完整教师系数的有界算子复合，故没有逐 $i$ 求和或部分迹损失。

以下考虑本叶全部位于该列。固定 $i$，按本叶如何消费各残余因子，分为全消费、部分消费、全在外。全消费因子产生 $\ell^2$ 有界向量 $\eta$；部分消费因子产生逐列范数至多 $C\delta_d$ 的有界家族；全在外家族仍有界。记本列收缩后算子为 $B_i$。若存在部分消费因子，则 $\|B_i\|_{\mathrm{HS}}^2 \leq C\delta_d^2 \sum_a |G_{ia}|^2$。否则至少一个因子全消费，故 $\|B_i\|_{\mathrm{HS}}^2 \leq C\kappa_d^2 \sum_a |\eta_a|^2$。于是 $\|B_i\|_{\mathrm{HS}} \leq C(\delta_d + \kappa_d)$。对第二项，其他源模式的展开算子记为 $T$，Hilbert–Schmidt 理想不等式给

$$\|(B_i \otimes T)D\|_{\mathrm{HS}} \leq \|T\|\,\|B_i\|_{\mathrm{HS}}\|\,\mathrm{Flat}_{1|\mathrm{rest}}\, D\|_{\mathrm{op}} \leq C\delta_d(\delta_d + \kappa_d).$$

对第三项，记收缩后的家族为 $H_j$，完全收缩者取值于 $\mathbb{R}$。若有部分收缩因子 $H_u$，其 Gram 对角元至多 $C\delta_d^2$；选任意 $j \neq u$，由 $H_j^* H_j \preceq CI$ 和 Schur 乘积半正定序，整个乘积家族的算子范数至多 $C\delta_d$。因此 $\|S_i\| \leq C\delta_d \|(d_a G_{ia})_a\|_2 \leq C\kappa_d\delta_d$。若无部分收缩，至少一个因子完全收缩为 $\ell^2$ 有界向量 $\eta$；将它移入系数后，$\|(d_a G_{ia}\eta_a)_a\|_2 \leq C\kappa_d^2$，其余至少一个家族的乘积有界。两种情况均给 $\|S_i\| \leq C\kappa_d(\delta_d + \kappa_d)$。最后只需一次 $\sum_i \|C(e_i, \cdot)\| \leq C\sqrt{d}\|C\|$，即得第二、三项。 □

二阶源矩阵若先限制到非对角，可分别处理 $D$ 与 $\mathrm{diag}\, D$，因为后者的算子范数及 Hilbert 范数不增；这里没有将其对角宣称为小量。其他掩码不能据此处理。系数只有一个索引且只剩一个因子的情形，在下段通过保留根索引处理。

保留根索引的二阶情形。 若系数只有一个索引，且除指定收缩因子外只剩一个因子，前一引理的第三项不适用。此时从 $E_{ab} = d_a U_{ab}$ 开始，保留索引 $a$，只展开后代索引。由展开保持范数和切片界的引理，重建后的系数张量至少有两个模式，所有非平凡矩阵化均为 $O(\delta_d)$；根处的收缩因子作为外部的单因子映射保留。若后代具有按原父索引分开表示的完整特征，可用引理 10；若本次展开涉及两个不同的后代索引，加上 $a$ 后总模式数至少三，可用引理 C.2。整个过程中不对 $a$ 求迹。相应的因子分解将在第 E 节中构造。

## D 实际激活的输入混沌投影与多项式近似

本节证明实际网络的第 $N$ 阶输入混沌可由有限个多项式网络的系数逼近。所有误差先在单个网络的先验下估计，最后再用于任意先验边缘耦合。令 $k_0 = d$，$L$ 固定，且 $cd \leq k_\ell \leq Cd$。写 $A_\ell = W^{(\ell)}/\sqrt{k_{\ell-1}}$，$W^{(\ell)}$ 的元素独立服从 $N(0,1)$，各层独立；$X \sim N(0, I_d)$ 独立于权重。定义

$$h^{(0)} = X, \quad h^{(\ell)} = \sigma(A_\ell h^{(\ell-1)}), \quad q_\ell = k_\ell^{-1}\|h^{(\ell)}\|^2, \qquad F_L := F_{\theta(W)}^{(L)} = k_L^{-1/2} \sum_i h_i^{(L)}.$$

激活满足 $\mathbb{E}\sigma(G) = 0$、$\mathbb{E}\sigma(G)^2 = 1$，并取以下之一：有界光滑奇函数（每个固定阶导数有界），或

$$\sigma(z) = az + b(|z| - u), \qquad u = \sqrt{2/\pi}, \qquad a^2 + b^2(1 - u^2) = 1. \tag{38}$$

记 $\psi_j = \mathrm{He}_j/\sqrt{j!}$，$a_j = \mathbb{E}[\sigma(G)\psi_j(G)]$，$b_j = \mathbb{E}[(\sigma(G)^2 - 1)\psi_j(G)]$。$\Pi_N$ 表示输入 $X$ 的第 $N$ 阶正交混沌投影；对称张量约定为

$$\mathbb{E}_X I_N(T) I_N(S) = N!\langle T, S\rangle. \tag{39}$$

特别地，下文的“形式次数为 $N$ 的系数再取 $I_N$”，不等于先计算整个多项式网络的函数值再作 $\Pi_N$。后者还包含更高形式次数经高斯收缩得到的第 $N$ 阶项。

局部矩估计。 以下估计均只涉及单网络边缘分布。这些结论分别由定理 3、条件行估计 A1 及 4 中的高斯矩阵网格尾界证明。对固定层数、固定 $p < \infty$，有

$$\|q_\ell - 1\|_{L^p(W,X)} \leq C_p d^{-1/2}, \quad \sup_{d,\ell,i} \mathbb{E}|h_i^{(\ell)}|^p < \infty, \quad \sup_d \mathbb{E}\|A_\ell\|_{\mathrm{op}}^p < \infty. \tag{40}$$

同样的矩界适用于固定多个神经元输出的乘积，允许神经元索引重复。从第一式和任意大的 $p$，$q_\ell \notin [1/2,2]$ 的概率可取任意多项式衰减。首层单位方向 $v_i = A_{1,i:}/\|A_{1,i:}\|$、半径 $s_i = \|A_{1,i:}\|$ 同时满足

$$\max_i |s_i - 1| + \max_{i\neq j} |\langle v_i, v_j\rangle| \le C_M\sqrt{\log d/d}, \qquad \|A_1\|_{\mathrm{op}} \le C_M \tag{41}$$

的失败概率至多 $d^{-M}$。这些结论也只涉及单个网络先验。证明分三步：截断条件 Hermite 展开，计算输出层的条件均值，再补回展开时删去的重复索引项。最后一步使用的多项式系数估计将在下文列出。

### *D.1* 首层激活乘积的输入混沌投影

固定 $t, N$，设 $v_1, \dots, v_t$ 为单位向量，$G = (\langle v_i, v_j\rangle)$，$\|G - I\| \le \eta$，$\max_i |s_i - 1| \le \delta$。则

$$\left\| \Pi_N \prod_{i=1}^{t} \sigma(s_i v_i \cdot X) - \sum_{\substack{n_i \ge 1 \\ \sum_i n_i = N}} \frac{\prod_i a_{n_i}}{\sqrt{\prod_i n_i!}} I_N\left(\mathrm{Sym} \bigotimes_i (s_i v_i)^{\otimes n_i}\right) \right\|_{L^2_X} \le C_{t,N}(\eta + \delta). \tag{42}$$

$t > N$ 时右侧的近似和为空。

证明如下。所有相关张量位于 $\mathrm{Sym}^N \mathrm{span}\{v_i\}$。用 $n_i \ge 0$、$\sum n_i = N$ 的 $B_n = I_N(\mathrm{Sym} \bigotimes_i v_i^{\otimes n_i})$ 作基。其 Gram 矩阵是 $G$ 的多项式，且在 $G = I$ 附近一致可逆：从标准正交基到 $v_i$ 的线性映射有一致有界的最大、最小奇异值，其固定对称张量幂也如此。投影的系数向量为此 Gram 矩阵的逆乘 $\mathbb{E}[\prod_i \sigma(s_i Z_i) B_n(Z; G)]$，其中 $Z \sim N(0, G)$。在 $G$ 的固定紧邻域内，对高斯密度关于协方差求导，得到一致可积的多项式乘高斯密度；$B_n$ 的系数也多项式依赖于 $G$。激活至多线性增长，故这些有限个积分关于 $G$ 局部 Lipschitz。关于 $s_i$ 的 Lipschitz 性来自 $\sigma$ 的 Lipschitz 性和高斯加权矩。在 $G = I, s_i = 1$，独立性给出系数 $\prod_i a_{n_i}/\sqrt{\prod_i n_i!}$；$a_0 = 0$ 去掉所有零次数。最后把 $v_i^{\otimes n_i}$ 改回 $(s_i v_i)^{\otimes n_i}$ 只产生 $O(\delta)$。有限维范数等价证明 (42)。这个证明对完整非多项式乘积积分，因此已包括高阶 Hermite 项和非正交方向引起的所有收缩项。

### *D.2* 条件 *Hermite* 展开的截断与误差

本小节先从网络输出中减去给定前层输出后的条件均值，记所得函数为 $F_+$；条件均值将在下一小节单独处理。给定前层特征 $h \in \mathbb{R}^k$，$q = \|h\|^2/k$，当前行预激活为 $W_i \cdot h/\sqrt{k}$。对 $q > 0$ 写

$$\sigma(\sqrt{q}G) = \sum_{r\ge 0} c_r(q)\psi_r(G), \qquad c_r(q) = \mathbb{E}\sigma(\sqrt{q}G)\psi_r(G).$$

多元 Hermite 加法公式为

$$\psi_r(W_i \cdot h/\|h\|) = \sum_{|\alpha|=r} \sqrt{\frac{r!}{\alpha!}} (h/\|h\|)^\alpha \prod_j \psi_{\alpha_j}(W_{ij}). \tag{43}$$

$q = 0$ 按连续的实际随机变量取值，不引入 $q^{-1}$ 的矩。

对本节出现的有限函数集 $f \in \{\sigma, \chi = \sigma^2 - 1\}$，其中 $\chi$ 只用作分段线性网络的输出层函数，均有 $|f(x)| \le C(1 + |x|^2)$。映射 $q \mapsto f(\sqrt{q}\,\cdot)$ 在 $[1/2, 2]$ 上为 $L^2(\gamma)$ 连续，故其 Hermite 投影尾在此紧区间上一致趋零。在区间外，投影的 $L^2$ 范数不超过完整函数，条件二阶矩至多 $C(1 + q^2)$；式 (40) 给任意高阶的 $q$ 矩和区间外概率，从而区间外误差趋零。固定多个不同神经元输出的乘积也可截断：条件于前层，相应权重行独立，逐因子写差后，每项的条件平方期望等于一个尾的平方期望乘其余因子的条件二阶矩。在紧区间上用一致尾界，区间外用上述多项式矩界即可，不需要单行尾的高阶 $L^p$ 收敛。从输出层向输入层依次选择截断阶数；每次所需处理的神经元数已经固定。

固定保留次数 $r$，令 $c_r^f(q) = \mathbb{E} f(\sqrt{q}G)\psi_r(G)$。将积分变量换成 $y = \sqrt{q}G$ 后，可对高斯密度和 $\psi_r(y/\sqrt{q})$ 求导；在 $[1/2, 2]$ 上导数由可积高斯多项式控制。故 $c_r^f(q) q^{-r/2}$ 局部 Lipschitz，可替换为 $c_r^f(1)$，误差由 $\|q - 1\|_{L^p} = O(d^{-1/2})$ 控制。区间外，精确有限分量的条件固定阶矩由高斯 Hermite 矩界控制，系数是 $c_r^f(q)$，没有逆方差；替换后的固定多项式由实际特征矩控制。Hölder 不等式与任意高阶区间外概率使误差趋零。此论证从不使用负阶 $q$ 矩，也不要求分段线性 $f$ 可微。

接着删去每层展开中重复使用前层神经元索引的项。此时关于当前权重的系数仍是多元 Hermite 多项式，前层输出仍是实际激活函数。若一个展开项含 $T$ 个前层输出因子，其中至少两个索引相同的赋值至多有 $C_T k^{T-1}$ 个；系数的平方归一化因子为 $k^{-T}$。由权重 Hermite 多项式的正交性和前层输出乘积的矩界，这些项的总平方误差为 $O_T(k^{-1})$。不同排序若对应同一组权重变量，先将它们合并；重数只依赖固定的 $T$。剩余各项的每个权重变量只出现一次，故其 Hermite 多项式等于普通权重乘积。分段线性激活的零阶系数 $c_0(q) = bu(\sqrt{q} - 1)$ 在每个固定 $L^p$ 中为 $O(d^{-1/2})$。对输出层以下的固定乘积，上述乘积估计允许删去含零阶系数的项；输出层的零阶项带有读出求和，须另行计算。

为说明这些局部误差不会被宽度放大，将某阶段的整个误差写为

$$\Delta = \sum_g \beta_g \Psi_g(W_{>\ell}) E_g(W_{\le \ell}, X), \qquad \sum_g \beta_g^2 \le C_{\text{fixed}}. \tag{44}$$

这里 $\Psi_g$ 是上方已展开各层的权重单项式，每个权重变量的次数均为一；相同单项式对应的项先合并。不同 $\Psi_g$ 在高斯权重下正交，且均与 $E_g$ 所依赖的下层权重及输入独立。每个权重归一化因子为相应输入宽度的 $-1/2$ 次幂，输出读出因子为 $k_L^{-1/2}$。对输出索引和各个自由的下层索引求和，这些因子的平方恰好抵消索引数目，只留下依赖固定展开结构和次数的常数。这证明系数平方和有界，并给出

$$\mathbb{E}\|\Delta\|_{L_X^2}^2 \le C_{\text{fixed}} \sup_g \mathbb{E}\|E_g\|_{L_X^2}^2. \tag{45}$$

对应同一上层权重单项式的全部下层误差合并为一个 $E_g$；上述正交性仅用于不同单项式之间。固定 $\eta_{\text{cut}} > 0$ 后，从输出层向输入层依次选择有限截断，得到每层神经元索引均互异的展开项之和 $F_{+,\eta_{\text{cut}}}$，且

$$\limsup_d \mathbb{E}\|F_+ - F_{+,\eta_{\text{cut}}}\|_{L_X^2}^2 \le C_L \eta_{\text{cut}}^2. \tag{46}$$

以上截断、径向系数替换和重复索引项删除的误差，均在单网络边缘分布下估计。

首层保留实际激活函数，并应用(42)。对每个固定的首层神经元数，(41) 使其误差趋零；利用 (45) 对不同权重单项式求平方和，避免逐项使用三角不等式。在首层好事件补集上，固定次数多项式矩及实际固定乘积矩至多有固定多项式维数增长，可选足够大的失败指数使贡献趋零。若某个展开节点的次数大于 $N$，它就包含超过 $N$ 棵不同子树。每棵子树至少保留一个首层输出，且这些输出的索引互异。因此该项含超过 $N$ 个首层激活因子，式 (42) 的近似和为空。所以各层截断阶数达到 $N$ 后，贡献于最终近似的项不再增加。先固定各层截断并令 $d \to \infty$，再令 $\eta_{\text{cut}} \to 0$，得到同一个有限多项式表达式。

### *D.3* 输出层条件均值与逐层递推

固定 $N > 2$，定义零常数多项式

$$P_N(z) = \sum_{j=1}^N \frac{a_j}{\sqrt{j!}} z^j, \qquad Q_N(z) = \sum_{j=1}^N \frac{b_j}{\sqrt{j!}} z^j. \tag{47}$$

使用网络原有的矩阵 $A_1, \dots, A_t$ 和读出 $k_t^{-1/2}\mathbf{1}$，令输出层激活多项式为 $A$，下层依次为 $p_1, \dots, p_{t-1}$。取该网络的形式 $N$ 次对称系数并施加 $I_N$，所得函数记为 $R_{t,N}[A; p]$。若在展开中只保留每个隐藏层的全部索引互异的项，再作同样操作，记为 $J_{t,N}[A; p]$。这里不限制输入坐标是否重复，故 $J_{1,N} = R_{1,N}$。下文 ; $P_N$ 表示所有下层均用 $P_N$。这些定义也适用于固定辅助变量的系数。

令 $F_t^f = k_t^{-1/2} \sum_i f((A_t h^{(t-1)})_i)$，并令 $F_{t,+}^f$ 表示从 $F_t^f$ 中减去给定前层输出后的条件均值。它恰好保留输出层权重的正阶 Hermite 项。由上述截断、权重单项式的正交性及截断达到 $N$ 后的稳定性，

$$\Pi_N F_{t,+}^f = J_{t,N}[H_f; P_N] + o_{L^2(W,X)}(1), \qquad H_\sigma = P_N, \quad H_\chi = Q_N. \tag{48}$$

这里 $\chi$ 只用于分段线性分支。深度一没有可用于上述正交估计的更高层权重，直接估计如下：$f = \sigma, \chi$ 满足 $|f(sx) - f(tx)| \le C|s - t|(|x| + x^2)$ $(s, t \in [1/2, 2])$，故 $\mathbb{E}[f(sG)\psi_N(G)]$ 对 $s$ 局部 Lipschitz。以其 $s = 1$ 值乘 $s^N$ 替换的逐行误差为 $O(\max_i |s_i - 1|)$；映射 $e_i \mapsto v_i^{\otimes N}$ 有界，因为其 Gram 绝对行和至多 $\sum_j |\langle v_i, v_j\rangle|^2 \le \|V\|_{\text{op}}^2$。归一化读出范数为一，故首层激活求和的误差也趋零；坏事件的贡献由固定矩和任意高阶概率界控制。

分段线性支有下列对所有 $q \geq 0$ 成立的精确恒等式：

$$\mathbb{E} f(\sqrt{q}G) = \lambda_f(q-1) + c_f(\sqrt{q}-1)^2, \quad (\lambda_\sigma, c_\sigma) = (bu/2, -bu/2), \qquad (\lambda_\chi, c_\chi) = (1, b^2u^2). \tag{49}$$

由 $|\sqrt{q}-1| \leq |q-1|$ 及四阶局部矩，乘 $\sqrt{k_t}$ 后的二次余项为 $O_{L^2}(d^{-1/2})$。又 $F^\chi_{t-1} = \sqrt{k_{t-1}}(q_{t-1}-1)$，所以

$$\Pi_N F^f_t = J_{t,N}[H_f; P_N] + \lambda_f \sqrt{k_t/k_{t-1}}\, \Pi_N F^\chi_{t-1} + o_{L^2}(1), \qquad t \geq 2. \tag{50}$$

$t=1$ 时直接有 $\Pi_N F^f_1 = R_{1,N}[H_f] + o_{L^2}(1)$：条件均值的线性项为 $\lambda_f\sqrt{k_1}(q_0-1)$，它属于输入二阶混沌，故被 $N>2$ 投影精确消去；二次余项仍为 $o(1)$。这也证明 (48) 的深度一版本。奇分支所有条件均值为零，只需 $f=\sigma$，递推中的第二项不存在。

### *D.4* 重复索引项与多项式近似公式

推论 C.2 给出：固定零常数多项式网络的完整 $r \geq 3$ 次系数满足

$$\mathbb{E}\| \operatorname{Coll}_r D_r\|^2_{\mathrm{HS}} = o(1), \qquad \sup_d \mathbb{E}\|D_r\|^p_{\mathrm{HS}} < \infty \quad (p<\infty). \tag{51}$$

这里 $\operatorname{Coll}_r$ 保留至少两个坐标索引相同的张量项。此估计要求使用未删去任何索引项的系数，不能直接用于 $J$ 的系数。二阶对角须单独计算。

设输入宽度为 $k$ 的深度 $t$ 上部网络各层多项式为 $p_j(z) = \sum_{r\geq 1} g_{j,r} z^r$。其全二次系数满足

$$\mathbb{E}\left\| \operatorname{Diag} D_2 - \lambda I_k/\sqrt{k} \right\|^2_{\mathrm{HS}} = O(k^{-1}), \qquad \lambda = g_{t,2}\prod_{j<t} g^2_{j,1}\sqrt{k_t/k}. \tag{52}$$

正次网络的二次项恰有一个二次节点。若在第 $j$ 层，去掉固定标量后的系数为 $D_2^{(j)} = B_j^T \operatorname{diag}(v_j) B_j$，其中 $B_j = A_j \cdots A_1$、$v_j = A^T_{j+1}\cdots A^T_t \mathbf{1}/\sqrt{k_t}$。写 $B_j = C_j A_1$、$H_j = C_j^T \operatorname{diag}(v_j) C_j$。条件于 $H_j$，$A_1$ 各列为独立 $N(0, I/k)$，故

$$\mathbb{E}(D_2^{(j)})_{ii} = \operatorname{tr} H_j/k, \qquad \mathbb{E}\sum_i |(D_2^{(j)})_{ii} - \operatorname{tr} H_j/k|^2 = 2\|H_j\|^2_{\mathrm{HS}}/k.$$

$\|H_j\|_{\mathrm{HS}} \leq \|C_j\|^2_{\mathrm{op}}\|v_j\|$ 与固定矩界控制后式。$j<t$ 时 $v_j$ 独立于 $C_j$，均值零、协方差 $I/k_j$，从而 $\mathbb{E}|\operatorname{tr} H_j|^2 = k_j^{-1}\mathbb{E}\sum_a \|C_{j,a:}\|^4 = O(1)$，标量对角平方范数亦为 $O(k^{-1})$。$j=t$ 时 $\operatorname{tr} H_t = \|C_t\|^2_F/\sqrt{k_t}$，均值为 $\sqrt{k_t}$，且 $\operatorname{Var}\|C_t\|^2_F = O(1)$：沿固定长度乘积逐层使用

$$\mathbb{E}(\|AC\|^2_F \mid C) = \frac{k_{\mathrm{new}}}{k_{\mathrm{old}}}\|C\|^2_F, \qquad \operatorname{Var}(\|AC\|^2_F \mid C) = \frac{2k_{\mathrm{new}}}{k^2_{\mathrm{old}}}\|CC^T\|^2_{\mathrm{HS}} = O_{L^1}(1)$$

及全方差公式即可。因此只有输出层的二次节点贡献非消失的确定对角项。乘回固定标量后得到(52)；辅助标记取系数不改变证明。

**引理 11** (去掉索引互异限制)**.** *对任意固定、常数项为零的输出层多项式 $A$，有*

$$J_{t,N}[A;p] = R_{t,N}[A;p] - \sum_{s=1}^{t-1} \lambda_{t,s}(A)\, J_{s,N}[p_s^2; p_{<s}] + o_{L^2}(1), \qquad \lambda_{t,s}(A) = [A]_2 \prod_{j=s+1}^{t-1} [p_j]_1^2 \sqrt{k_t/k_s}. \tag{53}$$

*其中 $[A]_2$ 和 $[p_j]_1$ 分别表示二次项和一次项的系数。所有确定性系数在固定宽比下有界。*

*证明.* 从第 $t-1$ 层开始向下，依次去掉 $J_{t,N}[A;p]$ 中的索引互异限制；新产生的修正项暂时保留其下层限制。处理第 $s$ 层时，其上方已经没有索引限制，故可对上方多项式的完整系数使用(51) 和 (52)。一次项没有重复索引，高于二次的重复索引项为 $o(1)$。二次项的确定对角部分代入 $y_i = p_s(z_i)$ 后为 $\lambda_{t,s}(A) k_s^{-1/2}\sum_i p_s(z_i)^2$。同一索引对应的两个因子在此精确相乘。第 $s$ 层以下的索引互异限制仍在，所以这项正是 $\lambda_{t,s}(A) J_{s,N}[p_s^2; p_{<s}]$。把各层补入的项移到等式右侧，得到(53)中的负号。

代入下层多项式所用的张量映射，其范数至多为固定个 $\|A_j\|_{\mathrm{op}}$ 的固定次幂；删除坐标项和对称化均不增加 Hilbert 范数。固定次数高斯多项式的矩等价、Hölder 不等式与(39) 因而保证上述有限步中的误差之和仍为 $o_{L^2}(1)$。每一步都只对没有索引限制的上方多项式系数使用重复索引估计。 □

二次修正项的消去。 式 (53)中的系数满足

$$\lambda_{t,s}(A) = \lambda_{t,t-1}(A)\lambda_{t-1,s}(p_{t-1}^2) \quad (s < t-1), \qquad [p_{t-1}^2]_2 = [p_{t-1}]_1^2.$$

把输出层多项式为 $p_{t-1}^2$ 的深度 $t-1$ 网络代入同一恒等式，即得

$$J_{t,N}[A;p] = R_{t,N}[A;p] - [A]_2\sqrt{k_t/k_{t-1}}\, R_{t-1,N}[p_{t-1}^2; p_{<t-1}] + o_{L^2}(1). \tag{54}$$

所有深度小于 $t-1$ 的修正项系数均精确抵消，只剩上式的一项；其余误差由前述张量映射估计控制。

对至多多项式增长的 $f$，高斯密度关于方差求导给 $\frac{d}{dq}\mathbb{E}f(\sqrt{q}G)|_{q=1} = \frac{1}{2}\mathbb{E}[f(G)(G^2-1)]$，所以 $[H_f]_2 = \lambda_f$ $(f = \sigma, \chi)$。将条件均值递推与上述系数恒等式合并，得到

$$\Pi_N F_t^f = R_{t,N}[H_f; P_N] + \lambda_f\sqrt{k_t/k_{t-1}}\big(\Pi_N F_{t-1}^\chi - R_{t-1,N}[P_N^2; P_N]\big) + o_{L^2}(1). \tag{55}$$

置 $U_N = [Q_N - P_N^2]_{\deg\le N}$，$E_t = \Pi_N F_t^\chi - R_{t,N}[P_N^2; P_N]$。由 $\lambda_\chi = 1$ 和深度一结论，

$$E_1 = R_{1,N}[U_N] + o_{L^2}(1), \qquad E_t = R_{t,N}[U_N; P_N] + \sqrt{k_t/k_{t-1}}E_{t-1} + o_{L^2}(1).$$

固定深度归纳，再将 $f = \sigma$ 代入(55)，得到

$$\mathcal{Q}_N = R_{L,N}[P_N; P_N] + \mu'\sum_{t=1}^{L-1}\sqrt{k_L/k_t}\, R_{t,N}[U_N; P_N], \qquad \mu' = bu/2, \tag{56}$$

以及

$$\boxed{\mathbb{E}_W\|\Pi_N F_L - \mathcal{Q}_N\|_{L^2_\chi}^2 \longrightarrow 0, \qquad N > 2.} \tag{57}$$

奇函数分支的条件均值为零，且各层展开的总次数为奇数，不出现二次对角项，故取 $\mu' = 0$，不需引入 $\chi$ 或 $E_t$。所有激活多项式均没有常数项；逐层代入不能降低形式次数，故可统一删去超过 $N$ 次的项。

任意先验边缘耦合。 若 $(W, W')$ 的两个边缘均为网络高斯先验，且 $\sup_d \mathbb{E}\|B(W)\|_2^2 < \infty$，则

$$\mathbb{E}|\langle B(W), \Pi_N F_{W'} - \mathcal{Q}_N(W')\rangle| \le (\mathbb{E}\|B(W)\|_2^2)^{1/2}(\mathbb{E}\|\Pi_N F_{W'} - \mathcal{Q}_N(W')\|_2^2)^{1/2} = o(1).$$

这里只用各自边缘的误差，不在耦合下额外假设层间独立。式 (56) 保留深度 $L$ 的完整多项式系数和每个较浅深度的 $U_N$ 修正项，下节将逐项比较它们与齐次网络的配对。

## E 计算树展开项的逐层比较

**先固定单项式和因子配对，再对所有选择求和**。本节固定深度 $L$、次数 $N = m^L$ 和比例宽度 $k_s \asymp d$。奇激活取奇数 $m \ge 5$；分段线性激活取偶数 $m \ge 6$。所有常数允许依赖这些固定参数。用 $K_d$ 表示一个固定的对数幂，令 $\delta_d = K_d/\sqrt{d}$、$\kappa_d = K_d/\sqrt{d}$。以下所有有限次数、高概率界均在源、教师各自的原始高斯边缘事件上成立；两个网络之间没有独立性假设。

在计算树的每个节点选择一个正次数单项式，并给孩子排序，便得到一个有序展开项。完全展开后，它包含 $N$ 个有序输入向量因子。先固定这些因子与比较张量中 $N$ 个因子的配对；全局对称化是在至多 $N!$ 种配对上取平均。各节点可选不同次数。不同节点使用的神经元索引即使数值相同，仍须与同一父索引的确定性复制区分。下文称齐次比较张量所在的网络为教师网络，称被比较展开项所在的网络为源网络；这些名称只区分配对两侧。

第 $h$ 步把每个已比较的高度 $h-1$ 子树视为一个当前因子；第 1 步的因子就是输入向量。每个待处理教师节点有 $m$ 个当前因子。收缩这 $m$ 个因子后，得到矩阵 $M_{ia}$，称为收缩因子：$a$ 是源节点索引，$i$ 是已处理教师子树的根索引，其值包含原展开的全部权重和归一化。它依赖已有权重，不是新引入的高斯边。本步得到的收缩因子先保留为输出，到下一步才参与后续收缩。

### *E.1* 剩余张量与最低非线性节点

**保留完整余张量**。教师当前原始齐次系数记作 $C$。完成的输出位置采用恒等映射，未完成位置采用有界齐次幂列映射。固定一个活动教师行 $i$ 后，其余全部输出因子的范数因此至多为 $K_d\|C(e_i,\cdot)\|_{\mathrm{HS}}$，而

$$\sum_i \|C(e_i,\cdot)\|_{\mathrm{HS}} \le \sqrt{k}\|C\|_{\mathrm{HS}} \le K_d\sqrt{d}. \tag{58}$$

跨网络收缩矩阵始终放在源侧；已经自适应收缩的教师张量不再被声称是新的原始齐次系数。

在源网络每个停止展开的节点处，把下方原子树和已算出的输出合为一个有界张量映射。高于停止层的每个收缩因子分别保留一个输出索引；同一源索引对应多个输出时，用恒等复制映射保留这些输出，而不删除它们的对角部分。在当前层须先保留原系数张量，再施加这些映射和复制，才能使用该层的右旋转估计。

**引理 12** (首次非线性节点的收缩)**.** *假定旧收缩因子在第一次活动使用之前，已对带有剩余因子的情形作完整余张量检验。若所有含两个活动源父位置的切口都已被相应解析估计排除，则每个存活的新教师叶收缩，恰好在一个原始源父节点消耗 $m$ 个完整、在当前变量中线性的原始孩子因子。*

*证明.* 给待完成教师叶的 $m$ 个源槽逐一作标记。按原始源高度递增推动这些标记，起点较高的标记暂时等待。标记在遇到第一个乘法分支之前，经过的表达式是原始归一化矩阵的连续乘积，末端接其已有收缩矩阵，故仍是有界行映射。删除一个选中线性因子后若没有显式保留的张量因子或留待下一步处理的输出，该父节点称为单因子节点。到达同一父节点的标记首先分组；两个标记同时到达的节点必然不是单因子节点。

若遇到的节点都是单因子节点，则精确求和其标签并沿原始线性路径继续。否则在最小高度的非单因子节点停止。到达这里的每个选中因子都是完整线性因子：若在其下方已穿过非线性分支，则应更早停止。若标记分布在至少两个父位置，选其中最低的非单因子位置作为本层引入的索引。较低的另一单路径推进到该高度；若它更早遇到分支，则改以该更早分支停止。较高活动旧收缩因子已经通过首次使用检验，因而不带剩余因子，不可能还是另一活动标记的祖先；本步新算出的收缩因子暂不参与后续收缩。由原始树重新构造共同切口，并按上文规则在本高度所有特征映射之前停止，便获得所需的本层引入的索引切口。

按假设，该混合父位置的情况被排除。因此全部标记在同一父节点相遇。如果其中两个标记来自同一个非线性原始孩子，它们在严格更低节点就已相遇并应停止，矛盾。所以它们来自 $m$ 个不同的完整原始孩子，且每个孩子关于当前因子为线性。 □

切口阶数至少三时，最低非单因子位置是本次展开引入的模式，删除一个选中线性槽后仍有非空残余，因此直接适用双父收缩估计 C.2。所有配对都在恢复后的原展开项上进行，包含相同数值标签，不再在本步骤插入碰撞掩码。每项完整余张量界为 $K_d/d$，与式 (58) 配对的误差为 $K_d/\sqrt{d} = o(1)$。

*完整收缩所得矩阵的范数。* 每次已经证明完整的 $m$ 因子收缩，其矩阵是 $m$ 个线性行核的逐项乘积。若核为 $\rho^{(j)}$，由各行各列的有界 $\ell^2$ 范数和 Hölder 不等式，

$$\sup_i \sum_a \left|\prod_{j=1}^m \rho_{ia}^{(j)}\right| + \sup_a \sum_i \left|\prod_{j=1}^m \rho_{ia}^{(j)}\right| \le K_d. \tag{59}$$

故所得矩阵 $M$ 的绝对行列和有界。下一教师原始高斯矩阵 $A$ 满足 $\max|A_{ij}| \le \kappa_d$，从而 $\max|AM| \le K_d\kappa_d$，即使 $M$ 依赖两个网络也成立。

### *E.2* 保留一个索引的二阶情形

**先处理其余子树，最后收缩索引 $a$ 所在的路径**。考虑一个精确二模式状态

$$\sum_{a,b} E_{ab}\,\ell_a \otimes Q_b. \tag{60}$$

其中 $\ell$ 是一个完整当前教师终端因子，$Q$ 是原始高度至多 $L-1$ 的完整子树；所有尚未收缩的因子及留待下一步处理的输出均保留。$E$ 必须来自原始二次切口或其原始矩形传输，而非任意自适应矩阵；其原始重构系数满足引理 C.1 的核心估计。特别地 $\|E\|_{\mathrm{HS}} \le K_d$，各非平凡展平至多 $\delta_d$。一个较短源根留下一个收缩因子与一个完整孩子时，就是 $E_{ab} = d_a U_{ab}$，其中 $\|d\|_2 \le K_d$、$\|d\|_\infty \le \kappa_d$，$U$ 为原始归一化高斯边。

保留索引 $a$，暂不完成从 $\ell$ 到教师根的路径上的收缩。其他教师子树按高度递增处理，其对应的源因子均位于 $Q$ 中。每次重建系数张量都保留 $a$，并在当前层的复制和特征映射之前停止展开。因此选择一个后代索引时，总模式数至少二；选择两个不同后代索引时，总模式数至少三。

因此，估计 $Q$ 中同一节点仍有剩余因子的项时，总可使用源系数的矩阵化界。固定教师行后，包含全部剩余因子的源张量范数至多 $K_d\delta_d(\delta_d+\kappa_d)$。暂缓处理的路径上的因子也包含在该张量中，结合式 (58)，总误差趋零。涉及不同父节点的收缩用估计 C.2。余下的各次收缩均在 $Q$ 内使用完整孩子，不能直接发生在索引 $a$ 处：若 $Q$ 非线性，所选因子先在其内部相遇；若 $Q$ 只有一个当前因子，则不足以提供所需的 $m$ 个因子。

完成上述路径之外的高度 $h$ 教师子树，需要 $Q$ 的原始高度至少为 $h$。若 $Q$ 高度小于 $L-1$，根部其余 $m-1$ 个高度 $L-1$ 的孩子不能全部完成。若 $Q$ 高度为 $L-1$，这些孩子的收缩都必须在 $Q$ 的原根 $b$ 处完成。记相应收缩矩阵为 $M^{(j)}$，最终教师矩阵为 $A$，置 $G^{(j)}=AM^{(j)}$。由式 (59)，每个 $G^{(j)}$ 的列 $\ell^2$ 范数有界，最大条目至多 $K_d\kappa_d$。

保持该路径上的教师子树所含的全部因子。固定最终教师行 $i$，它的范数有界。去掉 $m-1$ 个已知收缩因子后，完整源余张量为

$$R_b=\sum_a E_{ab}\ell_a\otimes Q_b^{\mathrm{res}},\qquad \|R_b\|\le K_d\|E_{:b}\|_2,\quad \sum_b\|R_b\|\le K_d\sqrt{d}\|E\|_{\mathrm{HS}}.$$

这里每个余因子仍原样保留，$\ell$ 的列映射有界，$Q_b^{\mathrm{res}}$ 的列范数有界。归一化最终读出最大值为 $O(d^{-1/2})$；利用两个 $G$ 的列 $\ell^2$ 界及其余 $m-3$ 个的条目界，完整标量配对至多

$$K_d\|E\|_{\mathrm{HS}}\kappa_d^{m-3}=o(1). \tag{61}$$

这一步同时使用 $m-1$ 个收缩因子，未把一个小标量核与任意余张量直接相乘。它解决了完整剩余深度下的单因子/非单因子二模式边界，也解决较短任意根的一个收缩因子加一个完整孩子的边界。

### *E.3 两类激活展开项的统一归纳*

**对源高度作强归纳**。令 $P$ 为相应激活的普通零常数多项式，$m$ 按本节开头选定。同时证明：高度 $t<L$、根为任意零常数多项式 $A$、下层各节点为 $P$ 的每个有序展开项，在每个固定槽分配下配对趋零；高度 $L$ 时先分出全 $m$ 展开项，证明其余普通 $P$ 展开项配对趋零。不同孩子可以选择不同单项式，根次数不限制奇偶性。以下只用节点次数为正，以及上一节的局部收缩估计和二阶对角公式。

最低切口阶数至少三已处理；阶数一不能有两个不同活动父位置。阶数二时，一单因子、一非单因子的情况由(60)–(61)解决。若两者都非单因子，则它们必须都是同高度的新模式：较高活动收缩因子首次使用后已无剩余因子，而较高层留待处理的输出会成为第三模式。该切口故是尚未施加下面特征映射的原始二次上方系数 $D$。

对它的非对角部分，由置换对称性、有界 Hilbert 二阶矩和固定次数高斯超可积性，有

$$\max_{a\neq b}|D_{ab}|\le K_d/d.$$

保留两标签后，完整源余张量界为

$$K_d\Big(\sum_{a\neq b}|\eta_{ia}\zeta_{ib}D_{ab}|^2\Big)^{1/2}\le K_d/d,$$

与教师切片和配对即趋零。该论证只使用坐标/坐标估计，未使用一般二阶坐标/向量增益。

对于对角，式 (52) 的原始二次系数估计给出

$$\operatorname{Diag}D=\lambda_sI/\sqrt{k_s}+E_s,\qquad \mathbb{E}\|E_s\|_{\mathrm{HS}}^2=o(1). \tag{62}$$

先用源侧完整特征映射的算子范数界控制误差。主项识别两个原始父标签，把它们的两个选中根单项式相乘，保留所有有序孩子与完全相同的教师槽分配。得到高度 $s<t$、读出 $1/\sqrt{k_s}$ 的原始前缀展开项，乘精确确定性系数 $\lambda_s$。其根可有任意奇偶性，所以必须使用上述加强归纳类。已完成的收缩矩阵可展开回原始槽收缩；它们是等式，故融合不产生残缺子树。若 $s=0$，只剩输入次数二，不能贡献 $N>2$。

二模式也可能含一个较高收缩所得输出与一个新模式：这两个模式不属于同一层，因此不使用上述同层对角删除，活动情况下属于保留索引的论证，该输出暂不参与收缩时，只有一个待处理父模式。如果两模式都是较高纯收缩所得输出，则未完成状态中每个最多代表 $m^{L-1}$ 个原始槽，两者总数小于 $N$，不能是整个展开项；若一个已为高度 $L$，它独自已用尽全部槽。结构复制同样按其代表的原始槽数计算，不能当成新的独立父节点。

现在检验已有收缩因子用于下一步时，同一源节点还带其他完整因子的情形。当前教师叶若还访问其他源列，用引理 10；若全来自本列，而上方原系数至少有两个索引，用引理 10。只需考虑上方原系数为一索引的情形。指定因子之外若至少还有两个因子，用引理 10；没有其他因子时，无须排除。

若恰有一个其他因子，只需判断它是完整原孩子还是已有收缩因子。这是因为这里只使用先前已证明完整的步骤，每次仅将 $m$ 个完整原孩子替换为一个收缩因子。若另一个也是收缩因子，本列至多提供两个当前因子位置，不能容纳一个 $m \geq 5$ 因子的教师叶，已属于访问其他列的情形。若另一个是原孩子，则所有较高层已完成输出及未收缩子树仍分别保留索引，且原子树次数为正；上方仅一个索引因此迫使当前节点以上只有原始一元链。其系数 $d$ 是归一化读出乘原高斯连续积，故 $\|d\|_2 \leq K_d$、$\|d\|_\infty \leq \kappa_d$。展开唯一原孩子的第一条边得到

$$\sum_a d_a \ell_a \otimes \Big( \sum_b U_{ab} Q_b \Big) = \sum_{a,b} d_a U_{ab}\, \ell_a \otimes Q_b .$$

$Q$ 的原高度至多 $t-1 \leq L-1$，正是式 (60)–(61)处理的情形。因此留下的每个收缩因子再次使用时，都已包含其来源节点的全部因子。此结论对普通节点与任意次数的较短根同时成立，给出引理 12的前提。

从 $t=1$ 开始归纳。每次二阶对角合并使源高度严格降低，故由归纳假设控制；高度降为零时只剩输入次数二，不能贡献 $N>2$。上述估计排除了涉及不同父节点的项，以及再次使用收缩因子时仍有其他因子的项。余下每次收缩均使用 $m$ 个完整孩子。沿线性路径求和会经过原树的一条边，每次 $m$ 因子收缩完成一个教师子树；原树和教师树均有限，因此步骤有限终止。最终收缩使用全部 $N$ 个输入因子，不再留下正次数因子。

高度 $h$ 的教师子树在每条源路径上至少需要 $h$ 个原节点：$h=1$ 需要分支节点；从 $h-1$ 到 $h$ 时，$m$ 个孩子已各自完成高度 $h-1$ 的收缩，且再次使用时不带剩余因子，所以父节点严格位于这些孩子之上。线性节点只增加源高度。故 $t<L$ 时无法完成高度 $L$ 的教师树，配对趋零。$t=L$ 时所有二阶对角合并项已由较低高度排除，而每条路径必须取高度等号：没有额外线性节点，每个节点次数恰为 $m$，与正在考虑的非全 $m$ 展开项矛盾。因此这些项的配对全都趋零；预先分出的全 $m$ 项恰为原齐次比较项，其系数、权重和归一化完全未改。这同时完成两类激活的归纳。

### *E.4* 从确定性事件到任意先验耦合

**先控制各自先验下的误差，再对耦合取上确界**。固定次数和深度时，有序展开项、槽分配、原始切口、融合高度和收缩步骤的数量均与 $d$ 无关。分别在两个边缘上同时施加所有前述原始高斯事件，然后才允许跨网络收缩矩阵依赖两个网络。在共同好事件上，各项估计均为确定性 $o(1)$。在坏事件上，用固定次数系数的有界边缘高阶矩和 Hölder 不等式；坏事件概率可取任意所需多项式阶。该控制不依赖耦合，因此对所有先验边缘耦合一致。

设 $T_W$ 为与激活对应、带完整标量系数的全 $m$ 平衡齐次输入混沌项，并记式 (56) 的有限原始多项式家族为 $\mathcal{Q}_N(V)$。上文逐展开项结论给出

$$\sup_{\pi \in \Gamma(\mathsf{P}_W, \mathsf{P}_V)} \mathbb{E}_\pi \, |\langle T_W, \mathcal{Q}_N(V) - T_V \rangle| \longrightarrow 0. \tag{63}$$

又 $T_W$ 完全位于第 $N$ 输入混沌，故 $\langle T_W, F_V \rangle = \langle T_W, \Pi_N F_V \rangle$。由式 (57)，每个网络在自身边缘下的展开余项由 Cauchy–Schwarz 控制：

$$\mathbb{E}_\pi |\langle T_W, \Pi_N F_V - \mathcal{Q}_N(V) \rangle| \leq (\mathbb{E}\|T_W\|^2)^{1/2} (\mathbb{E}\|\Pi_N F_V - \mathcal{Q}_N(V)\|^2)^{1/2} = o(1).$$

结合(63)得到所需全局函数比较

$$\boxed{\sup_{\pi \in \Gamma(\mathsf{P}_W, \mathsf{P}_V)} \mathbb{E}_\pi |\langle T_W, F_V - T_V \rangle| \longrightarrow 0.} \tag{64}$$

## F 齐次比较网络的全局匹配

**齐次系数差控制参数匹配距离**。本节仅讨论激活为 $c_m z^m$、$c_m = (m!)^{-1/2}$ 的齐次网络。固定 $L$ 与整数 $m \geq 5$，令 $k_0 = d$，$cd \leq k_s \leq Cd$，并定义

$$h^{(0)} = x, \qquad h^{(s)} = c_m (W^{(s)} h^{(s-1)} / \sqrt{k_{s-1}})^{\odot m}, \qquad \mathcal{H}_W(x) = k_L^{-1/2} \sum_i h_i^{(L)}(x), \qquad p = \sum_{s=1}^{L} k_{s-1} k_s.$$

每个网络的所有权重分别具有独立标准高斯先验；两个网络之间可任意耦合。记 $P_s(Y)$ 为将 $h^{(s)}$ 替换为形式变量 $Y$ 后的下游输出，$q_s = m^{L-s}$，$C_s = C_{q_s}(P_s)$。这里 $P(Y) = \langle C_r(P), Y^{\otimes r} \rangle$，张量使用继承的 Hilbert 范数；若 $P = \sum_{|\nu|=r} p_\nu Y^\nu$，则

$$\|C_r(P)\|^2 = \sum_{|\nu|=r} \frac{\nu!}{r!} |p_\nu|^2. \tag{65}$$

特别地 $C_L = k_L^{-1/2} \mathbf{1}$。

**定理 2** (齐次网络的有限标签全局匹配)**.** *存在一族确定性的参数对齐映射 $\mathcal{G}_d$，以及仅依赖固定深度、次数和宽度比例的常数 $K$，使得*

$$\log |\mathcal{G}_d| = O(d \log d) = o(p), \qquad \frac{1}{p} \mathbb{E} \min_{g \in \mathcal{G}_d} \|W - gV\|_F^2 \leq K \mathbb{E} \|C_0(W) - C_0(V)\|^2 + o_d(1). \tag{66}$$

*余项对所有具有上述先验边缘分布的耦合一致。若 $X \sim N(0, I_d)$，则右侧亦可替换为 $K\mathbb{E}\|\mathcal{H}_W - \mathcal{H}_V\|_{L^2_X}^2 + o_d(1)$。*

### F.1 系数切片的范数界

式 (31) 控制以下两类张量的 Gram 矩阵。对单位行向量 $a_i$、$k = O(d)$，若最大自身相干度 $\eta = O(\sqrt{\log d / d})$，固定 $r$，则张量

$$\mathrm{Sym} \bigotimes_i a_i^{\otimes m\nu_i}, \quad |\nu| = r,$$

以及少一个因子的张量

$$\mathrm{Sym} \bigotimes_i a_i^{\otimes (m\nu_i - \mathbf{1}_{i=j})}, \quad |\nu| = r, \quad \nu_j > 0,$$

各自满足同样的 Gram 矩阵上下界（不同的 $(\nu, j)$ 无重复）：其任意线性组合的范数平方与系数平方和在维数无关常数内等价。容许 $1/2 \leq \|a_i\| \leq 2$，只改变常数。充分的小扰动界为 $K[\eta + \sum_{h=1}^{r} k^h \eta^{mh-2}] = o(1)$。上述范数均在全局对称张量空间中计算。

令 $B_{s,i} = \partial_i P_s$。在各层行范数、相干度和列平方和的通常高斯集中事件上，

$$a/k_s \leq \|C(B_{s,i})\|^2 \leq b/k_s \quad \text{对所有} s, i. \tag{67}$$

为证明式 (67)，从终层 $B_{L,i} = k_L^{-1/2}$ 反向归纳。置 $w_j = W_{j:}^{(s+1)} / \sqrt{k_s}$，链式法则给出

$$B_{s,i}(Y) = m c_m \sum_j w_{ji} (w_j \cdot Y)^{m-1} B_{s+1,j}\big(c_m (w \cdot Y)^{\odot m}\big).$$

展开 $B_{s+1,j}$ 后，每项恰为标签 $(\nu, j)$ 的第二类张量；固定次数下式 (65) 与普通单项式系数范数等价。第二类张量的 Gram 矩阵界因此给出

$$\|C(B_{s,i})\|^2 \asymp \sum_j w_{ji}^2 \|C(B_{s+1,j})\|^2 \asymp k_{s+1}^{-1} \sum_j w_{ji}^2 \asymp k_s^{-1}.$$

这一估计在行向量满足上述条件时逐点成立。记 $H_s$ 为切片 $C_s(e_i, \cdot)$ 的 Gram 矩阵，即 $(H_s)_{ij} = \langle C_s(e_i, \cdot), C_s(e_j, \cdot) \rangle$。精确微分恒等式给出

$$(H_s)_{ii} = q_s^{-2} \|C(\partial_i P_s)\|^2, \qquad a'/k_s \leq (H_s)_{ii} \leq b'/k_s. \tag{68}$$

### *F.2 稠密系数与坐标碰撞的控制*

**系数分散性控制依赖两网络的删除操作**。对任意行矩阵 $A$，置 $U_A e_i = a_i^{\otimes m}$。由于 $U_A = (A^T)^{\otimes m} J$，其中 $Je_i = e_i^{\otimes m}$ 为等距嵌入，$\|U_A\|_{\mathrm{op}} \le \|A\|_{\mathrm{op}}^m$。每次齐次代入为 $U_A$ 的张量幂再接收缩映射 Sym。从 $\|C_L\| = 1$ 递推，$\|C_s\|$ 被有限个归一化高斯矩阵算子范数的固定幂乘积控制。高斯矩阵算子范数的固定阶矩有一致上界，故

$$\sup_d \mathbb{E}\|C_s\|^u < \infty \quad (0 < u < \infty). \tag{69}$$

平方自由单项式是每个变量次数至多为一的单项式；记 SF 为只保留这些单项式的正交投影。对 $Y_I = \prod_{i\in I} Y_i$，$|I| = q_s$，写其系数为 $p_I$，置 $c_I = p_I/\sqrt{q_s!}$。式 (65) 表明 $\sum_I c_I^2$ 为平方自由部分的张量范数平方。对 $s < L$，矩阵 $W^{(s+1)}$ 的列置换不变性及 (69) 给出 $\mathbb{E}c_I^2 \le C\binom{k_s}{q_s}^{-1} \le Ck_s^{-q_s}$。每个 $c_I$ 是次数不超过 $D_s = m + \cdots + m^{L-s}$ 的高斯多项式，故高斯多项式超收缩不等式 $\|c_I\|_u \le (u-1)^{D_s/2}\|c_I\|_2$（$u \ge 2$）给出：取 $u = A\log d$，在 $e\|c_I\|_u$ 处应用 Markov，再对至多 $k_s^{q_s}$ 项作并集界，可令任意预定 $M$ 下

$$\mathbb{P}\left\{\max_I |c_I|^2 > C_M(\log d)^{D_s} k_s^{-q_s}\right\} \le d^{-M}. \tag{70}$$

终层为确定向量，单独处理。

下面证明下游系数张量中含重复指标的部分范数为 $o(1)$。令 $T = \mathrm{Sym}_{mr} U_A^{\otimes r} B$，$\|A\|_{\mathrm{op}} \le K$，$\max_{ij}|a_{ij}| \le \kappa$。将 $T$ 的两个指定输入槽与 $e_j$ 收缩：若两个槽来自同一个 $m$ 块，所得块映射为

$$(A^T)^{\otimes(m-2)} J\,\mathrm{diag}(a_{ij}^2),$$

其范数至多 $K^{m-2}\kappa^2$；若来自不同块，每块各自范数至多 $K^{m-1}\kappa$。其余块的算子范数有常数上界，固定次数下对称化只有有限种槽分配。因此

$$\|T(e_j, e_j, \cdot, \ldots, \cdot)\| \le C\kappa^2\|B\|.$$

坐标碰撞张量范数平方至多所有坐标对角切片范数平方之和乘以 $\binom{mr}{2}$，所以

$$\|(I - \mathrm{SF})T\|^2 \le Cn\kappa^4\|B\|^2 = o(1)\|B\|^2, \qquad \kappa = O(\sqrt{\log d/d}),\ n \asymp d. \tag{71}$$

将此用于 $C_s$ 的第一次下游代入，并用上层张量范数有界，即得 $\|(I - \mathrm{SF})C_s\| = o(1)$。式 (68) 的下界用于完整系数张量的切片，因此后文在应用该下界前先恢复完整张量。

所有这些边缘事件可同时选取，失败概率趋于零。有符号行列置换保持行范数、算子范数、相干度、最大坐标及列平方和；下游系数张量只发生坐标重排和符号变化。因此其范数、最大系数绝对值、式 (68) 的切片界，以及重复指标部分的范数界均保持。即使根据两个网络选择对齐，这些确定性界仍成立。

### *F.3 全局对称与分组张量的精确换算*

**单位行归一化与全局对称化的系数**。在第 $s$ 层写 $w_i = W_{i:}^{(s)}/\sqrt{k_{s-1}} = r_i a_i$，$\|a_i\| = 1$，$R = \mathrm{diag}(r_i^m)$，$\overline{C}_s = R^{\otimes q_s} C_s$。精确代入为

$$C_{s-1} = c_m^{q_s}\,\mathrm{Sym}_{mq_s} U_A^{\otimes q_s}\overline{C}_s. \tag{72}$$

均匀半径误差 $\max_i|r_i - 1| \le \delta_d \to 0$ 意味着 $\|\overline{C}_s - C_s\| \le C\delta_d\|C_s\|$。式 (68) 的切片界、最大系数界与重复指标部分的估计仍成立，因为每个张量坐标只乘上固定个 $1 + o(1)$ 半径因子。

固定 $q = q_s$，对 $|I| = q$ 定义

$$Q_I = \sqrt{q!}\,\mathrm{Sym}_q \bigotimes_{i\in I} a_i^{\otimes m}, \qquad E_I = \sqrt{(mq)!/(m!)^q}\,\mathrm{Sym}_{mq} \bigotimes_{i\in I} a_i^{\otimes m}.$$

$Q_I$ 属于分组空间，$E_I$ 属于实际全局对称空间。平方自由坐标基向量经分组提升变为 $Q_I$，再经 (72) 变为 $\sqrt{\lambda_{m,q}}E_I$，其中

$$\lambda_{m,q} = q!/(mq)!. \tag{73}$$

两种归一化使不拆分 $m$ 个槽的跨网络配对项完全相同。

### *F.4 自适应混合槽比较*

**一次 Schur 比较同时处理自身与交叉 Gram。**给定两个单位行阵列 $A, B$，自身相干度至多 $\eta_d = O(\sqrt{\log d/d})$，算子范数至多 $K$。置 $\rho_{ij} = \langle a_i, b_j\rangle$、$\tau = d^{-1/8}$。二部图 $|\rho_{ij}| > \tau$ 的度数至多 $D = \lceil K^2/\tau^2\rceil$；在各侧连接共享邻居的顶点，所得图度数至多 $D^2$。不含图边的 $q$ 元集合称为好集合。对好 $I = \{i_1, \dots, i_q\}$，任一列中至多一个 $|\rho_{i_a j}| > \tau$，故

$$\sum_j \prod_a |\rho_{i_a j}|^{v_a} \le \begin{cases} K^2, & \#\{a : v_a > 0\} = 1, \\ C\tau, & \#\{a : v_a > 0\} \ge 2, \end{cases} \qquad \sum_a v_a = m. \tag{74}$$

为证后一界，在 $v_a > 0$ 的位置中选取 $|\rho_{i_a j}|$ 最大者，并按其位置分区：其指数至少二时保留该项的平方，否则保留它与另一项各一幂；剩余因子中至少一幂至多 $\tau$。所保留项的列和分别由平方和界及 Cauchy–Schwarz 控制。全槽配对计数给出

$$\langle E_I^A, E_J^B\rangle = \sum_{\substack{e_{ab}\ge 0 \\ \sum_b e_{ab} = \sum_a e_{ab} = m}} \frac{(m!)^q}{\prod_{a,b} e_{ab}!} \prod_{a,b} \rho_{i_a j_b}^{e_{ab}}.$$

矩阵 $e = (e_{ab})$ 记录每对因子组之间的配对数。当 $e = mP$、$P$ 为置换矩阵时，整组因子保持在一起，这些项之和恰为 $\langle Q_I^A, Q_J^B\rangle$；其余矩阵至少有一列含两个正元。记两族张量在好集合上的交叉 Gram 矩阵分别为 $K_{\text{act}} = (\langle E_I^A, E_J^B\rangle)_{I,J}$、$K_{\text{grp}} = (\langle Q_I^A, Q_J^B\rangle)_{I,J}$。固定好 $I$，把对好 $J$ 的绝对行和放大为对所有有序 $J$ 的和，各列分离，由 (74) 得 $C\tau$；交换两侧得到同一列和界。因此

$$\|K_{\text{act}} - K_{\text{grp}}\|_{\text{op}} \le C\tau \tag{75}$$

在双方好集合上成立。这也适用于 $A = A$、$B = B$；因 $\eta_d < \tau$，这两种自身比较的所有集合均好。最大度数 $D^2$ 的图中，含边 $q$ 元集合至多 $C_q D^2 k^{q-1}$ 个。由 (70)，同时对所有可能依赖完整网络及系数的图，删除能量至多 $CD^2k^{q-1}\max_I |c_I|^2 \le Cd^{-1/2}(\log d)^{D_s} = o(1)$。实际与分组提升的算子范数均有界，故删除以及 (71) 的平方自由截断各只产生 $o(1)$ 范数误差。对三个 Gram 块 $AA, AB, BB$ 使用同一比较，再恢复完整系数，得

$$\|C_{s-1}^A - C_{s-1}^B\|^2 = \lambda_{m,q}\|G_A - G_B\|^2 + o(1), \qquad G_A = U_A^{\otimes q}\overline{C}_s^A, \quad G_B = U_B^{\otimes q}\overline{C}_s^B. \tag{76}$$

误差在联合典型事件上一致；$q = 1$ 时无拆槽，此等式精确成立。

### *F.5 一个平方差恒等式同时给出匹配与系数恢复*

**交叉矩阵的绝对行列和控制匹配误差。**记 $U = U_A, V = U_B, M = U^*V = (\rho_{ij}^m)$，$\rho_i = \max_j |\rho_{ij}|$。一行中 $|\rho_{ij}| > \tau$ 的子集大小至多 $D$，其自身 Gram 算子范数至多 $1 + D\eta_d$；低相关项保留平方后提出 $\tau^{m-2}$，故

$$\sum_j |M_{ij}| \le \rho_i^{m-2}(1 + D\eta_d) + K^2\tau^{m-2} \le \rho_i^{m-2} + e_d, \qquad \sum_i |M_{ij}| \le 1 + e_d, \tag{77}$$

其中 $e_d \to 0$ 对两阵列一致；列界由同一论证得到。置 $\widetilde{M} = M/(1 + e_d)$、$\mathsf{K} = \widetilde{M}^{\otimes q}$，并将完整系数张量 $C = \overline{C}_s^A, D' = \overline{C}_s^B$ 写为有序指标数组 $(c_I), (d_J)$。$\mathsf{K}$ 的绝对行列和 $r_I, s_J$ 均不超过一，且有精确恒等式

$$\begin{aligned} \mathcal{E} &:= \|C\|^2 + \|D'\|^2 - 2\langle C, \mathsf{K}D'\rangle \\ &= \sum_I (1 - r_I)c_I^2 + \sum_J (1 - s_J)d_J^2 + \sum_{I,J} |\mathsf{K}_{IJ}|(c_I - \operatorname{sgn}(\mathsf{K}_{IJ})d_J)^2. \end{aligned} \tag{78}$$

零权项不影响等式。因为 $U^*U, V^*V = I + o_{\text{op}}(1)$（非对角绝对行和至多 $k\eta_d^m = o(1)$），且系数范数有界，$\mathcal{E} = \|G_A - G_B\|^2 + o(1)$。$r_I$ 是各槽行和的乘积，故 $1 - r_I$ 至少为一减去第一槽对应的行绝对和；由 (77) 及 (68)，(78) 给出

$$k_s^{-1}\sum_i (1 - \rho_i^{m-2}) \le C\|G_A - G_B\|^2 + o(1).$$

固定 $\rho_0 \in (1/\sqrt{2},1)$。由于 $2\rho_0^2 > 1+\eta_d$，绝对相关超过 $\rho_0$ 的边构成部分双射。将其补为排列并逐行定向，使对角相关非负。未匹配行的比例由上一式除以 $1-\rho_0^{m-2}$ 控制；已匹配行使用 $1-x^m \le \frac{m}{m-2}(1-x^{m-2})$。令 $\ell_i = 1-\langle a_i, b_i\rangle^m$，遂得

$$k_s^{-1}\sum_i \ell_i + k_s^{-1}\sum_i \|a_i-b_i\|^2 \le C\|G_A-G_B\|^2 + o(1). \tag{79}$$

定向时同步置换、变号学生系数以保持 $G_B$ 不变，式 (68) 的切片界亦保持。在此表示中 $\mathsf{K}_{II} = \prod_{a=1}^{q}(1-\ell_{i_a})/(1+e_d)^q \ge 0$，且 $1-\mathsf{K}_{II} \le \sum_a(\ell_{i_a}+e_d)$。保留 (78) 的对角平方项，记切片族 $C(e_i,\cdot)$、$D'(e_i,\cdot)$ 的 Gram 矩阵分别为 $H_C, H_{D'}$，得到

$$\begin{aligned}\|C-D'\|^2 &\le \mathcal{E} + \sum_I (1-\mathsf{K}_{II})(c_I-d_I)^2 \\ &\le \mathcal{E} + 2q\sum_i (\ell_i+e_d)((H_C)_{ii}+(H_{D'})_{ii}) \le C\|G_A-G_B\|^2 + o(1).\end{aligned}$$

最后去除一致趋于一的半径因子，并用 (76)，得到

$$\|C_s^A - C_s^B\|^2 \le C\|G_A-G_B\|^2 + o(1) \le C\|C_{s-1}^A - C_{s-1}^B\|^2 + o(1). \tag{80}$$

### *F.6　内部符号传播与终层对齐*

**终层只需匹配参数**。内部层 $s<L$ 的有符号行置换写作 $S_s = D_s P_s$，其中 $D_s$ 对角元为 $\pm 1$。隐特征相应变为 $R_s h^{(s)}$，$R_s = D_s^{m \bmod 2} P_s$。同时以 $V^{(s+1)} R_s^{-1}$ 替换下一层矩阵，整个齐次函数精确保持不变。奇数 $m$ 将符号传播到下一层列，偶数 $m$ 仅传播排列；形式下游系数相应重排、变号，前述典型事件保持。

终层也允许有符号排列，但仅用作参数对齐标签。若匹配符号为 $\varsigma_i$、学生半径为 $t_i$，把学生行定向后，同时在分析表示中取 $\bar{c}_i^B = \varsigma_i^m t_i^m/\sqrt{k_L}$，教师系数为 $\bar{c}_i^A = r_i^m/\sqrt{k_L}$。这样表示的原学生张量不变，式 (68) 的切片界仍成立。此时 $q_L = 1$，由 (76) 和 (79)，定向后的终层平均行距离直接由 $C\|C_{L-1}^A - C_{L-1}^B\|^2 + o(1)$ 控制。无需恢复终层系数，也不要求这个终层标签保持网络函数。

### *F.7　深度归纳与任意先验耦合*

**完成定理的证明**令 $E_0 = \|C_0(W) - C_0(V)\|^2$。自下而上在内部层选择有符号匹配、传播至下一层列，记当前对齐后的形式张量误差为 $E_s$。内部对称变换保持当前 $C_{s-1}$，且以后对齐不再改变已完成的较低层。因此 (76)、(79)、(80) 在每个内部层给出

$$E_s \le C E_{s-1} + e_d, \qquad \frac{1}{k_s}\sum_i \|w_{s,i} - (gv)_{s,i}\|^2 \le C E_{s-1} + e_d, \qquad e_d \to 0.$$

半径误差由 $\|r_i a_i - t_i b_i\|^2 \le C\|a_i-b_i\|^2 + C\delta_d^2$ 吸收。终层使用上一小节，固定深度归纳得到每层平均归一化行距离至多 $C_{L,m}E_0 + o(1)$。恢复原始权重需要乘 $k_{s-1}$，故以 $k_{s-1}k_s/p$ 加权求和，得到联合典型事件上的 (66) 确定性版本。

具体映射族为

$$(gV)^{(1)} = S_1 V^{(1)}, \qquad (gV)^{(s)} = S_s V^{(s)} R_{s-1}^{-1} \quad (s \ge 2),$$

所有 $S_s$ 均可为有符号排列，终层标签不必是函数对称。因此

$$\log|\mathcal{G}_d| \le \sum_s \{\log(k_s!) + k_s \log 2\} = O(d\log d).$$

可固定标签次序打破所有平局，获得可测的匹配选择。任意先验边缘耦合下，两个各自典型事件的并集界保证联合失败概率趋零，不需要两个网络相互独立。坏事件上取恒等对齐，

$$p^{-1}\min_g \|W - gV\|^2 \le 2p^{-1}(\|W\|^2 + \|V\|^2).$$

归一化高斯权重平方范数有一致二阶矩；Cauchy–Schwarz 将坏事件期望变为 $o(1)$，且对耦合一致。取期望即证 (66)。最后最高输入次数 $N = m^L$ 的高斯混沌满足

$$N!\|C_0(W) - C_0(V)\|^2 = \|\Pi_N(\mathcal{H}_W - \mathcal{H}_V)\|_{L^2_X}^2 \le \|\mathcal{H}_W - \mathcal{H}_V\|_{L^2_X}^2,$$

证明函数距离版本。 □

实际函数的参数比较。 定理 64 和正文的极化恒等式将实际函数距离控制转为齐次系数距离控制，再应用定理 2。行符号只用于有限标签参数对齐，并不要求保持实际激活的函数值。

## G 条件 I–MMSE 与统一平滑测试场

**引理 13** (条件 I–MMSE)**.** 设实随机变量 $S$ 有有限二阶矩，$N \sim N(0,1)$ 独立于 $(S,Z)$。对 $Y_s = \sqrt{s}S + N$，有

$$I(S; Y_\rho \mid Z) = \frac{1}{2}\int_0^\rho \mathbb{E}[(S - \mathbb{E}[S \mid Z, Y_s])^2]\, ds.$$

证明. 条件于 $Z = z$，令 $q_v$ 为 $S + \sqrt{v}N$ 的密度。高斯热方程和分部积分给

$$\frac{d}{dv}h(q_v) = \frac{1}{2}\mathcal{J}(q_v), \qquad \partial_y \log q_v(y) = \frac{\mathbb{E}[S \mid z, S + \sqrt{v}N = y] - y}{v}.$$

将 $S - (S + \sqrt{v}N)$ 对观察作正交分解，得到 $\mathrm{mmse}(S \mid z, S + \sqrt{v}N) = v - v^2\mathcal{J}(q_v)$。从熵中减去噪声熵 $\frac{1}{2}\log(2\pi e v)$ 后微分，再换元 $v = 1/s$，互信息导数即为 MMSE 的一半。有界信号先在有界空间积分，再去掉空间截断；一般信号以二阶矩截断逼近。由 $\mathcal{J}(q_v) \le 1/v$ 及截断二阶矩的一致可积性，每个紧区间 $0 < s_0 \le s \le s_1$ 上的积分恒等式通过极限。最后用 $I(S; Y_s \mid Z) \le s\mathbb{E}S^2/2$、$\mathrm{mmse} \le \mathbb{E}S^2$，平均 $z$ 并令 $s_0 \downarrow 0$。 □

### G.1 真实通道的分部积分界

记 $f = F^{(L)}_{\theta(W)}(X)$、$a = \nabla_W f$、$\mathcal{I}_W = \mathbb{E}_X aa^T/\Delta$、$Z = (\mathcal{D}_n, X)$，$U_s = \sqrt{s}f + N$，其中 $N$ 独立标准高斯。上引理给

$$\epsilon_{\log,d,n} = \frac{1}{2}\int_0^{1/\Delta} m(s)\, ds, \qquad m(s) = \mathbb{E}(f - \mathbb{E}[f \mid Z, U_s])^2. \tag{81}$$

对只依赖 $(W,X)$ 的向量场 $b$，令

$$G_s = \delta b + b^T S_D + \sqrt{s}Nb^T a, \qquad \delta b = \mathrm{div}_W\, b - W \cdot b, \quad S_D = \nabla_W \log p(\mathcal{D}_n \mid W).$$

固定观察并对参数分部积分得 $\mathbb{E}[(\mathbb{E}[f \mid Z, U_s] - f)G_s] = \mathbb{E}b^T a$。给定 $(W,X)$，训练得分与辅助噪声独立且中心化，训练得分协方差为 $n\mathcal{I}_W$。因此 Cauchy–Schwarz 给

$$m(s) \ge \frac{(\mathbb{E}b^T a)^2}{n\mathbb{E}b^T\mathcal{I}_W b + \mathbb{E}(\delta b)^2 + s\mathbb{E}(b^T a)^2}. \tag{82}$$

先对紧支撑光滑场及截断的后验均值证明，再用引理 9 的 Sobolev 逼近和 $L^2$ 收敛取极限；以下估计保证所需可积性。

### G.2 正则化测试场的 OU 平滑

固定 $0 < \tau \le r \le 1$，令 $\lambda = r/p$、$M_W = (\mathcal{I}_W + \lambda I_p)^{-1}$、$b_0(W,X) = M_W a(W,X)$。取 (6) 中的 $W_\tau$，仅对参数作条件平均：

$$b_\tau(W,X) = \mathbb{E}[b_0(W_\tau, X) \mid W, X].$$

真实网络、训练似然及辅助观测 $U_s$ 均不变。首先

$$\mathbb{E}\|b_0\|^2 = \Delta\mathbb{E}\,\mathrm{tr}(M_W^2\mathcal{I}_W) \le \frac{\Delta p}{4\lambda}, \qquad \mathbb{E}\|b_\tau\|^4 \le \mathbb{E}\|b_0\|^4 \le C\lambda^{-4}.$$

将 $b_0$ 视为 $L^2(P_X;\mathbb{R}^p)$ 值函数，记第 $k$ 阶参数 Hermite 能量为 $c_k$。OU 半群逐阶乘 $e^{-\tau k}$，所以

$$\mathbb{E}\|Db_\tau\|_{\mathrm{HS}}^2=\sum_{k\ge 1}ke^{-2\tau k}c_k\le C\tau^{-1}\mathbb{E}\|b_0\|^2\le Cp^2/(r\tau).$$

这直接使 $b_\tau$ 属于高斯 $W^{1,2}$，不需要对 $M_W$ 求导。由引理 9、梯度四阶矩及 $\tau\le r$，

$$\mathbb{E}(\delta b_\tau)^2\le Cp^2/(r\tau),\qquad \mathbb{E}(b_\tau^Ta)^2\le(\mathbb{E}\|b_\tau\|^4\mathbb{E}\|a\|^4)^{1/2}\le Cp^2/r^2\le Cp^2/(r\tau).\tag{83}$$

由高斯先验不变性、(6) 和 Cauchy–Schwarz，

$$\begin{aligned}\mathbb{E}b_\tau^Ta(W,X)&=\mathbb{E}b_0(W_\tau,X)^Ta(W,X)\\&\ge\Delta p[1-D_d(r)]-(\mathbb{E}\|b_0\|^2)^{1/2}(\mathbb{E}\|a(W_\tau,X)-a(W,X)\|^2)^{1/2}\\&\ge\Delta p[1-D_d(r)-C(\tau/r^2)^{1/4}].\end{aligned}\tag{84}$$

为控制训练得分项，另取独立输入 $\overline{X}$。条件 Jensen 给

$$\mathbb{E}b_\tau^T\mathcal{I}_Wb_\tau\le\Delta^{-1}\mathbb{E}[(b_0(W_\tau,X)^Ta(W,\overline{X}))^2].$$

写 $M'=M_{W_\tau}$、$\mathcal{I}'=\mathcal{I}_{W_\tau}$。条件于 $(W,W_\tau,\overline{X})$，$X$ 仍独立，故

$$\mathbb{E}_Xb_0(W_\tau,X)b_0(W_\tau,X)^T=\Delta M'\mathcal{I}'M'\preceq\frac{\Delta}{4\lambda}I_p.$$

在内积中分解 $a(W,\overline{X})=a(W_\tau,\overline{X})+e$。第一项的平方平均除以 $\Delta$ 为 $\Delta\mathbb{E}\,\mathrm{tr}[(M'\mathcal{I}')^2]\le\Delta p$；第二项满足

$$\Delta^{-1}\mathbb{E}[(b_0(W_\tau,X)^Te)^2]\le\frac{1}{4\lambda}\mathbb{E}\|e\|^2\le C\sqrt{\tau}/\lambda.$$

由 $L^2$ 三角不等式，得到

$$\mathbb{E}b_\tau^T\mathcal{I}_Wb_\tau\le\Delta p[1+C(\tau/r^2)^{1/4}]^2.\tag{85}$$

将 (84) 的右侧取正部，把 (83)、(85) 代入 (82)，再对 (81) 积分。最后取 $\tau=r^4$，使 $(\tau/r^2)^{1/4}=\sqrt{r}$、$r\tau=r^5$，即得 (21)。