中心化归一化网络的预测 KL 标度
固定深度标度定理

高斯回归；维度先行极限

2026 年 10 月 24 日

对固定深度、各层宽度与输入维数成正比的网络，本文证明平均 Bayes 预测 KL 的首项为 $P_{\text{hidden}}(d)/(2n)$，激活类包含中心化归一化的 tanh、sigmoid 和 ReLU。函数距离控制参数匹配误差，互信息界给出 Fisher 谱性质；条件 I–MMSE、高斯分部积分和线性高斯参考分布给出相同首项的上下界。维数极限先于样本比极限，无需固定样本比的风险极限或后验局部高斯近似。

1 模型、激活类与定理

固定 $L \geq 1$，$k_0 = d$，$k_\ell/d \to \gamma_\ell \in (0,\infty)$，$\gamma_0 = 1$。各层权重 $W^{(\ell)} \in \mathbb{R}^{k_\ell \times k_{\ell-1}}$ 的元素相互独立、服从标准高斯，输入 $x \sim N(0, I_d)$ 独立于权重。各层共用固定激活 $\sigma_\ell \equiv \sigma$，满足

$$\mathbb{E}\sigma(G) = 0, \qquad \mathbb{E}\sigma(G)^2 = 1, \qquad G \sim N(0,1).$$

记 $W = (W^{(\ell)})_{\ell=1}^{L}$、$\theta = \theta(W) = (v, W)$，固定 $v_i = 1$，定义

$$\begin{aligned} h^{(0)}(x) &= x, \qquad h^{(\ell)}(x) = \sigma_\ell\left(\frac{W^{(\ell)} h^{(\ell-1)}(x)}{\sqrt{k_{\ell-1}}}\right), \\ F_\theta^{(L)}(x) &= \frac{v^{\mathsf{T}} h^{(L)}(x)}{\sqrt{k_L}}. \end{aligned} \tag{1}$$

真实参数 $\theta^0 = (v, W^0)$ 由上述先验 P_0 抽取。训练集 $\mathcal{D}_n = \{(x_\mu, y_\mu)\}_{\mu=1}^n$ 由

$$y_\mu = F_{\theta^0}^{(L)}(x_\mu) + \sqrt{\Delta} z_\mu, \qquad z_\mu \sim N(0,1), \quad \Delta > 0$$

生成。训练和测试输入独立同分布；噪声相互独立，且独立于参数与全部输入。记 $P_{\text{out}}(y \mid \lambda) = N(y; \lambda, \Delta)$，真实先验和通道给出的后验为

$$P(d\theta \mid \mathcal{D}_n) \propto P_0(d\theta) \prod_{\mu=1}^{n} P_{\text{out}}\Big(y_\mu \mid F_\theta^{(L)}(x_\mu)\Big).$$

仅学习隐藏权重，其参数数目为

$$P_{\text{hidden}}(d) = \sum_{\ell=1}^{L} k_{\ell-1} k_\ell, \qquad c = \lim_d \frac{P_{\text{hidden}}(d)}{d^2} = \sum_{\ell=1}^{L} \gamma_{\ell-1}\gamma_\ell.$$

后验预测密度及平均预测 KL 定义为

$$\begin{aligned} p_{\mathcal{D}_n}(y \mid x) &= \mathbb{E}_{\theta \mid \mathcal{D}_n} P_{\text{out}}\Big(y \mid F_\theta^{(L)}(x)\Big), \\ \epsilon_{\log,d,n} &= \mathbb{E}_{\theta^0, \mathcal{D}_n, x}\, \mathrm{KL}\Big(P_{\text{out}}\Big(\cdot \mid F_{\theta^0}^{(L)}(x)\Big) \,\Big\|\, p_{\mathcal{D}_n}(\cdot \mid x)\Big). \end{aligned} \tag{2}$$

写 $\epsilon_{\log,d}(\alpha) := \epsilon_{\log,d,\lfloor \alpha d^2 \rfloor}$。下文简记 $p = P_{\text{hidden}}(d)$、$F_W = F = F_{\theta(W)}^{(L)}$、$\theta' = \theta(V)$，先验平均中的 W^0 简记为 W。微分、高斯积分和 OU 耦合仅作用于 $W \in \mathbb{R}^p$；齐次多项式网络另行定义。

常数可依赖深度、激活、宽度比例和噪声，不依赖 d, n。

1.1 激活类

取下列两类的并集 $\mathcal{A}_{\text{bal}}$。两支均满足上述中心化及单位方差条件。光滑奇函数支：σ 有界、奇、属于 C^∞，每个固定阶导数有界。分段线性支：令 $c_0 = \sqrt{2/\pi}$，

$$\sigma(z) = az + b(|z| - c_0), \qquad b \neq 0, \qquad a^2 + b^2(1 - 2/\pi) = 1. \tag{3}$$

两支均全局 Lipschitz。

记 He_j 为概率论约定的 Hermite 多项式，$\psi_j = \mathrm{He}_j/\sqrt{j!}$、$a_j = \mathbb{E}[\sigma(G)\psi_j(G)]$。相应地，$\mu_{\ell,j} = \mu_j = \sqrt{j!}a_j$。

引理 1 (高阶奇系数自动存在)**.** *若 σ 为有界连续奇函数且 $\mathbb{E}\sigma(G)^2 = 1$，则存在奇数 $m \geq 5$ 使 $a_m \neq 0$。*

证明. 若结论不成立，奇性和 Hermite 系的完备性给出 $\sigma = a_1\psi_1 + a_3\psi_3$ 高斯几乎处处成立；连续性使等式处处成立。有界奇多项式只能为零，与单位方差矛盾。 □

光滑支固定上述一个 m；分段线性支取 $m = 6$，下节验证 $a_6 \neq 0$。m 仅依赖激活，常数可依赖 m。

定理 1. *上述模型中，对任意固定深度 $L \geq 1$，任一固定 $\sigma \in \mathcal{A}_{\text{bal}}$ 满足*

$$\boxed{\lim_{\alpha\to\infty} \limsup_{d\to\infty} \left|\alpha\epsilon_{\log,d}(\alpha) - \frac{c}{2}\right| = 0.} \tag{4}$$

该结论包含任意固定正斜率的中心化归一化 tanh、logistic sigmoid，以及中心化归一化 ReLU。

先取 $d \to \infty$，再取 $\alpha \to \infty$；不要求固定 α 的风险极限存在。

1.2 tanh、sigmoid 与 ReLU

对任意固定 $a > 0$，令

$$s_a^2 = \mathbb{E}\tanh^2(aG) > 0, \qquad \sigma_a(z) = \tanh(az)/s_a.$$

它是方差为一的有界光滑奇函数。由 $\tanh' = 1 - \tanh^2$，每阶导数都是 $\tanh(az)$ 的多项式，故有界，属于光滑支。对固定 $b > 0$，logistic sigmoid $\ell_b(z) = (1 + e^{-bz})^{-1}$ 满足 $\ell_b(z) - 1/2 = \tanh(bz/2)/2$，其均值为 $1/2$、方差为 $s_{b/2}^2/4$，中心化归一化后恰为 $\sigma_{b/2}$。

对 ReLU，直接积分给出

$$\mu_R = \mathbb{E}G_+ = \frac{1}{\sqrt{2\pi}}, \qquad v_R = \mathrm{Var}(G_+) = \frac{1}{2} - \frac{1}{2\pi}, \qquad \sigma_R(z) = \frac{z_+ - \mu_R}{\sqrt{v_R}}.$$

由 $z_+ = (z + |z|)/2$，它对应式 (3) 的 $a = b = 1/(2\sqrt{v_R})$。整个分段线性支都中心化；奇偶正交性给出其方差 $a^2 + b^2(1 - 2/\pi) = 1$。由 $\mathrm{He}_6(z) = z^6 - 15z^4 + 45z^2 - 15$ 及 $\mathbb{E}|G|^{2j+1} = 2^j j!\sqrt{2/\pi}$，得到

$$\mathbb{E}[|G|\,\mathrm{He}_6(G)] = 3\sqrt{2/\pi}, \qquad a_6 = \frac{3b\sqrt{2/\pi}}{\sqrt{6!}} \neq 0.$$

分段线性支的奇次系数 a_j 在 $j \geq 3$ 时均为零；光滑奇函数支的偶次系数均为零。

2 先验矩与局部估计

令 $q_\ell = \|h^{(\ell)}\|^2/k_\ell$、$a(W, X) = \nabla_W F_{\theta(W)}^{(L)}(X)$。附录引理 3–6 证明：对每个固定 $r > 0$，

$$\mathbb{E}|q_\ell - 1|^r \leq C_r d^{-r/2}, \qquad \mathbb{E}|F_{\theta(W)}^{(L)}(X)|^r + \mathbb{E}\|a(W, X)\|^r \leq C_r. \tag{5}$$

存在固定 $0 < \delta \leq 1$，使独立于 (W, X) 的标准高斯 Z 满足

$$W_\tau = e^{-\tau}W + \sqrt{1 - e^{-2\tau}}Z, \qquad \mathbb{E}\|a(W_\tau, X) - a(W, X)\|^2 \leq C\tau^\delta \quad (0 < \tau \leq 1). \tag{6}$$

对 $0 < t \leq 1/2$，写 $W(t) = \sqrt{1 - t}W + \sqrt{t}Z$，则一阶展开满足

$$\begin{aligned} F_{\theta(W(t))}^{(L)} - F_{\theta(W)}^{(L)} &= \sqrt{t}\, a(W, \cdot)^T Z + E_t, \\ \mathbb{E}\|E_t\|_{L_X^2}^2 &\leq Ct^{1+\delta}. \end{aligned} \tag{7}$$

常数和指数不依赖扰动参数；维数阈值可依赖该参数，但在紧离零区间上一致。以下局部界均在阈值以上使用。

3 全局函数比较与参数匹配

用齐次网络比较实际输出，再匹配参数。置

$$N = m^L, \qquad S = 1 + m + \cdots + m^{L-1}, \qquad B = a_m^S \neq 0.$$

将各层激活换为 $z^m/\sqrt{m!}$，保留权重与读出，记其最高输入次数系数为 $C_N(W) \in \mathrm{Sym}^N \mathbb{R}^d$，定义

$$H_m(W) = I_N(C_N(W)), \qquad T_W = BH_m(W).$$

记 Π_N 为 $L^2(P_X)$ 到第 N 阶 Hermite 子空间的正交投影。I_N 将对称张量映为该子空间中的多项式：对 $v \neq 0$，$I_N(v^{\otimes N})(X) = \|v\|^N \,\mathrm{He}_N(\langle v, X\rangle/\|v\|)$，再线性延拓。其归一化满足

$$\langle I_N(C), I_N(D)\rangle_{L^2_X} = N!\langle C, D\rangle. \tag{8}$$

张量均取对称张量空间中继承的 Hilbert 范数。

引理 2 (函数内积的统一估计)**.** *若 Π_d 为原高斯参数先验，记 $\Gamma(\Pi_d, \Pi_d)$ 为两个边缘均为 Π_d 的联合分布集合，则*

$$e_d := \sup_{\pi \in \Gamma(\Pi_d, \Pi_d)} \mathbb{E}_\pi |\langle T_W, F_{\theta'}^{(L)} - T_V\rangle_{L^2_X}| \longrightarrow 0. \tag{9}$$

耦合只须具有正确先验边缘，无需 W, V 独立。

证明. 附录 D 给出实际输出的多项式近似，附录 E 逐项比较并控制耦合误差，得到式 (56)，即本引理。 □

对任一正确边缘耦合，令 $D = \mathbb{E}\,\|T_W - T_V\|^2$、$B_F = \mathbb{E}\left\|F_\theta^{(L)} - F_{\theta'}^{(L)}\right\|^2$。在原耦合、转置耦合以及两个对角项中分别使用 (9)，得

$$|\mathbb{E}\langle T_W - T_V, F_\theta^{(L)} - F_{\theta'}^{(L)}\rangle - D| \le 4e_d.$$

所以

$$D \le \sqrt{DB_F} + 4e_d \le (D + B_F)/2 + 4e_d, \quad D \le B_F + 8e_d.$$

齐次全局匹配定理给出有限可测映射族 $\mathcal{G}_d$，

$$\begin{aligned} \log|\mathcal{G}_d| &= O(d\log d) = o(p), \\ \frac{1}{p}\mathbb{E}\min_{g\in\mathcal{G}_d}\|W - gV\|^2 &\le C\mathbb{E}\,\|H_m(W) - H_m(V)\|^2 + o_d(1) \\ &\le C\mathbb{E}\left\|F_\theta^{(L)} - F_{\theta'}^{(L)}\right\|^2 + o_d(1). \end{aligned} \tag{10}$$

误差对耦合一致，证明见附录 F。行符号变换仅作控制条件熵的有限标签，无需保持实际输出。

4 互信息界与后验收缩

记 $I_{d,n} = I(\theta^0; \mathcal{D}_n) = I(W; \mathcal{D}_n)$。Bayes 定义和样本条件独立性给出

$$\epsilon_{\log,d,n} = I_{d,n+1} - I_{d,n}, \qquad \epsilon_{\log,d,n+1} \le \epsilon_{\log,d,n}. \tag{11}$$

第二式源于预测条件熵递减、噪声熵不变。

4.1 粗风险上界

固定充分大的 u，令 $n = \lfloor ud^2 \rfloor$、$t = (1 + n/p)^{-1}$。因 $t \to (1 + u/c)^{-1} > 0$，维数充分大时可用下一节仅由先验矩与 OU 余项推出的 (21)。又

$$\mathbb{E}\log\det(I_p + ntA/\Delta) \le nt\mathbb{E}\,\mathrm{tr}\,A/\Delta \le Cp, \qquad (n/p)t^{1+\delta} \le 1,$$

所以 $I_{d,n} \le \frac{p}{2}\log(1 + n/p) + Cp$。由 (11)，$n\epsilon_{\log,d,n} \le I_{d,n}$，因此

$$\limsup_d \epsilon_{\log,d}(u) \le C\frac{\log u}{u} \qquad (u \text{ 充分大}). \tag{12}$$

4.2 后验参数距离与条件熵

给定 $\mathcal{D}_n$ 独立抽取后验样本 W, V；平均数据后两者保持原先验边缘。记 $B_X = F^{(L)}_{\theta(W)}(X) - F^{(L)}_{\theta(V)}(X)$。以后验预测密度为中间点，Hellinger 三角不等式和 $H^2 \le \mathrm{KL}$ 给

$$\mathbb{E}[1 - e^{-B_X^2/(8\Delta)}] \le 2\epsilon_{\log,d,n}, \tag{13}$$

指数项为两高斯密度的亲和度。固定 $q > 2$，有

$$z^2 \le C_q(1 + |z|^q)^{2/q}(1 - e^{-z^2/(8\Delta)})^{1-2/q}$$

（分 $|z| \le 1$、$|z| > 1$ 验证）。Hölder 与 (5) 给 $\mathbb{E}B_X^2 \le C_q \epsilon_{\log,d,n}^{1-2/q}$。定义

$$r_{d,n} = \frac{1}{p}\mathbb{E}\min_{g \in \mathcal{G}_d} \|W - gV\|^2, \qquad r_*(u) = \limsup_d r_{d,\lfloor ud^2 \rfloor}.$$

在 (10) 中取此后验耦合，再取 $q = 2/\eta$，由 (12) 得

$$r_*(u) \le C_\eta (\log u/u)^{1-\eta}, \qquad 0 < \eta < 1. \tag{14}$$

选取可测最优标签 $\widehat{g}$，令 $V_t = \sqrt{1-t}W + \sqrt{t}U$，其中 U 独立于上述变量且为标准高斯，$0 \le t \le 1/2$。给定 $\mathcal{D}_n$，V 与 V_t 独立；且

$$\mathbb{E}\|V_t - \sqrt{1-t}\widehat{g}V\|^2 = p[t + (1-t)r_{d,n}].$$

条件于 $(\mathcal{D}_n, V, \widehat{g})$，由高斯最大熵和 Jensen 得

$$h(V_t \mid \mathcal{D}_n) \le \log|\mathcal{G}_d| + \frac{p}{2}\log\{2\pi e[t + (1-t)r_{d,n}]\}. \tag{15}$$

其中标签的条件熵至多为 $\log|\mathcal{G}_d|$。$t = 0$ 时 $V_0 = W$；从 $h(W) = \frac{p}{2}\log(2\pi e)$ 减去上述界并用 (14)，得

$$\liminf_d \frac{I_{d,\lfloor \alpha d^2 \rfloor}}{p} \ge \frac{1-\eta}{2}\log\alpha - \frac{1-\eta}{2}\log\log\alpha - C_\eta. \tag{16}$$

这里 $\eta \in (0,1)$ 固定，α 充分大。对 $t > 0$，记 $J_n(t) = I(W; V_t \mid \mathcal{D}_n)$。从 (15) 减去条件噪声熵，得到

$$J_n(t) \le \log|\mathcal{G}_d| + \frac{p}{2}\log\left(1 + \frac{(1-t)r_{d,n}}{t}\right) \le \log|\mathcal{G}_d| + \frac{pr_{d,n}}{2t}. \tag{17}$$

5 线性高斯参考分布与互信息界

当 $0 < t \le 1/2$ 时，反向表示为 $W = \sqrt{1-t}V_t + \sqrt{t}\xi$，其中 ξ 与 V_t 独立标准高斯。记 $f_W = F^{(L)}_{\theta(W)}$、$a(x) = \nabla f_{V_t}(x)$、$A = \mathbb{E}_X a(X)a(X)^T$。对固定 t 及 $d \ge d_0(t)$，(7)、(5) 给出

$$f_W(x) - f_{V_t}(x) = \sqrt{t}\, a(x)^T\xi + R_t(x), \qquad \mathbb{E}\|R_t\|^2_{L^2_X} \le Ct^{1+\delta}, \quad \mathbb{E}\|a(X)\|^4 \le C.$$

5.1 相对熵分解与互信息增量

给定 $V_t, X_{1:j}$，令 Φ_j 的第 i 行为 $a(X_i)^T$，定义

$$Q_j = N((f_{V_t}(X_i))_{i \le j}, S_j), \qquad S_j = \Delta I_j + t\Phi_j\Phi_j^T.$$

各参考分布共用虚拟系数 $\zeta \sim N(0, I_p)$，由线性模型 $f_{V_t}(X_i) + \sqrt{t}\, a(X_i)^T\zeta + \sqrt{\Delta}Z_i$ 生成，故样本边缘相容。输入服从真实分布，虚拟系数不被观测。令 P_j 为给定 V_t 的真实数据分布，定义

$$C_j = \mathbb{E}\log\frac{p(Y_{1:j} \mid W, X_{1:j})}{q_j(Y_{1:j} \mid V_t, X_{1:j})}, \qquad B_j = \mathbb{E}_{V_t}\mathrm{KL}(P_j\|Q_j).$$

P_j, Q_j 包含相同的输入边缘。由相对熵分解和 Markov 链 $V_t - W - \mathcal{D}_j$，

$$I_{d,j} + J_j(t) = \frac{p}{2}\log(1/t) + C_j - B_j. \tag{18}$$

边缘相容性给 $B_n \ge B_j \ge 0$，再用 $J_n(t) \ge 0$ 得

$$I_{d,n} \le \frac{p}{2}\log(1/t) + C_n, \qquad I_{d,n} - I_{d,j} \le C_n - C_j + J_j(t). \tag{19}$$

5.2　交叉熵的非线性误差

令 $L_j=\sqrt{t}\Phi_j\xi$、$R_j=(R_t(X_i))_{i\le j}$，并置 $H_j=\mathbb{E}\log\det(I_p+t\Phi_j^T\Phi_j/\Delta)$。高斯密度公式和 Sylvester 恒等式给

$$C_j=H_j/2+\mathbb{E}L_j^TS_j^{-1}R_j+\tfrac12\mathbb{E}R_j^TS_j^{-1}R_j,$$

线性项与噪声项抵消，因为 $\mathbb{E}[L_j^TS_j^{-1}L_j\mid V_t,X_{1:j}]+\Delta\,\mathrm{tr}\,S_j^{-1}=j$。又由 $S_j\succeq\Delta I_j$，

$$\mathbb{E}L_j^TS_j^{-1}L_j=\mathbb{E}\,\mathrm{tr}(t\Phi_j\Phi_j^TS_j^{-1})\le p,\qquad \mathbb{E}R_j^TS_j^{-1}R_j\le Cjt^{1+\delta}.$$

加权 Cauchy–Schwarz 给出

$$|C_j-H_j/2|\le C\sqrt{pjt^{1+\delta}}+Cjt^{1+\delta}. \tag{20}$$

此处不要求 R_j 与 ξ 独立。

5.3　经验与总体行列式的比较

置 $\overline{H}_j=\mathbb{E}\log\det(I_p+jtA/\Delta)$。在 $M\succeq I_p$ 上，$D^2(-\log\det)(M)[H,H]=\mathrm{tr}(M^{-1}HM^{-1}H)\le\|H\|_{\mathrm{HS}}^2$。条件于 V_t，对 $I_p+(t/\Delta)\sum_{i\le j}a(X_i)a(X_i)^T$ 在均值处作二阶 Taylor 展开，用条件独立性和梯度四阶矩得

$$0\le\overline{H}_j-H_j\le\frac{jt^2}{2\Delta^2}\mathbb{E}\|a(X)a(X)^T-A\|_{\mathrm{HS}}^2\le Cjt^2.$$

对 $n>j\ge1$，逐特征值使用 $(1+nt\lambda/\Delta)/(1+jt\lambda/\Delta)\le n/j$，故

$$H_n-H_j\le\overline{H}_n-\overline{H}_j+Cjt^2\le p\log(n/j)+Cjt^2.$$

由 (19) 的第一式、(20) 及 $H_n\le\overline{H}_n$，累计信息满足

$$\begin{aligned}\frac{I_{d,n}}{p}&\le\frac12\log\frac1t+\frac{1}{2p}\mathbb{E}\log\det(I_p+ntA/\Delta)\\&\quad+C\sqrt{\frac{n}{p}t^{1+\delta}}+C\frac{n}{p}t^{1+\delta}.\end{aligned} \tag{21}$$

6　信息矩阵的谱与预测下界

令 $a_W(x)=\nabla_WF_\theta^{(L)}(x)$、$\mathcal{I}_W=\mathbb{E}_Xa_Wa_W^T/\Delta$，并记

$$D_d(r)=\mathbb{E}\frac1p\,\mathrm{tr}\{r(p\mathcal{I}_W+rI)^{-1}\},\qquad\nu_d=\frac1p\mathbb{E}\sum_{i=1}^p\delta_{\lambda_i(p\mathcal{I}_W)}.$$

由梯度二阶矩，$\int\lambda\,d\nu_d=\mathbb{E}\,\mathrm{tr}\,\mathcal{I}_W\le C$。

6.1　互信息界排除零附近的正比例谱质量

记 $q_d(s)=\nu_d([0,s])$。反设 $b=\lim_{s\downarrow0}\limsup_d q_d(s)>0$，固定 $0<\beta<b$。固定 $1/(1+\delta)<a<1$，在 (21) 中取 $n=\lfloor\alpha d^2\rfloor$、$t=\alpha^{-a}$。对每个充分大的固定 α，可选维数子序列使 $q=q_d(\alpha^{-1})\ge\beta$。因 $n/p\to\alpha/c$，记 $Q_d=nt/p\le C\alpha^{1-a}$。$A/\Delta$ 与 $\mathcal{I}_W$ 同分布，所以 Jensen 不等式给

$$\begin{aligned}\frac1p\mathbb{E}\log\det(I_p+ntA/\Delta)&=\int\log(1+Q_d\lambda)\,d\nu_d\\&\le\log(1+Q_d/\alpha)+(1-q)\log\left(1+\frac{CQ_d}{1-q}\right)\\&\le(1-\beta)(1-a)\log\alpha+C.\end{aligned}$$

$q=1$ 时第二项按连续延拓取零；最后一步用 $-(1-q)\log(1-q)\le 1/e$。故沿该子序列，信息上界至多

$$\frac{1-\beta(1-a)}{2}\log\alpha + C + o_\alpha(1).$$

在 (16) 中固定 $\eta=\beta(1-a)/2$，其 $\log\alpha$ 系数比上式大 $\beta(1-a)/4$，其余损失为 $O_\eta(\log\log\alpha)$，故 $\alpha\to\infty$ 时矛盾，$b=0$。最后由 $D_d(r)\le q_d(s)+r/s$，依次令 $d\to\infty$、$r\downarrow 0$、$s\downarrow 0$，得到

$$D_*(r):=\limsup_d D_d(r),\qquad \lim_{r\downarrow 0} D_*(r)=0. \tag{22}$$

6.2 预测 KL 下界

附录 G 对正则化测试场作 OU 平滑，证明

$$\epsilon_{\log,d,n}\ge \frac{p[1-D_d(r)-C\sqrt{r}]_+^2}{2\{n(1+C\sqrt{r})^2+Cp/r^{1+2/\delta}\}},\quad 0<r\le 1,\ d\ge d_0(r). \tag{23}$$

固定 r，依次令 $d\to\infty$、$\alpha\to\infty$，得到

$$\liminf_{\alpha\to\infty}\alpha\liminf_d \epsilon_{\log,d}(\alpha)\ge \frac{c[1-D_*(r)-C\sqrt{r}]_+^2}{2(1+C\sqrt{r})^2}.$$

最后由 (22) 令 $r\downarrow 0$，得到

$$\liminf_{\alpha\to\infty}\alpha\liminf_d \epsilon_{\log,d}(\alpha)\ge c/2. \tag{24}$$

7 预测 KL 上界

固定 $\vartheta\in(0,1)$，取 $n=\lfloor\alpha d^2\rfloor$、$j=\lfloor(1-\vartheta)\alpha d^2\rfloor$。由风险递减及 (19)，有 $(n-j)\epsilon_{\log,d,n}\le C_n-C_j+J_j(t)$。代入 (17)、(20) 和行列式差界，固定 α,t 后令 $d\to\infty$，由 $p/d^2\to c$、$\log|\mathcal{G}_d|=o(d^2)$ 得

$$\begin{aligned}\alpha\limsup_d \epsilon_{\log,d}(\alpha)\le{}& \frac{c}{2\vartheta}\left\{\frac{r_*((1-\vartheta)\alpha)}{t}+\log\frac{1}{1-\vartheta}\right\}\\ &+\frac{C}{\vartheta}\left\{\alpha t^2+\sqrt{\alpha t^{1+\delta}}+\alpha t^{1+\delta}\right\}.\end{aligned} \tag{25}$$

固定 $1/(1+\delta)<a<1$ 和 $0<\eta<1-a$，取 $t=\alpha^{-a}$。由 (14)，第一误差为 $O_\vartheta(\alpha^{a-1+\eta}(\log\alpha)^{1-\eta})=o(1)$；又因 $a>1/2$、$a(1+\delta)>1$，其余三项也趋零。先 $\alpha\to\infty$，再 $\vartheta\downarrow 0$，由 $\vartheta^{-1}\log(1/(1-\vartheta))\to 1$ 得

$$\limsup_{\alpha\to\infty}\alpha\limsup_d \epsilon_{\log,d}(\alpha)\le c/2.$$

结合 (24)，并使用

$$\limsup_d|\alpha\epsilon_{\log,d}(\alpha)-c/2|=\max\{\alpha\limsup_d\epsilon_{\log,d}(\alpha)-c/2,\,c/2-\alpha\liminf_d\epsilon_{\log,d}(\alpha)\},$$

即得定理 1。

A 固定深度网络的解析估计及分部积分的定义域

沿用模型中的 $h^{(\ell)},F$，记 $u^{(\ell)}=W^{(\ell)}h^{(\ell-1)}/\sqrt{k_{\ell-1}}$。固定深度 L，且 $cd\le k_\ell\le Cd$；期望均对独立高斯权重和输入。矩估计允许各层采用不同的固定、中心化单位方差 Lipschitz 激活。矩阶先固定，常数可依赖激活、深度和宽比。OU 常数独立于扰动参数；维数阈值可依赖该参数，在紧离零区间上一致。

A.1 输出和隐藏范数的任意固定阶矩

引理 3. 令 $q_\ell = \|h^{(\ell)}\|^2/k_\ell$。每个固定 $r > 0$ 均有

$$\mathbb{E}q_\ell^r \le C_r, \qquad \mathbb{E}|q_\ell - 1|^r \le C_r d^{-r/2}, \qquad \mathbb{E}|F|^r \le C_r.$$

单个特征及固定个特征的乘积均有任意固定阶矩界，允许不同层或具有上述高斯边缘的耦合输入。

证明. 写 $b(q) = \mathbb{E}\sigma(\sqrt{q}G)$、$v(q) = \mathbb{E}\sigma(\sqrt{q}G)^2$。Lipschitz 性、中心化及单位方差给出全局界

$$\mathbb{E}|\sigma(\sqrt{q}G)|^s \le C_s(1 + q^{s/2}), \qquad |b(q)| + |v(q) - 1| \le C|q - 1| \quad (q \ge 0). \tag{26}$$

这里用 $|\sigma(z)| \le C(1 + |z|)$ 及 $|\sqrt{q} - 1|(\sqrt{q} + 1) = |q - 1|$。若 Y_i 给定 $\mathcal{F}$ 后独立且中心化，则

$$\mathbb{E}\left[\left|N^{-1}\sum_i Y_i\right|^{2m}\middle|\mathcal{F}\right] \le C_m N^{-m} \max_i \mathbb{E}[|Y_i|^{2m} \mid \mathcal{F}]. \tag{27}$$

展开 $2m$ 次幂，单次指标项为零；余项至多含 m 个指标，共 $O_m(N^m)$ 项，由 Hölder 控制。

给定前层，本层行输出独立同分布为 $\sigma(\sqrt{q_{\ell-1}}G)$。先由 Jensen 与式 (26) 归纳得 $\mathbb{E}q_\ell^{2m} \le C_m$；再对 $Y_i = (h_i^{(\ell)})^2 - v_\ell(q_{\ell-1})$ 用式 (27)，得到

$$\mathbb{E}|q_\ell - 1|^{2m} \le C_m d^{-m} + C_m \mathbb{E}|q_{\ell-1} - 1|^{2m} = O(d^{-m}).$$

初值 $q_0 = d^{-1}\sum_i X_i^2$ 由同一展开给出。全一读出分解为：

$$F = \sqrt{k_L} b_L(q_{L-1}) + k_L^{-1/2}\sum_i \{h_i^{(L)} - b_L(q_{L-1})\}.$$

第一项的 $2m$ 阶矩至多 $C_m k_L^m \mathbb{E}|q_{L-1} - 1|^{2m} = O(1)$，第二项由式 (27) 及正矩界控制。取 $2m \ge r$ 即得所需阶数；条件行估计与 Hölder 分别给出单特征和固定乘积矩。 □

A.2 梯度的任意固定阶矩

令 $A_\ell = W^{(\ell)}/\sqrt{k_{\ell-1}}$，$B_\ell = \|A_\ell\|_{\mathrm{op}}$。下文 P 为 $1 + \|X\|/\sqrt{d}$ 与有限个 B_ℓ 的非负固定次数多项式，也允许第二组独立高斯矩阵的归一化算子范数。此类 P 的固定阶矩一致有界：两球面的 $1/4$ 网至多各含 $9^m, 9^r$ 点，网逼近与标量高斯尾界给 $m \times r$ 标准高斯矩阵 G 的尾界

$$\Pr\{\|G\|_{\mathrm{op}} > 2u\} \le 2\,9^{m+r} e^{-u^2/2}.$$

有界宽比下积分即得归一化算子范数的固定阶矩。

引理 4. 对 *Lipschitz* 激活，弱梯度满足 $\mathbb{E}\|\nabla_W F\|^r \le C_r$，每个固定 $r > 0$ 均成立。

证明. 前向递推给出 $\|h^{(\ell)}\|/\sqrt{k_\ell} \le P$。定义

$$\beta_L = k_L^{-1/2}\mathbf{1}, \quad \lambda_\ell = \mathrm{diag}(\sigma_\ell'(u^{(\ell)}))\beta_\ell, \quad \beta_{\ell-1} = A_\ell^T\lambda_\ell.$$

由有界斜率，$\|\beta_\ell\| + \|\lambda_\ell\| \le P$，且

$$\nabla_{W^{(\ell)}} F = \lambda_\ell (h^{(\ell-1)})^T/\sqrt{k_{\ell-1}}, \qquad \|\nabla_W F\|^2 \le P. \tag{A3}$$

网络局部 Lipschitz，故几乎处处的链式公式给出弱梯度。

□

A.3 两类激活的梯度变化

引理 5. 令 $W'=\sqrt{1-t}W+\sqrt{t}Z$，Z 独立标准高斯，$0<t\le 1/2$。对任意范数多项式 P 和固定 $t>0$，充分大的 d 下两类激活均满足

$$\mathbb{E}[P\|\nabla F(W',X)-\nabla F(W,X)\|^2]\le C_P t^{1/4}.$$

常数独立于 t，维数阈值在紧离零区间上一致。

证明. 对每个固定 $s>0$，反向坐标满足

$$\mathbb{E}[P|\beta_{\ell,i}|^{2s}]\le C_{P,s}k_\ell^{-s}. \tag{28}$$

终层直接成立。其余层给定 $h=h^{(\ell)}$，下一层高斯矩阵右乘任何固定 h 的正交变换后分布不变，β_ℓ 相应旋转；其范数由独立于 h 的下游算子范数控制，故 $\mathbb{E}[\|\beta_\ell\|^{2s}\mid h]\le C_s$。沿 h 及 h 的正交补分解，用后者均匀球面方向的坐标矩得

$$\mathbb{E}[|\beta_{\ell,i}|^{2s}\mid h]\le C_s\left(k_\ell^{-s}+|h_i|^{2s}/\|h\|^{2s}\right).$$

$h=0$ 时分布对全部旋转不变，上式的比值取零。在 $q_\ell\ge 1/2$ 上用特征正矩，在补集上用比值不超过一及 $\Pr(q_\ell<1/2)\le C_m d^{-m}$（引理 3），得到无权坐标矩；再对 P 用 Cauchy–Schwarz 即得 (28)。这里 U 在 S^{n-1} 上均匀时，标准高斯径向分解给 $\mathbb{E}|U_1|^{2s}=\Gamma(s+1/2)\Gamma(n/2)/(\sqrt{\pi}\Gamma(n/2+s))\le C_s n^{-s}$。

前向递推给 $\|A'_\ell-A_\ell\|_{\mathrm{op}}\le\sqrt{t}P$、$\|h'^{(\ell)}-h^{(\ell)}\|/\sqrt{k_\ell}\le\sqrt{t}P$。记 $D_\ell=\mathrm{diag}(\sigma'(u^{(\ell)}))$。光滑支中，给定前层，$u'_i-u_i$ 是中心高斯，方差不超过 $C(tq_{\ell-1}+\|h'-h\|^2/k_{\ell-1})$，故 $\mathbb{E}|\sigma'(u'_i)-\sigma'(u_i)|^4\le C\mathbb{E}|u'_i-u_i|^4\le Ct^2$。分段线性支中，令 $\mathcal{G}=\{q_{\ell-1},q'_{\ell-1}\ge 1/2\}$。给定前层，在 $\mathcal{G}$ 上两预激活为中心高斯，相关系数为 $\sqrt{1-t}\langle h,h'\rangle/(\|h\|\|h'\|)$，其夹角满足

$$\omega_\ell\le C\left(\sqrt{t}+\frac{\|h-h'\|}{\sqrt{\|h\|\|h'\|}}\right)\le\sqrt{t}P.$$

二维高斯极角均匀性给条件异号概率 ω_ℓ/π，而 $\Pr(\mathcal{G}^c)\le C_m d^{-m}$，因此 $\Pr(u_iu'_i<0)\le C\sqrt{t}+C_md^{-m}$。零预激活在 $\mathcal{G}$ 上概率为零；零点任选有界斜率，其贡献由 $\Pr(\mathcal{G}^c)$ 吸收，故 $\mathbb{E}|\sigma'(u'_i)-\sigma'(u_i)|^4\le C\sqrt{t}+C_md^{-m}$。于是两支均有

$$\mathbb{E}[P\|(D'_\ell-D_\ell)\beta_\ell\|^2]\le\sum_i(\mathbb{E}[P^2\beta_{\ell,i}^4])^{1/2}(\mathbb{E}|\sigma'(u'_i)-\sigma'(u_i)|^4)^{1/2}\le C_P(t^{1/4}+d^{-1}).$$

从相同读出反向使用 $\lambda'_\ell-\lambda_\ell=D'_\ell(\beta'_\ell-\beta_\ell)+(D'_\ell-D_\ell)\beta_\ell$ 及 $\beta'_{\ell-1}-\beta_{\ell-1}=A_\ell^T(\lambda'_\ell-\lambda_\ell)+(A'_\ell-A_\ell)^T\lambda'_\ell$。算子范数只改变 P，矩阵差项为 $O(t)$；固定深度反向归纳及梯度块公式 (A3) 的乘积差均保留此界。固定 $t>0$ 后取 $d^{-1}\le t^{1/4}$ 即得结论；光滑支全程为 $O(t)$。 □

A.4 OU 梯度变化与余项

引理 6. 式 (6) 和式 (7) 以统一指数 $\delta=1/4$ 成立，维数阈值按本节约定。

证明. 记 c_N 为对 X 平均后的第 N 阶参数 Hermite 能量，$a_t=\sqrt{1-t}$，并令 $G(t)=\mathbb{E}\|\nabla F(W(t),X)-\nabla F(W,X)\|^2$。正交性和 $\partial_i H_\nu=\sqrt{\nu_i}H_{\nu-e_i}$ 给

$$G(t)=2\sum_{N\ge1}N(1-a_t^{N-1})c_N\le Ct^\delta.$$

末步由引理 5，统一取 $\delta=1/4$。取 $t=1-e^{-2\tau}$ 即得第一式；$t>1/2$ 时由梯度二阶矩增大常数即可。对式 (7) 的余项，同一正交展开及关于 Z 的分部积分给

$$\mathbb{E}\|E_t\|_{L^2_X}^2=\sum_{N\ge1}\{2(1-a_t^N)+tN-2tNa_t^{N-1}\}c_N.$$

当 $N\ge2$ 时 $a_t^N\ge1-Nt/2$；当 $N=1$ 时大括号等于 $(1-a_t)^2\le t^2$。因此

$$\mathbb{E}\|E_t\|_{L^2_X}^2\le t^2\mathbb{E}\|\nabla F\|^2+tG(t)\le Ct^{1+\delta}. \tag{29}$$

先对有限 Hermite 和计算，再在高斯 Sobolev 范数下取极限。 □

A.5 高斯分部积分的定义域

引理 7. 设 $g:\mathbb{R}^p\to\mathbb{R}^p$ 属于高斯 $W^{1,2}$，也允许值域带独立的外部 L^2 变量。定义 $\delta g=\operatorname{div} g-W\cdot g$。则其闭扩张满足

$$\mathbb{E}(\delta g)^2=\mathbb{E}\|g\|^2+\mathbb{E}\sum_{i,j}(\partial_i g_j)(\partial_j g_i)\le \mathbb{E}\{\|g\|^2+\|Dg\|_{\mathrm{HS}}^2\}. \tag{A13}$$

证明. 对紧支撑光滑场，展开 $(\delta g)^2$ 并逐坐标两次分部积分得等式，再用 $2uv\le u^2+v^2$。一般 g 先乘径向截断 χ_R（$\|\nabla\chi_R\|_\infty\le C/R$），再在紧集卷积。尾部及截断导数由 $g,Dg\in L^2$ 控制；高斯密度在紧集有正上下界，故所得紧支撑光滑场在高斯 $W^{1,2}$ 中收敛于 g。上述不等式使散度在 L^2 中收敛；对测试函数分部积分识别极限为分布散度，并将等式传至极限。外部变量先用简单函数逼近再积分。 □

B 对称张量的 Gram 矩阵界

固定整数 $m\ge 5$、$q\ge 1$。设单位行 $w_1,\dots,w_k$ 满足 $\max_{i\ne j}|\langle w_i,w_j\rangle|\le\delta$。对多重指标 $r\in\mathbb{N}^k$、$|r|=q$，定义

$$P_r=\operatorname{Sym}\bigotimes_j w_j^{\otimes mr_j},\qquad Z_{r,i}=\operatorname{Sym}\bigotimes_j w_j^{\otimes(mr_j-\mathbf{1}_{j=i})},\quad r_i>0.$$

Sym 是全部槽位排列的平均，范数取继承的 Hilbert 张量范数。令 $\mathcal{F}$、$\mathcal{F}^-$ 分别以 P_r、$Z_{r,i}$ 为列。则

$$cI\preceq\mathcal{F}^*\mathcal{F}\preceq CI,\qquad cI\preceq(\mathcal{F}^-)^*\mathcal{F}^-\preceq CI, \tag{30}$$

只要 $\delta+\sum_{h=1}^q k^h\delta^{mh-2}=o(1)$；$c,C>0$ 只依赖 m,q。

精确配对公式为

$$\left\langle\operatorname{Sym}\bigotimes_{a=1}^R u_a,\operatorname{Sym}\bigotimes_{a=1}^R v_a\right\rangle=\frac{1}{R!}\sum_{\pi\in\mathfrak{S}_R}\prod_a\langle u_a,v_{\pi(a)}\rangle.$$

若列的标签重数为 (n_j)，对角中的无错配项为 $\prod_j n_j!/R!$，有只依赖总次数的正下界；其余对角项为 $O(\delta)$。纯列与删除列的重数分别为 mr、$mr-e_i$，各族内均互异：后者模 m 的余数唯一确定 i。同一支撑内的非对角项至少有一个错配，故为 $O(\delta)$，列数有固定上界。另一列若含 $h\ge1$ 个新标签，至少 $mh-1$ 个槽错配，故内积至多 $C\delta^{mh-2}$；此类列至多 Ck^h 个。因此每个 Gram 矩阵与上述正对角矩阵之差的绝对行和至多 $C(\delta+\sum_h k^h\delta^{mh-2})=o(1)$。对称矩阵的 Schur 界即得 (30)。

行长在固定正区间时，各列只乘有固定上下界的标量，结论不变。对按输入宽度归一化的高斯行，行长一致趋于一且 $\delta=O(\sqrt{\log d/d})$、$k\asymp d$，故扰动趋零；事件补集概率可取任意固定负幂。

C 计算树展开的张量估计

所有空间取实 Euclidean 空间及其 Hilbert 张量积；$\|\cdot\|_{\mathrm{HS}}$ 表示张量 Hilbert 范数，$\mathrm{Flat}_{S|S^c}$ 表示按索引位置分组的矩阵化。模式指系数张量的索引位置；不同模式可取相同值，或由同一原节点索引复制。各层宽度在 $[cd,Cd]$ 内，深度、多项式次数、涉及的层数和操作次数均固定。记 $\delta_d=L_d/\sqrt{d}$、$\rho_d=L_d/d$，其中 L_d 是可随有限次运算增大的固定对数幂。概率估计分别基于各网络的高斯边缘；事件上，以下估计对两网络的任意耦合成立。

C.1 系数张量的范数界与线性求和

计算树的系数张量。 从归一化读出向量沿原计算树向下展开。当前模式代表原节点指标，模式 p 的一次展开为

$$Je_a=\bigotimes_{t=1}^q u_a^{(t)},\qquad q\ge1,\qquad \|U_t\|_{\mathrm{op}}\le C,\quad U_t=(u_a^{(t)})_a. \tag{31}$$

因子 e_a 保留父索引；同父索引的因子仍共享该索引。可在任意节点停止展开，保留其下的整个张量映射。依赖两网络的映射仅作用于停止叶，每个映射输出一个因子；输出多因子的非线性映射须先沿原计算树展开，纳入系数张量。

引理 8（展开算子的范数）。 上述展开在全部保留因子上的复合称为展开算子；固定次复合均有界。令 $\Delta_q e_a = e_a^{\otimes q}$，则 $J = (\bigotimes_t U_t^*)\Delta_q$，而 Δ_q 为等距嵌入，故 $\|J\| \le \prod_t \|U_t\|$。同样，若 $F_j : e_a \mapsto f_a^{(j)}$ 有界，则共享指标的乘积特征 $e_a \mapsto \bigotimes_j f_a^{(j)}$ 有界。其 Gram 矩阵为 $\circ_j F_j^* F_j$，且对半正定矩阵 $X \preceq bI, Y \succeq 0$，$X \circ Y \preceq b\,\mathrm{diag}(Y)$。

引理 9（展开保持范数和切片界）。 设 E 有 r 个模式，满足

$$\|E\|_{\mathrm{HS}} \le C, \qquad \max_{p,a} \|E(e_a \text{ 于模式} p, \cdot)\|_{\mathrm{HS}} \le \delta_d, \qquad \|\,\mathrm{Flat}_{S|S^c} E\|_{\mathrm{op}} \le \delta_d \quad (\varnothing \ne S \ne [r]). \tag{32}$$

除 $r = q = 1$ 外，一次展开保持这些结论，常数可增大固定倍数。

证明。 Hilbert 范数界来自展开算子有界。对新核的非平凡分割，若新块在同一侧，即在旧核非平凡分割的两侧复合有界算子。若新块跨越两侧，两侧暂留正交父指标 a。中央算子按 a 分块对角，每块是旧切片 $E(e_a, \cdot)$ 的矩阵化，其算子范数不超过 Hilbert 范数 δ_d。再施加两侧行映射即得结论，旧核为一模时亦成立。

除 $r = q = 1$ 外，新张量至少有两个索引；其坐标切片满足 $\|E_{\mathrm{new}}(e_a \text{ 于} p, \cdot)\|_{\mathrm{HS}} \le \|\,\mathrm{Flat}_{\{p\}|\{p\}^c} E_{\mathrm{new}}\|_{\mathrm{op}} \le C\delta_d$，由矩阵化界得证。$r = q = 1$ 时无非平凡矩阵化，须用高斯连续积的坐标估计。 □

线性路径上的高斯矩阵乘积。 令 A_ℓ 为独立、按输入宽度平方根归一化的高斯矩阵。任意固定连续积 $P = A_b \cdots A_a$ 满足

$$\|P\|_{\mathrm{op}} \le C, \qquad \max_{ij} |P_{ij}| \le C_M \sqrt{\log d / d} \tag{33}$$

且可使失败概率为 $O(d^{-M})$。算子范数由各层相乘得到；条件于 $Q = A_{b-1} \cdots A_a$ 后，$(A_b Q)_{ij}$ 是方差 $\|Qe_j\|^2 / n_{b-1} \le C/d$ 的高斯变量，尾界与有限并合即得第二式。读出向量乘连续高斯积时，条件于最后未暴露的高斯因子，坐标最大值满足相同估计。这处理了首次分叉前的 $r = q = 1$ 链；分叉后模式数不减，后续步骤用前一引理。停止展开或施加恒等映射无须概率估计。有限原树核全部满足 (32)。这里的一元链仅由原网络矩阵组成。

外部映射及重建。 各索引上的有界单因子映射保持非平凡矩阵化界，但未必保持坐标切片界。每次收缩后，须沿原计算树重建系数张量：在对应父节点停止展开，以所得跨网络收缩矩阵为叶上外部映射。停止深度可不同，根到叶的内部路径仍只含原网络矩阵。以下坐标切片界仅用于这些重建的系数张量。

引理 10（线性路径的精确求和）。 令底层行向量为 b_j，父层矩阵为 $U = (u_{aj})$，并设 $z_a = \sum_j u_{aj} b_j$。一个父节点有 t 个线性子槽以及次数 $q_1, \dots, q_h \ge 2$ 的非线性子槽，则其未对称化张量严格等于

$$z_a^{\otimes t} \otimes \bigotimes_{\ell=1}^{h} \left(\sum_j u_{aj} b_j^{\otimes q_\ell} \right). \tag{34}$$

证明。 各有序子槽独立求和；多线性性使线性槽得到 z_a，非线性槽保留原式。对称化是固定次数的槽排列平均，可在求和后施加。故纯一元链为归一化矩阵乘积，无额外 $\sqrt{\text{宽度}}$ 因子。非线性因子仍共享 a，不能视为独立阵列。坐标掩码一般不与求和交换；须先在全部因子的展开算子中证明删掩码误差为 $o(1)$，再恢复原张量、应用本式。 □

C.2 同层索引的旋转与双索引收缩

概率工具。 若确定性矩阵 $A_j : \mathbb{R}^u \to \mathbb{R}^v$ 满足 $\max\{\|\sum_j A_j^* A_j\|, \|\sum_j A_j A_j^*\|\} \le s^2$，则独立标准高斯系数满足

$$\mathbb{P}\left(\left\| \sum_j g_j A_j \right\| > t \right) \le 2(u+v) \exp[-t^2/(2s^2)].$$

用自伴膨胀 $H_j = \left(\begin{smallmatrix} 0 & A_j^* \\ A_j & 0 \end{smallmatrix}\right)$，$\|\sum_j H_j^2\| \le s^2$；矩阵高斯 Laplace 界 $\mathbb{E}\,\mathrm{tr}\exp(\lambda_{\mathrm{c}} \sum_j g_j H_j) \le \mathrm{tr}\exp(\lambda_{\mathrm{c}}^2 \sum_j H_j^2/2)$ 配合 $\lambda_{\mathrm{c}} = t/s^2$ 得到上尾，对负号重复即得双侧界。以下只用其维数为固定 d 次幂时的 $O(s\sqrt{\log d})$ 结论。

引理 11（同层旋转下的坐标切片）。 在同一原网络层同时展开所有未停止模式。选当前高斯层矩阵的列索引模式 p，它随该矩阵右乘正交矩阵而旋转，排除保留的父索引 e_a 及其确定性复制。另选不同模式 q，总模式数 $N \geq 3$。令 E 为未加外部映射的系数张量。以任意高多项式概率有

$$\max_{j} \sup_{\|v\|\leq 1} \|E(e_j \text{ 于} p, v \text{ 于} q, \cdot)\|_{\mathrm{HS}} \leq \rho_d. \tag{35}$$

此时不展开更低层，较高层的停止索引不动。

证明。 条件于一个满足 (32) 的核，置 $A_j v = E(e_j, v, \cdot)$。直接按矩阵元素求和可知

$$\left\| \sum_j A_j^* A_j \right\| = \| \operatorname{Flat}_{\{q\}|\{q\}^c} E \|^2 \leq \delta_d^2, \qquad \left\| \sum_j A_j A_j^* \right\| = \| \operatorname{Flat}_{\{p,q\}|\{p,q\}^c} E \|^2 \leq \delta_d^2.$$

第二分割非平凡恰好使用 $N \geq 3$。前述级数界、$\|g\| \geq c\sqrt{d}$ 的高斯尾界，给均匀球面向量 $u = g/\|g\|$ 的收缩范数至多 $C_M \delta_d \sqrt{\log d / d}$。对独立 Haar 矩阵的各列作并合，不要求列独立。该高斯层矩阵右乘此正交矩阵，分布不变，其全部列索引模式同时旋转。未固定模式的旋转等距；若 q 也是该层列索引，对 v 的上确界不变。故 Haar 估计即给原坐标估计。核和模式只有固定有限种。 □

推论 12（重复坐标项的范数）。 若至少两个模式对应同一高斯层矩阵的列索引，且总模式数至少三，则其中至少两个索引取相同值的部分满足

$$\|E_{\mathrm{coll}}\|_{\mathrm{HS}}^2 \leq \sum_{p<q} \sum_{j} \|E(e_j \text{ 于} p, e_j \text{ 于} q, \cdot)\|^2 \leq C d \rho_d^2 = o(1). \tag{36}$$

在该层引入模式时估计此部分，再经有界展开算子传递，误差仍为 $o(1)$。仅删除不同原节点索引同值的项，保留同父索引的确定性复制。

推论 13（原始系数的矩与坐标界）。 设 C_R 为固定深度、固定次数、零常数高斯多项式网络的原始 R 阶系数，允许保留有序因子、对称化及固定有限个展开项的和。对每个固定 $0 < p < \infty$，$\sup_d \mathbb{E}\|C_R\|_{\mathrm{HS}}^p < \infty$。若全部索引由同一原高斯层的列索引产生（不含父索引的确定性复制），宽度为 $k \asymp d$，则对任意固定 M，以失败概率 $O(d^{-M})$ 同时有

$$\max_{i_1,\dots,i_R \text{ 互异}} |(C_R)_{i_1 \cdots i_R}| \leq L_d k^{-R/2}, \qquad \| \operatorname{Coll}_R C_R \|_{\mathrm{HS}}^2 \leq L_d / d \quad (R \geq 3), \tag{37}$$

其中 L_d 为固定对数幂；$R \geq 3$ 时还有 $\mathbb{E}\| \operatorname{Coll}_R C_R \|_{\mathrm{HS}}^2 = o(1)$。矩界由原展开算子范数相乘、归一化高斯矩阵算子范数的固定阶矩及 Hölder 不等式得到，无须因子独立。列置换不变性使互异坐标的二阶矩相同，每个至多 $C/(k)_R = O(k^{-R})$。每个坐标是固定次数 D_0 的高斯多项式，$\|Z\|_u \leq (u-1)^{D_0/2} \|Z\|_2$；取 $u = C_M \log d$，在 $e\|Z\|_u$ 处用 Markov 并对至多 k^R 个坐标作并集界，即得第一界。对各有序展开项用引理 11及式 (36)得第二界；固定有限次排列、求和不改阶数。矩界及 Cauchy–Schwarz 给 $\mathbb{E}\| \operatorname{Coll}_R C_R \|^2 \leq L_d/d + (\mathbb{E}\|C_R\|^4)^{1/2} O(d^{-M/2}) = o(1)$。上述仅控制未加跨网络外部映射的原始系数。

引理 14（两个父索引的收缩与二阶非对角项）。 在一个未加掩码的原始切口中，设不同父模式 p, q 的所选线性槽与教师行收缩后给出 η_i, ζ_i，其 ℓ^2 范数有界。模式 p 是本层引入的模式，且删去所选槽后仍有非空残余；所有完整残余家族均为有界算子。若总模式数 $R \geq 3$，完整剩余源张量 S_i 满足 $\|S_i\|_{\mathrm{HS}} \leq C\rho_d$。事实上，令 $B_i e_b = \zeta_{ib} f_b$，其中 f_b 是第二个源索引删除所选槽后的完整剩余特征；无剩余槽时取 $f_b = 1$。逐点有 $\|B_i\|_{\mathrm{HS}}^2 = \sum_b |\zeta_{ib}|^2 \|f_b\|^2 \leq C$。将原始切片 $E(e_a, \cdot)$ 看作从 q 索引到其余索引的算子 T_a。式 (35)给 $\|T_a\|_{\mathrm{op}} \leq \rho_d$，故 $\|T_a B_i^*\|_{\mathrm{HS}} \leq C\rho_d$。保留索引 a，乘 η_{ia} 后平方求和，再施加完整剩余特征即得界。估计逐点成立，无须 B_i 与网络独立。

若 $R = 2$、两个索引属于同一原网络层，且删除所选槽后两个模式均有非空残余，式 (37)给 $\max_{a \neq b} |D_{ab}| \leq L_d/d$；保留两标签后施加完整特征映射，非对角部分满足

$$\|S_i^{\mathrm{off}}\| \leq C \Big(\sum_{a \neq b} |D_{ab} \eta_{ia} \zeta_{ib}|^2 \Big)^{1/2} \leq C L_d / d.$$

两种界与教师切片和 $C\sqrt{d}\|C\|$ 配对均为 $o(1)\|C\|$。二阶结论不含对角及坐标–向量切片；不同层索引须保留根索引另行处理。同父索引的确定性复制不算两个父节点，不能用本估计。

C.3 保留剩余因子的局部收缩估计

引理 15 (残余家族与局部收缩)**.** 设 $F_a = \sum_b U_{ab} Q_b$，U 为原高斯层或连续积，Q_b 为正次数原计算树；停止叶允许有界自适应单槽映射。完整家族 $e_a \mapsto F_a$ 有界，且当 F_a 至少有两个输出因子时，每个非平凡输出矩阵化均至多 $C\delta_d$。同指标乘积家族也有界。

固定一个有 $m \geq 2$ 个因子的教师节点。设它接触源父索引 a 的一个旧收缩因子 ℓ_a，该源列除 ℓ_a 外至少还有一个完整因子，且 $G_{ia} = \langle a_i, \ell_a \rangle$ 满足 $\|G\|_{\max} \leq \kappa_d$、$\sup_i \|G_{i,:}\|_2 \leq C$。所有其他完整残余均保留，其他源父标签的映射不依赖 a。教师、源原系数分别为 C, D。则完整配对满足：

$$|\text{pairing}| \leq \begin{cases} C\kappa_d \|C\| \|D\|, & \text{本叶还接触另一源父节点,} \\ C\sqrt{d}\,\alpha(D)(\delta_d + \kappa_d)\|C\|, & \text{本叶全在父节点} a\text{,} \end{cases} \tag{38}$$

第二行中，多模核取 $\alpha(D) = \|\operatorname{Flat}_{a|\text{rest}} D\|$；一模核 $D = d$ 取 $\alpha(D) = \|d\|_\infty$，但要求除 ℓ_a 外至少有两个完整因子。因此 $\alpha(D), \delta_d, \kappa_d \leq L_d/\sqrt{d}$ 时两类配对均为 $o(1)$。

证明. 残余家族为原展开算子与 U^* 的复合。固定 a，以 $U_{a,:}$ 为读出重建核；式 (33)、引理 9 给非平凡矩阵化界，外部单槽映射保持此界。对角等距嵌入保证乘积家族有界。

若还接触另一父节点，先将来自其他父节点的全部 $t \geq 1$ 个槽映到正交教师标签 i。该映射的伴随为 $(A^*)^{\otimes t}\Delta_t$，故有界。保留 a, i 后乘 G_{ia} 的算子范数为 $\|G\|_{\max}$；再在每个 i 块内提升本列的剩余家族并完成其余配对。另有至少一个完整因子保证家族有界；即使被本叶完全收缩，仍留下 ℓ^2 有界标量家族，不能无权删标签。这些是完整张量上的有界算子，无部分迹或逐 i 求和损失。

以下本叶全在 a。固定 i，其余因子收缩后形成家族 H_j：完全收缩者是 ℓ^2 有界向量；部分收缩者的列范数至多 $C\delta_d$；完全保留者仍为有界家族。本叶尚有 $m - 1 \geq 1$ 个槽，故至少一个因子被部分或完全收缩。

令 $B_i e_a = G_{ia} \bigotimes_j H_j e_a$。有部分收缩因子时用 $\|G_{i,:}\|_2$，否则用 $\|G\|_{\max}$ 及完全收缩向量的 ℓ^2 范数，均得 $\|B_i\|_{\text{HS}} \leq C(\delta_d + \kappa_d)$。多模情形把其余模式展开记为 T，于是 $\|(B_i \otimes T)D\|_{\text{HS}} \leq C\alpha(D)(\delta_d + \kappa_d)$。

一模情形至少有两个 H_j。若有部分收缩者 H_u，取 $j \neq u$，利用 $H_j^* H_j \preceq CI$ 和 $\operatorname{diag}(H_u^* H_u) \preceq C\delta_d^2 I$，Schur 乘积序给乘积家族算子范数至多 $C\delta_d$；作用于 $(d_a G_{ia})_a$ 即得 $C\|d\|_\infty \delta_d$。否则移入一个完全收缩向量 η，$\|(d_a G_{ia}\eta_a)_a\|_2 \leq C\|d\|_\infty \kappa_d$，其余至少一个家族仍有界。最后仅用一次 $\sum_i \|C(e_i, \cdot)\| \leq C\sqrt{d}\|C\|$，即得第二行。 □

二阶非对角核写成 $D - \operatorname{diag} D$ 后分别用此界；对角核的算子范数、Hilbert 范数均不增。其他掩码不适用，二阶对角也未必小。一模且仅有一个其他因子的边界使用引理 17 中的保留索引子程序。

D 实际激活的输入混沌投影与多项式近似

固定 $N > 2$，记 $A_\ell = W^{(\ell)}/\sqrt{k_{\ell-1}}$、$u = c_0 = \sqrt{2/\pi}$，并置

$$P_N(z) = \sum_{j=1}^{N} \frac{a_j z^j}{\sqrt{j!}}, \qquad Q_N(z) = \sum_{j=1}^{N} \frac{b_j z^j}{\sqrt{j!}}, \qquad b_j = \mathbb{E}[(\sigma(G)^2 - 1)\psi_j(G)]. \tag{39}$$

Q_N 仅用于分段线性分支。多项式网络使用原矩阵 $A_1, \ldots, A_t$、读出 $k_t^{-1/2}\mathbf{1}$、输出激活 A 及下层激活 $p_1, \ldots, p_{t-1}$；其形式 N 次对称系数经 I_N 映射后记为 $R_{t,N}[A; p]$，仅保留各隐藏层索引全部互异的展开项时记为 $J_{t,N}[A; p]$。输入坐标不受限制，故 $J_{1,N} = R_{1,N}$；；P_N 表示所有下层均用 P_N。可先对固定辅助变量取系数。形式取系数先于 I_N，不含更高形式次数经高斯收缩产生的第 N 阶项。

D.1 条件展开及其误差

本节所有 L^p 均对原高斯先验及输入。引理 3 和第 A 节的矩阵尾界给出

$$\|q_\ell - 1\|_p = O(d^{-1/2}), \qquad \sup_d \mathbb{E}\left[\|A_\ell\|_{\mathrm{op}}^p + |h_i^{(\ell)}|^p\right] < \infty. \tag{40}$$

固定乘积（含重复索引）也有全部固定阶矩，故 $q_\ell \notin [1/2, 2]$ 的概率可取任意多项式衰减。首层行写为 $A_{1,i:} = s_i v_i$，$\|v_i\| = 1$。高斯长度和内积尾界及矩阵尾界给出概率至少 $1 - d^{-M}$ 的事件

$$\max_i |s_i - 1| + \max_{i \neq j} |\langle v_i, v_j \rangle| \le C_M \sqrt{\log d / d}, \qquad \|A_1\|_{\mathrm{op}} \le C_M. \tag{41}$$

首层有限乘积。 若固定 t 个单位向量的 Gram 矩阵 G 满足 $\|G - I\| \le \eta$，且 $\max_i |s_i - 1| \le \delta$，则

$$\left\| \Pi_N \prod_{i=1}^{t} \sigma(s_i v_i \cdot X) - \sum_{\substack{n_i \ge 1 \\ \sum_i n_i = N}} \frac{\prod_i a_{n_i}}{\sqrt{\prod_i n_i!}} I_N\left(\mathrm{Sym} \bigotimes_i (s_i v_i)^{\otimes n_i}\right) \right\|_2 \le C_{t,N}(\eta + \delta). \tag{42}$$

在 $\mathrm{Sym}^N \mathrm{span}\{v_i\}$ 中取 $B_n = I_N(\mathrm{Sym} \bigotimes_i v_i^{\otimes n_i})$，$n_i \ge 0$、$\sum n_i = N$。其 Gram 矩阵为 G 的多项式，在 $G = I$ 附近一致可逆；投影坐标为该矩阵的逆乘 $\mathbb{E}[\prod_i \sigma(s_i Z_i) B_n(Z; G)]$，$Z \sim N(0, G)$。高斯密度的协方差导数由可积的多项式乘高斯密度控制；B_n 的系数为 G 的多项式，激活至多线性增长且 Lipschitz，故这些积分关于 (G, s) 局部 Lipschitz。在 $(I, \mathbf{1})$ 处，独立性给系数 $\prod_i a_{n_i} / \sqrt{\prod_i n_i!}$，$a_0 = 0$ 删除零次数。将 v_i 换为 $s_i v_i$ 即得上式，包含非多项式乘积的全部收缩项。特别地 $t > N$ 时近似和为空。

逐层条件展开。 令 $\chi = \sigma^2 - 1$，$f = \sigma$，或在分段线性支取 $f = \chi$。给定前层特征 $h \in \mathbb{R}^k$，置 $q = \|h\|^2/k$、$c_r^f(q) = \mathbb{E} f(\sqrt{q} G) \psi_r(G)$。条件 Hermite 展开使用

$$f(W_i \cdot h/\sqrt{k}) = \sum_{r \ge 0} c_r^f(q) \sum_{|\alpha| = r} \sqrt{\frac{r!}{\alpha!}} (h/\|h\|)^\alpha \prod_j \psi_{\alpha_j}(W_{ij}). \tag{43}$$

$q = 0$ 按实际随机变量的连续值解释。由于 $|f(x)| \le C(1 + x^2)$，$q \mapsto f(\sqrt{q}\,\cdot)$ 为 $[1/2, 2]$ 到 $L^2(\gamma)$ 的连续映射，其 Hermite 尾一致趋零。区间外用完整条件二阶矩 $C(1 + q^2)$、式 (40) 及任意高阶小概率控制。对固定多个不同行输出，条件独立性将逐因子差的条件平方期望分解为一个尾的平方期望与其余因子二阶矩的乘积，故乘积可截断，无须单行尾的高阶收敛。

固定 r，换元 $y = \sqrt{q} G$，对密度及 $\psi_r(y/\sqrt{q})$ 求导可知 $c_r^f(q) q^{-r/2}$ 在 $[1/2, 2]$ 上 Lipschitz，故换为 $c_r^f(1)$ 的误差趋零。区间外，精确有限分量的固定阶条件矩由 $c_r^f(q)$ 的增长及高斯 Hermite 矩界控制，替换后的多项式由特征矩控制；Hölder 与小概率界给 $o(1)$，不使用负阶 q 矩或 f 的导数。

固定展开含 T 个前层输出因子时，重复索引赋值至多 $C_T k^{T-1}$ 个，平方归一化因子为 k^{-T}。合并相同权重 Hermite 单项式的排序（重数仅依赖 T）后，由正交性及固定乘积矩，删去重复赋值的平方误差为 $O_T(k^{-1})$。剩余权重变量均只出现一次，Hermite 单项式成为普通权重乘积。隐藏层零阶系数为零（奇支）或 $bu(\sqrt{q} - 1) = O_{L^p}(d^{-1/2})$（分段线性支），也可在固定乘积中删去；输出层零阶项稍后单独保留。

局部误差经读出求和仍趋零：各阶段合并相同的上方权重单项式，写成

$$\Delta = \sum_g \beta_g \Psi_g(W_{>\ell}) E_g(W_{\le \ell}, X), \quad \sum_g \beta_g^2 \le C_{\mathrm{fixed}}, \quad \mathbb{E}\|\Delta\|_{L^2_X}^2 \le C_{\mathrm{fixed}} \sup_g \mathbb{E}\|E_g\|_{L^2_X}^2. \tag{44}$$

这里不同 Ψ_g 正交、每个变量次数为一，且独立于下层；系数平方和有界：读出 $k_t^{-1/2}$ 与每条边的输入宽度 $-1/2$ 次幂平方后抵消输出及各自由索引的数目，合并重数只依赖固定展开结构。从输出层向下依次取有限截断，使总 L^2 尾任意小，再用 (42) 处理互异的首层激活因子。式 (41) 与上述平方和界使首层误差趋零；坏事件上，固定乘积和固定次数多项式的矩至多按维数的固定多项式增长，由任意高阶失败概率吸收。若某节点次数超过 N，其不同子树至少给出超过 N 个互异首层因子，投影近似为空。故各层截断达到 N 后表达式稳定；先令 $d \to \infty$，再令截断误差趋零，得

$$\Pi_N F_{t,+}^f = J_{t,N}[H_f; P_N] + o_{L^2}(1), \qquad H_\sigma = P_N, \quad H_\chi = Q_N. \tag{45}$$

其中 $F_t^f = k_t^{-1/2}\sum_i f((A_t h^{(t-1)})_i)$，$F_{t,+}^f$ 为其减去给定前层的条件均值。$t=1$ 时直接展开每行：$\mathbb{E}f(sG)\psi_N(G)$ 关于 $s\in[1/2,2]$ Lipschitz，故可换成 $s^N\mathbb{E}f(G)\psi_N(G)$。首层向量映射 $e_i\mapsto v_i^{\otimes N}$ 有界，因为其 Gram 绝对行和至多 $\sum_j|\langle v_i,v_j\rangle|^2\le\|V\|_{\mathrm{op}}^2$。读出范数为一，逐行 $O(\max_i|s_i-1|)$ 的系数误差因此给总 $o(1)$，坏事件同上。

D.2 二次对角与索引恢复

对完整上部多项式，$r\ge 3$ 的重复坐标由推论 13 控制，但不能直接用于受索引限制的 J。二次项另满足：输入宽度为 k、深度为 t、各层激活 $p_j(z)=\sum_{r\ge1}g_{j,r}z^r$ 时，

$$\mathbb{E}\|\operatorname{Diag}D_2-\lambda I_k/\sqrt{k}\|_{\mathrm{HS}}^2=O(k^{-1}),\qquad \lambda=g_{t,2}\prod_{j<t}g_{j,1}^2\sqrt{k_t/k}. \tag{46}$$

正次网络二次项恰有一个二次节点；节点位于第 j 层时，去掉固定标量后为 $D_2^{(j)}=B_j^T\operatorname{diag}(v_j)B_j$，其中 $B_j=A_j\cdots A_1=C_jA_1$，$v_j=A_{j+1}^T\cdots A_t^T\mathbf{1}/\sqrt{k_t}$。令 $H_j=C_j^T\operatorname{diag}(v_j)C_j$。条件于 H_j，A_1 各列独立，故

$$\mathbb{E}((D_2^{(j)})_{ii}\mid H_j)=\operatorname{tr}H_j/k,\qquad \mathbb{E}\sum_i|(D_2^{(j)})_{ii}-\operatorname{tr}H_j/k|^2=2\mathbb{E}\|H_j\|_{\mathrm{HS}}^2/k=O(k^{-1}).$$

末步用 $\|H_j\|_{\mathrm{HS}}\le\|C_j\|_{\mathrm{op}}^2\|v_j\|$。$j<t$ 时 v_j 独立于 C_j，均值零、协方差 I/k_j，所以 $\mathbb{E}|\operatorname{tr}H_j|^2=k_j^{-1}\mathbb{E}\sum_a\|C_{j,a:}\|^4=O(1)$。$j=t$ 时 $\operatorname{tr}H_t=\|C_t\|_F^2/\sqrt{k_t}$，均值为 $\sqrt{k_t}$，且方差为 $O(k_t^{-1})$：对独立下一层 A，

$$\mathbb{E}(\|AC\|_F^2\mid C)=\frac{k_{\mathrm{new}}}{k_{\mathrm{old}}}\|C\|_F^2,\qquad \operatorname{Var}(\|AC\|_F^2\mid C)=\frac{2k_{\mathrm{new}}}{k_{\mathrm{old}}^2}\|CC^T\|_{\mathrm{HS}}^2=O_{L^1}(1),$$

沿固定长度乘积用全方差公式归纳得 $\operatorname{Var}\|C_t\|_F^2=O(1)$。乘回标量证明(46)，亦适用于辅助变量取系数。

引理 16 (去掉索引互异限制)**.** *设 $A,p_1,\dots,p_{t-1}$ 零常数、次数固定且系数一致有界，$t\ge2$。以 $[p]_r$ 表示 z^r 系数，则*

$$R_{t,N}[A;p]-J_{t,N}[A;p]=\sum_{s=1}^{t-1}\lambda_sJ_{s,N}[p_s^2;p_{<s}]+o_{L^2}(1),\qquad \lambda_s=[A]_2\prod_{j=s+1}^{t-1}[p_j]_1^2\sqrt{k_t/k_s}. \tag{47}$$

证明. 从完整展开出发，依次施加第 $s=1,\dots,t-1$ 层的互异限制。处理第 s 层时，上部仍是完整多项式。式 (46) 将其二次对角写成 $\lambda_sI/\sqrt{k_s}$ 加 Hilbert–Schmidt 小误差。记第 s 层多项式输出为 h_s；主项识别两个父标签，得到 $\lambda_sk_s^{-1/2}\sum_ih_{s,i}^2$；下方已有的互异限制使其恰为 $\lambda_sJ_{s,N}[p_s^2;p_{<s}]$，两个相等因子仍各占一个原槽。一次没有重复坐标，更高次重复由原始碰撞估计控制。上述误差均通过共同下层的原展开、坐标投影和对称化传递，其算子范数由有限个 $\|A_j\|_{\mathrm{op}}$ 的固定次幂控制。固定次数高斯多项式的矩等价将系数误差提升为 L^4 小量，Hölder 与(8) 给每步函数误差 $o_{L^2}(1)$。对有限个接口求和即得结论，不需上下层误差独立。 □

右侧各 J 的高度严格小于 t，从 $J_{1,N}=R_{1,N}$ 强归纳，便将 $J_{t,N}[A;p]$ 写成 $R_{t,N}[A;p]$ 加有限个更浅的裸网络。各浅根仍零常数、系数一致有界；超过 N 次的项不贡献形式 N 次系数，可删去。

D.3 条件均值递推与浅层修正

分段线性支对 $f=\sigma,\chi$ 有精确公式

$$\mathbb{E}f(\sqrt{q}G)=\lambda_f(q-1)+c_f(\sqrt{q}-1)^2,\quad (\lambda_\sigma,c_\sigma)=(bu/2,-bu/2),\quad (\lambda_\chi,c_\chi)=(1,b^2u^2). \tag{48}$$

由 $|\sqrt{q}-1|\le|q-1|$ 和引理 3，乘读出因子 $\sqrt{k_t}$ 后的二次余项仍为 $O_{L^2}(d^{-1/2})$。$t\ge2$ 时线性项等于 $\lambda_f\sqrt{k_t/k_{t-1}}F_{t-1}^{\chi}$；$t=1$ 时为 $\lambda_f\sqrt{k_1}(q_0-1)$，被 $N>2$ 投影精确消去。结合(45) 得

$$\Pi_NF_t^f=J_{t,N}[H_f;P_N]+\lambda_f\sqrt{k_t/k_{t-1}}\Pi_NF_{t-1}^{\chi}+o_{L^2}(1),\quad t\ge2, \tag{49}$$

初值为 $\Pi_NF_1^f=R_{1,N}[H_f]+o_{L^2}(1)$。代入引理 16 的浅层表示，对高度归纳并合并同高根多项式，得到

$$\mathcal{Q}_N=R_{L,N}[P_N;P_N]+\sum_{s=1}^{L-1}R_{s,N}[A_{s,d};P_N], \tag{50}$$

$$\boxed{\mathbb{E}_W\|\Pi_N F_L - \mathcal{Q}_N\|_{L^2_X}^2 \longrightarrow 0, \qquad N > 2.} \tag{51}$$

这里 $A_{s,d}$ 是零常数、次数至多 N 的确定性多项式，系数由固定激活系数和有限个宽度比构成，故一致有界。奇支的条件均值及二次系数均为零，可取所有 $A_{s,d} = 0$，无需 χ；$L = 1$ 时求和为空。以下比较对次数固定、系数有界的任意浅根一致成立，故无需计算 $A_{s,d}$ 的具体系数；单网络 L^2 误差由 Cauchy–Schwarz 转移到任意先验边缘耦合。

E 计算树展开项的逐层比较

固定 L、$N = m^L$；奇激活取奇数 $m \geq 5$，分段线性激活取偶数 $m \geq 6$。令 $\delta_d, \kappa_d \leq K_d/\sqrt{d}$，$K_d$ 是可随有限次运算增大的固定对数幂。每个节点选取正次单项式并排列孩子，形成有序展开项；固定其 N 个输入因子与齐次教师项的槽配对，最后对有限种选择和至多 $N!$ 个排列求和。教师、源各自的原高斯事件先固定，跨网络映射随后可任意依赖两网络。

引理 17 (有序树消元)**.** *高度 $t < L$、根为任意零常数多项式 A、下层为 P 的每个有序 N 次展开项，与高度 L 的齐次教师项的每种固定槽配对均为 $o(1)$。高度 L 的普通 P 展开项中，除每个节点次数均为 m 的项外，结论相同。*

证明. 对源高度 t 强归纳；固定 t，按教师高度处理未完成节点。高度 $h-1$ 的已完成收缩作为第 h 步的因子，新输出下一步才使用。跨网络收缩均放在源侧，教师保留原始齐次系数 C。固定当前教师行 i 后，其余完整教师因子的范数至多 $K_d\|C(e_i,\cdot)\|$，故

$$\sum_i \|C(e_i,\cdot)\| \leq \sqrt{k}\|C\| \leq K_d\sqrt{d}. \tag{52}$$

在源原树的停止节点重建系数核，再施加有界完整特征映射；各高度输出分别保留标签。同一父索引的复制也保留，不视为独立高斯列索引或可删碰撞。纯一元链先用引理 10 精确求和，所有收缩均作用于恢复后的无掩码项。

完整收缩与保留索引子程序。 一次合法完整收缩使用同一源节点的 m 个完整线性孩子，其矩阵 $M_{ia} = \prod_{j=1}^m \rho_{ia}^{(j)}$ 满足

$$\sup_i \sum_a |M_{ia}| + \sup_a \sum_i |M_{ia}| \leq K_d, \qquad \|AM\|_{\max} \leq K_d\kappa_d, \tag{53}$$

其中各 $\rho^{(j)}$ 的行列 ℓ^2 范数有界，A 为下一教师原高斯矩阵。前式由 Hölder 得到，后式只用 $\|A\|_{\max} \leq \kappa_d$，不要求 M 独立于 A。完整孩子尚不保证高度增长，因为同一原节点可产生多个旧输出。每次复用旧输出前，先排除其来源节点仍有其他因子的项；过滤后，父收缩才严格高于已完成孩子。因此高度 h 的教师子树在每条源路径上至少占用 h 个原节点。

二模式的特殊状态写成

$$\sum_{a,b} E_{ab}\ell_a \otimes Q_b, \qquad \|E\|_{\mathrm{HS}} \leq K_d, \quad \|E\|_{\mathrm{op}} \leq \delta_d. \tag{54}$$

ℓ 是一个完整当前因子，Q 为原始高度至多 $L-1$ 的完整子树；E 是原二阶停止核或沿原一元链传播的核，故满足引理 9。此式包含全部未收缩因子和下一步输出。保留 a，暂缓从 ℓ 到教师根的整条路径，按高度处理路径之外的教师子树。每次先检查旧输出复用，再推进选中路径；旧 G 只来自已认证完整的较低教师高度步骤。此时选一个 Q 后代就有至少两个模式，选两个不同后代就有至少三个模式。因此旧收缩因子仍带残余时，式 (38) 的混合父界或多模界适用；两个不同源父节点相遇时，引理 14 的 $R \geq 3$ 界适用。混合父旧输出的完整配对直接为 $O(K_d\kappa_d) = o(1)$；同父旧输出与双父切片情形，固定教师行后的完整余张量分别至多 $K_d\delta_d(\delta_d + \kappa_d)$ 和 K_d/d，由(52) 均为 $o(1)$。对余下项，将选中路径推进到最低的非单因子节点；若来自同一非线性孩子，应更早停止，故每步只能完整使用该节点的 m 个线性孩子。每次收缩使已完成教师节点数增加；其间线性路径游标仅沿有限原树向上移动。旧输出的上述过滤保证每次父收缩严格高于孩子，故高度计数适用于 Q。此子程序不调用本引理的结论，也不递归调用二模式子程序。

根部其余 $m-1$ 个教师孩子高度均为 $L-1$。若 Q 更浅，消元不能完成；若其高度恰为 $L-1$，这 $m-1$ 次收缩只能在 Q 原根 b 处完成。记矩阵为 $M^{(j)}$，$G^{(j)}=AM^{(j)}$；每个 $G^{(j)}$ 的列 ℓ^2 范数有界，最大条目至多 $K_d\kappa_d$。保留整条暂缓路径及所有残余，去掉这 $m-1$ 个已知因子后有

$$R_b=\sum_a E_{ab}\ell_a\otimes Q_b^{\mathrm{res}},\qquad \sum_b\|R_b\|\le K_d\sqrt{d}\|E\|_{\mathrm{HS}}.$$

固定最终教师行时其完整路径范数有界。结合归一化读出的 $O(d^{-1/2})$ 最大值，对两个 G 用列 ℓ^2 界、其余 $m-3$ 个用条目界，整个配对至多

$$K_d\|E\|_{\mathrm{HS}}\kappa_d^{m-3}=o(1). \tag{55}$$

此处同时使用全部 $m-1$ 个因子，未将小标量核单独乘任意余张量。

消元顺序与全部边界。 首先排除旧收缩因子再次使用时仍带其他因子的项。当前教师节点若接触另一源父节点，用(38) 第一行；否则原核为多模，或一模且另有至少两个因子时，用第二行。一模无其他因子时可继续。若仅有的另一因子也是旧收缩因子，本列两个当前位置容不下 $m\ge 5$ 个槽，属第一种情况。若它是原始完整孩子，正次数及其他输出标签的保留迫使上方只有原一元链；故系数 d 满足 $\|d\|_2\le K_d$、$\|d\|_\infty\le\kappa_d$。展开该孩子第一条边，得到(54)，其中 $E_{ab}=d_aU_{ab}$、Q 高度至多 $t-1\le L-1$，由保留索引子程序排除。此后复用的收缩因子均包含其来源节点的全部因子。

然后沿当前教师节点所选的 m 条源路径向上推进；一元节点精确求和，在最低的非单因子节点停止，较高路径暂缓，较低路径推进至同高或其更低分支。选中最低父节点的当前层列索引随该层右旋转，且删除选中槽后仍有残余。若选中因子涉及不同父节点，原核有至少三个模式时用双父引理的 $R\ge 3$ 情形。二模式中若一父为单因子、另一父有残余，使用保留索引子程序。若两父都有残余，则两者同属当前原高斯层：较高层的旧收缩因子已不带其他因子，而暂不处理的较高输出另保留标签，会使模式数至少三。故二阶非对角项满足双父引理的两边非空残余条件。

二阶对角由式 (46) 化为 $\lambda_sI/\sqrt{k_s}$ 加 $o_{L^2}(1)$ 的 Hilbert–Schmidt 误差；误差通过完整有界特征映射传递。主项将两个原父标签识别，将根单项式相乘，保持全部有序孩子与原教师槽分配，成为高度 $s<t$、读出 $1/\sqrt{k_s}$ 的前缀项。根次数允许任意奇偶性，故由加强的源高度归纳控制；已有收缩展开回原始等式后无残缺子树。$s=0$ 时只有输入次数二，不贡献 $N>2$。不同层的二模式不使用此对角公式：较高的旧因子若参与，就用保留索引子程序；若不参与，本次仅涉及一个父节点。若两个模式均为较高旧输出，每个至多含 m^{L-1} 个原输入因子，合计小于 N；若一个已达高度 L，它已耗尽 N 个因子。确定性复制只按原输入因子数计数，不增加原父节点数。

余下 m 条路径必在同一最低源父节点相遇，且来自 m 个不同的完整线性孩子，否则应在更低非线性孩子处停止。故每步均为合法完整收缩；有限原树的边仅推进有限次，过程终止。高度计数排除 $t<L$。$t=L$ 时每条路径必须取等号，故无额外一元节点且每节点次数恰为 m；除预先分出的全 m 项外均矛盾。二阶融合已严格降低源高度，归纳从 $t=1$ 起闭合。全 m 项的系数、权重与归一化保持原值，两类激活的结论同时成立。 □

E.1 从确定性事件到任意先验耦合

先控制边缘误差，再对耦合取上确界。固定次数和深度时，有序展开项、因子配对、停止位置、合并高度及收缩步骤的种类数均与 d 无关。先在两个边缘上施加全部原始高斯事件，再允许跨网络收缩矩阵依赖两网络。共同好事件上，各项均为确定性 $o(1)$；坏事件上，结合固定次数系数的有界边缘高阶矩、Hölder 不等式及任意多项式阶失败概率控制。因此估计对所有先验边缘耦合一致。

设 T_W 为与激活对应、带完整标量系数的全 m 平衡齐次输入混沌项，$\mathcal{Q}_N(V)$ 为式 (50) 的多项式近似。上述逐展开项估计给出 $\mathbb{E}_\pi|\langle T_W,\mathcal{Q}_N(V)-T_V\rangle|=o(1)$，对耦合一致。又 T_W 位于第 N 输入混沌，故 $\langle T_W,F_V\rangle=\langle T_W,\Pi_NF_V\rangle$。剩余配对期望由 Cauchy–Schwarz 不等式控制为 $\|T_W\|_{L^2(W,X)}\|\Pi_NF_V-\mathcal{Q}_N(V)\|_{L^2(V,X)}=o(1)$；由有界边缘二阶矩与式 (51)，此界亦对耦合一致，故

$$\boxed{\sup_{\pi\in\Gamma(\mathsf{P}_W,\mathsf{P}_V)}\mathbb{E}_\pi|\langle T_W,F_V-T_V\rangle|\longrightarrow 0.} \tag{56}$$

F 齐次比较网络的全局匹配

固定 L、整数 $m \ge 5$、$k_0 = d$ 及 $k_s \asymp d$。本节的齐次网络为 $h^{(s)} = c_m (W^{(s)} h^{(s-1)}/\sqrt{k_{s-1}})^{\odot m}$, $c_m = (m!)^{-1/2}$, $h^{(0)} = x$，输出为 $\mathcal{H}_W = k_L^{-1/2} \sum_i h_i^{(L)}$，参数数目为 $p = \sum_s k_{s-1} k_s$。将 $h^{(s)}$ 换成形式变量 Y 后的输出记为 $P_s(Y)$，其次数为 $q_s = m^{L-s}$。写 $P_s(Y) = \langle C_s, Y^{\otimes q_s} \rangle$，使用继承的 Hilbert 范数，即

$$\|C_r(P)\|^2 = \sum_{|\nu|=r} \frac{\nu!}{r!} |p_\nu|^2 \quad \text{若} P(Y) = \sum_\nu p_\nu Y^\nu; \qquad C_L = k_L^{-1/2} \mathbf{1}. \tag{57}$$

定理 2 (齐次网络的有限标签全局匹配)**.** *存在确定性的参数对齐映射族 $\mathcal{G}_d$，使任意两个具有原独立标准高斯先验边缘的网络满足*

$$\log |\mathcal{G}_d| = O(d \log d) = o(p), \qquad p^{-1} \mathbb{E} \min_{g \in \mathcal{G}_d} \|W - gV\|_F^2 \le K \mathbb{E} \|C_0(W) - C_0(V)\|^2 + o_d(1). \tag{58}$$

K 只依赖固定深度、次数和宽度比例，余项对耦合一致。右侧亦可换为 $K \mathbb{E} \|\mathcal{H}_W - \mathcal{H}_V\|^2_{L^2(N(0,I_d))} + o_d(1)$。

共同典型事件。 归一化权重行的长度一致趋于一，单位行自身相干度 $\eta_d = O(\sqrt{\log d/d})$，行阵列算子范数有界，列平方和有正的常数上下界。在此高斯集中事件上，第 B 节的两个 Gram 界适用。令 $B_{s,i} = \partial_i P_s$、$w_j = W_{j:}^{(s+1)}/\sqrt{k_s}$；链式法则给出

$$B_{s,i}(Y) = m c_m \sum_j w_{ji} (w_j \cdot Y)^{m-1} B_{s+1,j}\big(c_m (w \cdot Y)^{\odot m}\big).$$

展开后的项正是 (30) 中带标签 (ν, j) 的删除因子张量。固定次数下单项式系数范数与 (57) 等价，从 $B_{L,i} = k_L^{-1/2}$ 反向归纳得 $\|C(B_{s,i})\|^2 \asymp \sum_j w_{ji}^2 \|C(B_{s+1,j})\|^2 \asymp k_s^{-1}$。因此完整切片满足

$$a/k_s \le \|C_s(e_i, \cdot)\|^2 = q_s^{-2} \|C(\partial_i P_s)\|^2 \le b/k_s. \tag{59}$$

特别地 $\|C_s\| \le C$。令 SF 投影到平方自由坐标，其正交基中的系数为 $c_I = p_I/\sqrt{q_s!}$（$|I| = q_s$）。式 (37) 及原始系数界 13 给出同一边缘高概率事件上的

$$\max_I |c_I|^2 \le C (\log d)^{D_s} k_s^{-q_s}, \qquad D_s = m + \cdots + m^{L-s}, \tag{60}$$

$$\|(I - \mathrm{SF}) C_s\|^2 \le L_d/d = o(1). \tag{61}$$

终层取 $D_L = 0$，第二项为零；L_d 为适当的对数幂。内部层的协调行列变换保持权重集中量，仅使系数重排、变号，故数据依赖对齐后全部估计仍逐点成立。

全局对称与分组提升。 在一层写归一化行 $w_i = r_i a_i$、$\|a_i\| = 1$，置 $U_A e_i = a_i^{\otimes m}$、$\overline{C}_s = \mathrm{diag}(r_i^m)^{\otimes q_s} C_s$。有 $\|U_A\| \le \|A\|^m \le C$ 及精确代入式

$$C_{s-1} = c_m^{q_s} \, \mathrm{Sym}_{m q_s} U_A^{\otimes q_s} \overline{C}_s. \tag{62}$$

半径一致趋于一，故 $\overline{C}_s - C_s = o(1)$；逐坐标半径乘子一致为 $1 + o(1)$，故 (59)–(61) 仍成立。对任意两个典型网络及 $q = q_s$，一致有

$$\|C_{s-1}^A - C_{s-1}^B\|^2 = \lambda_{m,q} \|G_A - G_B\|^2 + o(1), \qquad \lambda_{m,q} = \frac{q!}{(mq)!}. \tag{63}$$

这里 $G_A = U_A^{\otimes q} \overline{C}_s^A$、$G_B = U_B^{\otimes q} \overline{C}_s^B$。定义平方自由基的分组与全对称提升 $Q_I = \sqrt{q!}\, \mathrm{Sym}_q \bigotimes_{i \in I} a_i^{\otimes m}$、$E_I = \sqrt{(mq)!/(m!)^q}\, \mathrm{Sym}_{mq} \bigotimes_{i \in I} a_i^{\otimes m}$。式 (62) 将该基送到 $\sqrt{\lambda_{m,q}} E_I$。置 $\rho_{ij} = \langle a_i, b_j \rangle$、$\tau = d^{-1/8}$。二部图 $|\rho_{ij}| > \tau$ 的度数至多 $D = \lceil C/\tau^2 \rceil$；在各侧连接共享邻居的顶点，度数至多 D^2。不含这种边的 q 元集称为好集。对好 $I = \{i_1, \dots, i_q\}$ 和 $\sum_a v_a = m$，

$$\sum_j \prod_a |\rho_{i_a j}|^{v_a} \le \begin{cases} C, & |\operatorname{supp} v| = 1, \\ C\tau, & |\operatorname{supp} v| \ge 2. \end{cases} \tag{64}$$

每列至多一个因子超过 τ；按最大因子位置分区，从乘积保留该因子的平方，或保留它与另一因子各一幂。余下至少一幂不超过 τ，所留两幂的和由平方和界或 Cauchy–Schwarz 控制。配对计数给出

$$\langle E_I^A, E_J^B\rangle = \sum_{\substack{e_{ab}\ge 0\\ \sum_b e_{ab}=\sum_a e_{ab}=m}} \frac{(m!)^q}{\prod_{a,b} e_{ab}!}\prod_{a,b}\rho_{i_a j_b}^{e_{ab}}.$$

$e = mP$（P 为排列矩阵）的项之和正是 $\langle Q_I^A, Q_J^B\rangle$。其余项至少一列混合两个标签；把对 J 的求和扩大到所有有序指标并分离各列，式 (64) 给出绝对行和 $O(\tau)$。交换两侧给出列和。令 $K_{\mathrm{act}} = (\langle E_I^A, E_J^B\rangle)_{I,J}$、$K_{\mathrm{grp}} = (\langle Q_I^A, Q_J^B\rangle)_{I,J}$ 为好集上的交叉 Gram，则

$$\|K_{\mathrm{act}} - K_{\mathrm{grp}}\|_{\mathrm{op}} \le C\tau. \tag{65}$$

取两网络相同即得自身 Gram；因 $\eta_d < \tau$，所有集合均好。坏集至多 $C_q D^2 k^{q-1}$ 个，其总系数能量由 (60) 至多为 $Cd^{-1/2}(\log d)^{D_s} = o(1)$，此计数也适用于依赖两网络和系数的图。两种提升有界，故删除坏集及重复指标均产生 $o(1)$ 误差；对三个 Gram 块应用 (65) 并恢复完整系数，得 (63)。$q = 1$ 时无拆槽，等式精确成立。

单层匹配与系数恢复。 令 $M = U_A^* U_B = (\rho_{ij}^m)$、$\rho_i = \max_j |\rho_{ij}|$。每行超过 τ 的学生行至多 D 个，自身 Gram 范数至多 $1 + D\eta_d$；其余项保留平方并提出 τ^{m-2}，得

$$\sum_j |M_{ij}| \le \rho_i^{m-2} + e_d, \qquad \sum_i |M_{ij}| \le 1 + e_d, \qquad e_d = C(D\eta_d + \tau^{m-2}) = o(1). \tag{66}$$

写完整有序系数数组 $C = \overline{C}_s^A = (c_I)$、$D' = \overline{C}_s^B = (d_J)$，并令 $\mathsf{K} = (M/(1+e_d))^{\otimes q}$。其绝对行列和 $r_I, s_J \le 1$，且

$$\begin{aligned}\mathcal{E} &:= \|C\|^2 + \|D'\|^2 - 2\langle C, \mathsf{K}D'\rangle \\ &= \sum_I (1 - r_I)c_I^2 + \sum_J (1 - s_J)d_J^2 + \sum_{I,J} |\mathsf{K}_{IJ}|(c_I - \mathrm{sgn}(\mathsf{K}_{IJ})d_J)^2.\end{aligned} \tag{67}$$

因 $U_A^* U_A, U_B^* U_B = I + o_{\mathrm{op}}(1)$（非对角绝对行和至多 $k\eta_d^m = o(1)$），有 $\mathcal{E} = \|G_A - G_B\|^2 + o(1)$。$r_I$ 为各槽行和的乘积，故用第一槽的缺额及完整切片下界 (59) 得 $k_s^{-1}\sum_i (1 - \rho_i^{m-2}) \le C\mathcal{E} + o(1)$。固定 $\rho_0 \in (1/\sqrt{2}, 1)$。因 $2\rho_0^2 > 1 + \eta_d$，绝对相关超过 ρ_0 的边构成部分双射。补为排列并逐行定向，使对角相关非负；未匹配比例由上述缺额控制，已匹配行用 $1 - x^m \le m(1 - x^{m-2})/(m-2)$，便得

$$k_s^{-1}\sum_i \left(\ell_i + \|a_i - b_i\|^2\right) \le C\mathcal{E} + o(1), \qquad \ell_i = 1 - \langle a_i, b_i\rangle^m. \tag{68}$$

同步重排系数并乘相应 m 次符号以保持 G_B 不变。此时 $\mathsf{K}_{II} \ge 0$，$1 - \mathsf{K}_{II} \le \sum_{a=1}^q (\ell_{i_a} + e_d)$。保留 (67) 的对角平方项，并用完整切片上界，得到

$$\|C - D'\|^2 \le \mathcal{E} + \sum_I (1 - \mathsf{K}_{II})(c_I - d_I)^2 \le \mathcal{E} + \frac{Cq}{k_s}\sum_i (\ell_i + e_d) \le C\mathcal{E} + o(1).$$

去掉半径因子，结合 (63) 得

$$\|C_s^A - C_s^B\|^2 + k_s^{-1}\sum_i \|w_i - v_i\|^2 \le C\|C_{s-1}^A - C_{s-1}^B\|^2 + o(1). \tag{69}$$

此处行已对齐；半径误差由 $\|r_i a_i - t_i b_i\|^2 \le C\|a_i - b_i\|^2 + C\max_j(|r_j - 1| + |t_j - 1|)^2$ 吸收。

深度归纳及任意耦合。 内部层的有符号行排列写作 $S_s = D_s P_s$，令 $R_s = D_s^{m \bmod 2} P_s$。将下一层的列同时变为 $V^{(s+1)} R_s^{-1}$，保持整个齐次函数及当前 C_{s-1} 不变。故自下而上对内部层应用 (69)，后续对齐不影响已完成层，固定深度下每层平均归一化行距离均至多 $C\|C_0(W) - C_0(V)\|^2 + o(1)$。终层 $q_L = 1$ 只需 (68)：定向符号为 ς_i 时，在分析表示中将学生系数改为 $\varsigma_i^m t_i^m/\sqrt{k_L}$，保持原张量及切片

界。无需恢复终层系数；终层符号仅为参数标签，不要求保持函数。取所有映射 $(gV)^{(1)} = S_1 V^{(1)}$、$(gV)^{(s)} = S_s V^{(s)} R_{s-1}^{-1}$，则 $\log|\mathcal{G}_d| \le \sum_s (\log(k_s!) + k_s \log 2) = O(d \log d)$。按固定标签次序打破平局可使选择可测。将各层界以 $k_{s-1}k_s/p$ 加权相加，即得典型事件上的 (58)。任意先验耦合的失败概率至多为两边缘失败概率之和；坏事件上用恒等对齐及 $p^{-1}\|W - V\|^2 \le 2p^{-1}(\|W\|^2 + \|V\|^2)$，由归一化高斯平方范数的一致二阶矩和 Cauchy–Schwarz，期望贡献一致为 $o(1)$。最后 $N = m^L$ 阶高斯混沌的等距性给出 $N!\|C_0(W) - C_0(V)\|^2 = \|\Pi_N(\mathcal{H}_W - \mathcal{H}_V)\|_{L^2}^2 \le \|\mathcal{H}_W - \mathcal{H}_V\|_{L^2}^2$，证明函数距离版本。 □

实际函数的参数比较。 式 (56) 和正文极化恒等式将实际函数距离控制转为齐次系数距离控制，再应用定理 2。行符号仅用于有限标签对齐，不要求保持实际激活的函数值。

G 条件 I–MMSE 与统一平滑测试场

记 $f = F_{\theta(W)}^{(L)}(X)$、$a = \nabla_W f$、$\mathcal{I}_W = \mathbb{E}_X aa^T/\Delta$、$Z = (\mathcal{D}_n, X)$。另取独立标准高斯 N，令 $U_s = \sqrt{s} f + N$、$m(s) = \mathbb{E}[(f - \mathbb{E}[f \mid Z, U_s])^2]$。真实高斯输出通道及条件 I–MMSE 给

$$\epsilon_{\log,d,n} = I(f; U_{1/\Delta} \mid Z) = \frac{1}{2}\int_0^{1/\Delta} m(s)\, ds. \tag{70}$$

第二等号的证明：条件于 $Z = z$，令 q_v 为 $f + \sqrt{v}N$ 的密度。高斯热方程、分部积分及条件期望公式给

$$\frac{d}{dv} h(q_v) = \frac{1}{2}\mathcal{J}(q_v), \qquad \partial_y \log q_v(y) = \frac{\mathbb{E}[f \mid z, f + \sqrt{v}N = y] - y}{v}.$$

正交分解得到 $\mathrm{mmse}(f \mid z, f + \sqrt{v}N) = v - v^2 \mathcal{J}(q_v)$。将 $h(q_v)$ 减去噪声熵后微分，令 $v = 1/s$，即得互信息导数为 MMSE 的一半。上述计算先对截断信号及有界空间成立；由 $\mathcal{J}(q_v) \le 1/v$ 和信号二阶矩的一致可积性，可在任意 $0 < s_0 \le s \le s_1$ 上去掉截断。最后用 $I(f; U_s \mid Z) \le s\mathbb{E}f^2/2$、$m(s) \le \mathbb{E}f^2$，平均 z 并令 $s_0 \downarrow 0$，即得 (70)。

G.1 真实通道的分部积分界

对只依赖 (W, X) 的向量场 b，令

$$G_s = \delta b + b^T S_D + \sqrt{s} N b^T a, \qquad \delta b = \mathrm{div}_W\, b - W \cdot b, \quad S_D = \nabla_W \log p(\mathcal{D}_n \mid W).$$

固定观察并对参数分部积分得 $\mathbb{E}[(\mathbb{E}[f \mid Z, U_s] - f)G_s] = \mathbb{E}b^T a$。给定 (W, X)，训练得分与辅助噪声独立且中心化，训练得分协方差为 $n\mathcal{I}_W$。因此 Cauchy–Schwarz 给

$$m(s) \ge \frac{(\mathbb{E}b^T a)^2}{n\mathbb{E}b^T \mathcal{I}_W b + \mathbb{E}(\delta b)^2 + s\mathbb{E}(b^T a)^2}. \tag{71}$$

先对紧支撑光滑场和截断后验均值证明，再由引理 7 的 Sobolev 逼近及 L^2 收敛取极限；可积性见下。

G.2 正则化测试场的 OU 平滑

固定 $0 < \tau \le r \le 1$，令 $\lambda = r/p$、$M_W = (\mathcal{I}_W + \lambda I_p)^{-1}$、$b_0(W, X) = M_W a(W, X)$。取 (6) 中的 W_τ，仅对参数作条件平均：

$$b_\tau(W, X) = \mathbb{E}[b_0(W_\tau, X) \mid W, X].$$

真实网络、训练似然及辅助观测 U_s 均不变。有

$$\mathbb{E}\|b_0\|^2 = \Delta\mathbb{E}\,\mathrm{tr}(M_W^2 \mathcal{I}_W) \le \frac{\Delta p}{4\lambda}, \qquad \mathbb{E}\|b_\tau\|^4 \le \mathbb{E}\|b_0\|^4 \le C\lambda^{-4}.$$

将 b_0 视为 $L^2(P_X; \mathbb{R}^p)$ 值函数，记第 k 阶参数 Hermite 能量为 c_k。OU 半群逐阶乘 $e^{-\tau k}$，所以

$$\mathbb{E}\|Db_\tau\|_{\mathrm{HS}}^2 = \sum_{k \ge 1} k e^{-2\tau k} c_k \le C\tau^{-1}\mathbb{E}\|b_0\|^2 \le Cp^2/(r\tau).$$

故 b_τ 属于高斯 $W^{1,2}$，无需对 M_W 求导。由引理 7、梯度四阶矩及 $\tau \le r$，

$$\mathbb{E}(\delta b_\tau)^2 \le Cp^2/(r\tau), \qquad \mathbb{E}(b_\tau^T a)^2 \le (\mathbb{E}\|b_\tau\|^4 \mathbb{E}\|a\|^4)^{1/2} \le Cp^2/r^2 \le Cp^2/(r\tau). \tag{72}$$

写 $b'(x) = b_0(W_\tau, x)$、$a'(x) = a(W_\tau, x)$、$e(x) = a(W, x) - a'(x)$，并另取独立输入 $\overline{X}$。条件于 $(W, W_\tau, \overline{X})$，$X$ 仍独立，因此

$$\mathbb{E}_X b'(X) b'(X)^T = \Delta M_{W_\tau} \mathcal{I}_{W_\tau} M_{W_\tau} \preceq \frac{\Delta}{4\lambda} I_p.$$

由 (6)，$\mathbb{E}\|e(X)\|^2 \le C\tau^\delta$。Cauchy–Schwarz 和上述条件协方差分别给出

$$|\mathbb{E} b'(X)^T e(X)| \le Cp\tau^{\delta/2}/\sqrt{r}, \qquad \Delta^{-1}\mathbb{E}[(b'(X)^T e(\overline{X}))^2] \le \frac{\mathbb{E}\|e(\overline{X})\|^2}{4\lambda} \le Cp\tau^\delta/r.$$

高斯先验不变性给 $\mathbb{E} b'(X)^T a'(X) = \Delta p[1 - D_d(r)]$；独立输入给 $\Delta^{-1}\mathbb{E}[(b'(X)^T a'(\overline{X}))^2] = \Delta \mathbb{E}\,\mathrm{tr}[(M_W \mathcal{I}_W)^2] \le \Delta p$。故条件 Jensen 与 L^2 三角不等式给

$$\begin{aligned} \mathbb{E} b_\tau^T a &= \mathbb{E} b'(X)^T (a'(X) + e(X)) \ge \Delta p[1 - D_d(r) - C\tau^{\delta/2}/\sqrt{r}], \\ \mathbb{E} b_\tau^T \mathcal{I}_W b_\tau &\le \Delta^{-1}\mathbb{E}[(b'(X)^T (a'(\overline{X}) + e(\overline{X})))^2] \le \Delta p[1 + C\tau^{\delta/2}/\sqrt{r}]^2. \end{aligned} \tag{73}$$

将目标量下界取正部，与 (72) 一同代入 (71) 并对 (70) 积分。最后取 $\tau = r^{2/\delta} \le r$，使 $\tau^{\delta/2}/\sqrt{r} = \sqrt{r}$，即得 (23)。